

中文版 Method

仅供客户在文章写作时参考，分析内容和方法请以结题报告为准，请客户自行承担文章查重等相关风险。

1.实验流程

1.1 样品检测(DNA Quality Control)

详见样本检测报告。

1.2 DNA 片段化(DNA Shearing)

将基因组 DNA 经 Covaris 破碎仪随机打断成长度为 350bp 左右的片段。

1.3 末端修复反应(End Repair)

片段化后的 DNA 存在 5'或 3'端突出,向纯化后的 DNA 片段中加入末端补齐体系,其中 T4 DNA 聚合酶(T4 DNA Polymerase)的外切酶(Exonuclease)活性消化 3'端的单链突出,而聚合酶(Polymerase)活性补齐 5'端的突出;同时磷酸激酶(PNK)在 5'末端加上后续连接反应必需的磷酸基团,经过 Agencourt AMPure XP 磁珠纯化,最终得到 5'端含有磷酸基团的平末端 DNA 短片段文库。

1.4 3'端加“A”尾(Adenylate 3' Ends)

向上述体系中加入 3'末端加“A”缓冲反应体系。在末端修饰完成的双链 DNA 3'末端加上单个腺苷酸“A”,防止 DNA 片段之间的平末端自连,还可以与下一步测序接头 5'末端的单个“T”突出互补配对,准确连接,有效降低文库片段之间自身的串联。

1.5 连接测序接头(Adapter Ligation)

向上述反应体系中加入连接缓冲液和双链测序接头,利用 T4 DNA 连接酶将 Illumina 测序接头连接至文库 DNA 两端。

1.6 文库片段筛选(Size Selection)

对于加上接头的文库,应用 Agencourt SPRIselect (Beckman Coulter, USA, Catalog #: 2358413)核酸片段筛选试剂盒在纯化文库的同时,进行片段大小筛选。采用两步法筛选(Double Size Selection),先用 SPRI 磁珠去掉目标域左侧小片段(Left-side Size Selection),再去掉位于目标片段区域右侧的大片段(Right-side Size Selection)最终筛选出片段长度适中的原始文库,用于下一步的 PCR 扩增。经过纯化后的文库,去掉了体系中过量的测序接头和接头自连产物,避免 PCR 过程的无效扩增,消除对上机测序的影响。

1.7 PCR 扩增 DNA 文库(PCR Amplification)

应用高保真的聚合酶扩增原始文库,以保证足够的文库总量。此外因为只有两端都连有接头的 DNA 片段才能够被扩增,因此该步骤还能够有效富集这部分 DNA。在保证产物足够的前提下,减少因扩增循环数过大而引入的 bias;最终使用 Qubit3.0 精确测定每个文库浓度。

1.8 文库库检 (Library Quality Assessment)

文库构建完成后, Agilent 5400 system(AATI)对文库的 insert size 进行检测, insert size 符合预期后, 使用 qPCR 方法对文库的有效浓度(1.5 nM)进行准确定量, 以保证文库质量。

1.9 桥式 PCR (BridgePCR)

库检合格后, 根据文库的有效浓度及数据产出在 Illumina Novaseq 平台进行测序。即将捕获后的文库种到 FlowCell 芯片上进行扩增的过程。FlowCell 通道内表面种植有两种不同的 DNA 引物, 这两种引物序列与 DNA 文库中两头的接头序列相互补, 且以共价键形式连接在 FlowCell 上。具体过程如下:

a. 将 DNA 文库加入到芯片上, 由于文库两头的 DNA 序列和芯片上的引物序列互补, 产生互补杂交, 杂交完后, 加入 dNTP 和聚合酶, 聚合酶从引物开始, 沿着模板, 合成一条与原来 DNA 序列互补的 DNA 链;

b. 加入 NaOH 碱溶液, 使得 DNA 双链解链, 冲走原来那条没有和芯片共价连接的 DNA 链, 保留新合成的和芯片共价连接的 DNA 链;

c. 再在液流磁中加入中和液, 中和掉碱性溶液, 此时 DNA 上的另一端和芯片上的另一个引物发生互补杂交, 加入酶和 dNTP, 合成一条新的 DNA 链; 再次加入碱溶液, 使两条 DNA 链分开, 再加中和液, DNA 即和芯片上新的引物杂交, 加酶和 dNTP, 再次从新的引物上合成新链, 连续重复这一过程, DNA 链以指数的方式增长。

1.10 Illumina 平台 PE150 上机测序(Sequencing)

PE150 即 Pair-end150bp, 高通量测序。在构建的 DNA 小片段文库中, 将每条插入片段进行两端测序, 每端各测 150bp, 具体过程如下:

完成桥式 PCR 之后, 将合成的双链变成可以测序的单链;

将芯片上其中一个引物的一个特定基团切断, 碱溶液冲洗芯片, 使得 DNA 双链解链, 且被切断根部的 DNA 链被冲掉, 留下被共价键连接的那条链;

加入中性溶液、测序引物及带荧光标记的 dNTP, 四种 dNTP 由四种不同的荧光标记, 其 3'末端被叠氮基堵住, 再加入聚合酶, 使 dNTP 合成到新的 DNA 链上, 由于其 3'末端被叠氮基堵住, 故每个循环只能延长一个碱基, 完成一个循环后将多余的 dNTP、酶等冲掉, 置于显微镜下进行激光扫描, 根据发出来的荧光判断新合成的是哪个碱基, 通过互补原理可推测模板碱基;

在完成一个循环之后, 加入化学试剂, 将叠氮基团和荧光基团切掉, 使得 3'端羟基暴露出来, 加入新的 dNTP 和新的酶, 又延长一个碱基, 新的碱基延长完成之后, 把多余的 dNTP 和酶冲掉, 再进行一轮显微激光扫描, 再读一轮此碱基, 不断重复此循环, 就可以读出上百个碱基。

2 生物信息分析

测序结束后对原始序列进行信息分析, 通过对数据质量进行评估, 判断其是否达到标准, 若符合标准, 则对样本进行变异检测, 包括 SNP、InDel、CNV、SV, 并注释; 若不合标准, 则需根据实际情况加测或者重新建库。

2.1 测序数据质控

2.1.1 原始数据

获得 FASTQ 格式的数据，包含序列信息和相应的测序质量信息。

2.1.2 测序数据质量评估

a.原始数据过滤:去除带接头(adapter)的 reads 对;去掉单端测序 read 中 N(N 表示无法确定碱基信息)的比例大于 10%的 reads 对;当单端测序 read 中含有的低质量(低于 5)碱基数超过该条 read 长度比例的 50%时，去除此对 reads。

b.检查测序错误率分布:测序错误率是在碱基识别(Base Calling)过程中通过一种判别发生错误概率的模型计算得到的。它与碱基质量有关，受测序仪本身、测序试剂、样品等多个因素共同影响。测序错误率分布检查用于检测在测序长度范围内，有无异常的碱基位置存在高错误率，一般情况下，每个碱基位置的测序错误率都应该低于 1%。

c.测序数据质量分布:依照测序技术特点，测序片段末端碱基质量一般较前端低。

2.1.2 测序数据质量评估

a.原始数据过滤:去除带接头(adapter)的 reads 对;去掉单端测序 read 中 N(N 表示无法确定碱基信息)的比例大于 10%的 reads 对;当单端测序 read 中含有的低质量(低于 5)碱基数超过该条 read 长度比例的 50%时，去除此对 reads。

b.检查测序错误率分布:测序错误率是在碱基识别(Base Calling)过程中通过一种判别发生错误概率的模型计算得到的。它与碱基质量有关，受测序仪本身、测序试剂、样品等多个因素共同影响。测序错误率分布检查用于检测在测序长度范围内，有无异常的碱基位置存在高错误率，一般情况下，每个碱基位置的测序错误率都应该低于 1%。

c.测序数据质量分布:依照测序技术特点，测序片段末端碱基质量一般较前端低。

2.1.3 测序深度及覆盖度统计

有效测序数据通过 BWA (Li et al., 2009a) 软件(参数:mem -t 4 -k 32 -M)比对到参考基因组，比对结果经 SAMTOOLS (Li et al., 2009b)去除重复(参数:rmdup)。

2.2 变异检测结果

2.2.1 SNP 检测结果

SNP(单核苷酸多态性)主要是指在基因组水平上由单个核苷酸的变异所引起的 DNA 序列多态性，包括单个碱基的转换、颠换等。

我们采用 GATK 软件 (DePristo et al., 2011)(参数 : -gcpHMM 10 -stand_emit_conf 10 -stand_call_conf 30)进行个体 SNP 的检测。为了降低 SNP 检测的错误率, 选用如

下标准进行过滤:

SNP: QD < 2.0, FS > 60.0, MQ < 30.0, HaplotypeScore > 13.0,
MappingQualityRankSum < -12.5, ReadPosRankSum < -8.0

2.2.2 InDel 检测结果

InDel 全称 Insertion and Deletion, 指小片段的插入和缺失。编码区或剪接位点处发生的插入缺失都可能会改变蛋白的翻译。移码变异, 其插入或缺失的碱基串的长度为 3 的非整数倍, 因此可能导致整个读框的改变;移码变异与非移码变异相比较, 前者 对基因功能的影响更大, 同时在群体 中受到更大的筛选压力。

在 比 对 结 果 的 基 础 上 , GATK(-gcpHMM 10 -stand_emit_conf 10 -stand_call_conf 30)检测长度小于 50bp 的小片段插入与缺失(InDel)。选用如下标准进行过滤:

INDEL: QD < 2.0, FS > 200.0, ReadPosRankSum < -20.0

2.2.3 CNV 检测

CNV(拷贝数变异)指基因组片段的拷贝数增加或者减少。可通过 CNVnator(参数:-call 100) (Abyzov et al., 2011)进行检测, 即通过基因组上不同的 reads 覆盖深度, 判断潜在的 deletion 和 duplication。

2.2.4 SV 检测

SV(结构变异)指基因组水平上大片段的插入、缺失、倒置、易位等序列。可利用 BreakDancer(Chen et al., 2009) 软件, 基于 pair-end reads 比对到参考基因组上面的关系及实际 Insert size 大小检测样品与参考基因组间的插入(insertion, INS)、缺失(deletion, DEL)、倒置(inversion, INV)、染色体内部迁移(intra-chromosomal translocation, ITX)、染色体间的迁移(inter-chromosomal translocation, CTX)。过滤去掉 PE reads 支持数小于 2 的 SV 结果。

2.3 注释

ANNOVAR(Wang et al., 2010)是一种高效的软件工具, 它能利用最新的信息, 对 由多个基因组检测出的基因变异进行功能注释。只要给出变异所在的染色体、起始位点、 终止位点、参考核苷酸和变异核苷酸, ANNOVAR 就能进行 Gene-based annotation、Region-based annotations、Filter-based annotation 和 Other functionalities。

2.4 基因功能注释

目前提供注释的通用功能数据库主要有:

GO(Gene Ontology , <http://geneontology.org/>) 、KEGG (Kyoto Encyclopedia of Genes and Genomes , <http://www.genome.jp/kegg>) 、COG(Cluster of Orthologous Groups of proteins , <http://www.ncbi.nlm.nih.gov/COG/>)

功能注释基本步骤如下:

- 1) 将预测基因与各功能数据库进行 BLAST 比对 (blastp, $\text{evalue} \leq 1\text{e-}5$);
- 2) BLAST 结果过滤: 对于每一条序列的 BLAST 结果, 选取 score 最高的比对结果 (默认 $\text{identity} \geq 40\%$, $\text{coverage} \geq 40\%$) 进行注释。

3 参考文献

Abyzov A, Urban AE, Snyder M, Gerstein M. CNVnator: an approach to discover, genotype, and characterize typical and atypical CNVs from family and population genome sequencing. *Genome Res.* 2011;21(6):974-984. doi:10.1101/gr.114876.110

Chen K, Wallis JW, McLellan MD, et al. BreakDancer: an algorithm for high-resolution mapping of genomic structural variation. *Nat Methods.* 2009;6(9):677-681. doi:10.1038/nmeth.13635

Cock PJ, Fields CJ, Goto N, Heuer ML, Rice PM. The Sanger FASTQ file format for sequences with quality scores, and the Solexa/Illumina FASTQ variants. *Nucleic Acids Res.* 2010;38(6):1767-1771. doi:10.1093/nar/gkp1137

Li H, Durbin R. Fast and accurate short read alignment with Burrows-Wheeler transform. *Bioinformatics.* 2009a;25(14):1754-1760. doi:10.1093/bioinformatics/btp324

Li H, Handsaker B, Wysoker A, et al. The Sequence Alignment/Map format and SAMtools. *Bioinformatics.* 2009b;25(16):2078-2079. doi:10.1093/bioinformatics/btp352

DePristo M A, Banks E, Poplin R, et al. A framework for variation discovery and genotyping using next-generation DNA sequencing data. *Nature Genetics.* 2011, 43(5):491-498 .doi: 10.1038/ng.806

Wang K, Li M, Hakonarson H. ANNOVAR: functional annotation of genetic variants from high-throughput sequencing data. *Nucleic Acids Res.* 2010;38(16):e164. doi:10.1093/nar/gkq603