

## 中文版 Method

仅供客户在文章写作时参考，分析内容和方法请以结题报告  
为准，请客户自行承担文章查重等相关风险。

## 1 实验流程

### 1.1 样品检测(Evaluation of DNA quality)

详见样本检测报告。

### 1.2 DNA 片段化(DNA Shearing)

将基因组 DNA 经 Covaris 破碎仪随机打断成长度为 350bp 左右的片段。

### 1.3 末端修复反应(End Repair)

片段化后的 DNA 存在 5' 或 3' 端突出，向纯化后的 DNA 片段中加入末端补齐体系，其中 T4 DNA 聚合酶(T4 DNA Polymerase)的外切酶(Exonuclease)活性消化 3' 端的单链突出，而聚合酶(Polymerase)活性补齐 5' 端的突出；同时磷酸激酶(PNK)在 5' 末端加上后续连接反应必需的磷酸基团，经过 Agencourt AMPure XP 磁珠纯化，最终得到 5' 端含有磷酸基团的平末端 DNA 短片段文库。

### 1.4 3' 端加“A”尾(Adenylate 3' Ends)

向上述体系中加入 3' 末端加“A”缓冲反应体系。在末端修饰完成的双链 DNA 3' 末端加上单个腺苷酸“A”，防止 DNA 片段之间的平末端自连，还可以与下一步测序接头 5' 末端的单个“T”突出互补配对，准确连接，有效降低文库片段之间自身的串联。

### 1.5 连接测序接头(Adapter Ligation)

向上述反应体系中加入连接缓冲液和双链测序接头，利用 T4 DNA 连接酶将 Illumina 测序接头连接至文库 DNA 两端。

### 1.6 文库片段筛选(Size Selection)

对于加上接头的文库，应用 Agencourt SPRIselect 核酸片段筛选试剂盒在纯化文库的同时，进行片段大小筛选。采用两步法筛选(Double Size selection)，先用 SPRI 磁珠去掉目标域左侧小片段(Left-side Size selection)，再去掉位于目标片段区域右侧的大片段(Right-side Size selection)。

最终筛选出片段长度适中的原始文库，用于下一步的 PCR 扩增。经过纯化后的文库，去掉了体系中过量的测序接头和接头自连的产物，避免 PCR 过程的无效扩增，消除对上机测序的影响。

### 1.7 PCR 扩增 DNA 文库(PCR Amplification)

应用高保真的聚合酶扩增原始文库，以保证足够的文库总量。此外因为只有两端都连有接头的 DNA 片段才能够被扩增，因此该步骤还能够有效富集这部分 DNA。在保证产

物足够的前提下,减少因扩增循环数过大而引入的 bias;最终使用 Qubit3.0 精确测定每个文库浓度。

## 1.8 文库质检 (Library Quality Assessment)

文库构建完成后,先使用 Qubit 3.0 进行初步定量,随后使用 Agilent 5400 对文库的 Insert size 进行检测,Insert size 符合预期后,使用 qPCR 方法对文库的有效浓度 ( $>1.5 \text{ nM}$ ) 进行准确定量,以保证文库质量。

## 1.9 桥式 PCR

即将捕获后的文库种到 Flow Cell 芯片上进行扩增的过程。Flow Cell 通道内表面种植有两种不同的 DNA 引物,这两种引物序列与 DNA 文库中两头的接头序列相互补,且以共价键形式连接在 Flow Cell 上。具体过程如下:

a. 将 DNA 文库加入到芯片上,由于文库两头的 DNA 序列和芯片上的引物序列互补,产生互补杂交,杂交完后,加入 dNTP 和聚合酶,聚合酶从引物开始,沿着模板,合成一条与原来 DNA 序列互补的 DNA 链;

b. 加入 NaOH 碱溶液,使得 DNA 双链解链,冲走原来那条没有和芯片共价连接的 DNA 链,保留新合成的和芯片共价连接的 DNA 链;

c. 再在液流磁中加入中和液,中和掉碱性溶液,此时 DNA 上的另一端和芯片上的另一个引物发生互补杂交,加入酶和 dNTP,合成一条新的 DNA 链;再次加入碱溶液,使两条 DNA 链分开,再加中和液,DNA 即和芯片上新的引物杂交,加酶和 dNTP,再次从新的引物上合成新链,连续重复这一过程,DNA 链以指数的方式增长。

## 1.10 Illumina 平台 PE150 上机测序 (sequencing)

PE150 即 Pair end 150 bp,高通量测序。在构建的 DNA 小片段文库中,将每条插入片段进行两端测序,每端各测 150bp,具体过程如下:

完成桥式 PCR 之后,将合成的双链变成可以测序的单链;a. 将芯片上其中一个引物的一个特定基团切断,碱溶液冲洗芯片,使得 DNA 双链解链,且被切断根部的 DNA 链被冲掉,留下被共价键连接的那条链;b. 加入中性溶液、测序引物及带荧光标记的 dNTP,四种 dNTP 由四种不同的荧光标记,其 3' 末端被叠氮基堵住,再加入聚合酶,使 dNTP 合成到新的 DNA 链上,由于其 3' 末端被叠氮基堵住,故每个循环只能延长一个碱基,完成一个循环后将多余的 dNTP、酶等冲掉,置于显微镜下进行激光扫描,根据发出来的荧光判断新合成的是哪个碱基,通过互补原理可推测模板碱基;c. 在完成一个循环之后,加入化学试剂,将叠氮基团和荧光基团切掉,使得 3' 端羟基暴露出来,加入新的 dNTP 和新的酶,又延长一个碱基,新的碱基延长完成之后,把多余的 dNTP 和酶冲掉,再进行一轮显微激光扫描,再读一轮此碱基,不断重复此循环,就可以读出上百个碱基。

## 2 生物信息分析

测序结束后对原始序列进行信息分析,通过对数据质量进行评估,判断其是否达到标准,若符合标准,则对样本进行变异检测,包括 SNP、InDel、CNV、SV,并注释;若不符合标准,则需根据实际情况加测或者重新建库。

## 2.1 数据质量控制

### 2.1.1 原始序列数据

原始测序数据通过 Illumina 测序平台得到的原始图像数据文件经碱基识别 (Base Calling) 分析转化为原始测序序列 (Sequenced Reads), 即 Raw Data, 结果以 FASTQ (简称为 fq) (Cock et al., 2010) 文件格式存储, 其中包含测序序列 (reads) 的序列信息及其对应的测序质量信息。

### 2.1.2 测序数据质量评估

a. 原始数据过滤: 去除带接头 (adapter) 的 reads 对; 去掉单端测序 read 中 N (N 表示无法确定碱基信息) 的比例大于 10% 的 reads 对; 当单端测序 read 中含有的低质量 (低于 5) 碱基数超过该条 read 长度比例的 50% 时, 去除此对 reads。

b. 检查测序错误率分布: 测序错误率是在碱基识别 (Base Calling) 过程中通过一种判别发生错误概率的模型计算得到的。它与碱基质量有关, 受测序仪本身、测序试剂、样品等多个因素共同影响。测序错误率分布检查用于检测在测序长度范围内, 有无异常的碱基位置存在高错误率, 一般情况下, 每个碱基位置的测序错误率都应该低于 1%。

c. 测序数据质量分布: 依照测序技术特点, 测序片段末端碱基质量一般较前端低。

### 2.1.3 测序深度及覆盖度统计

有效测序数据通过 BWA (Li et al., 2009a) 软件 (参数: mem -t 4 -k 32 -M) 比对到参考基因组, 比对结果经 SAMTOOLS (Li et al., 2009b) 去除重复 (参数: rmdup)。

## 2.2 变异检测结果

### 2.2.1 SNP 检测结果

SNP (单核苷酸多态性) 主要是指在基因组水平上由单个核苷酸的变异所引起的 DNA 序列多态性, 包括单个碱基的转换、颠换等。

我们采用 SAMTOOLS (-C 50 -mpileup -m 2 -F 0.002 -d 1000) 进行个体 SNP 的检测。为了降低 SNP 检测的错误率, 选用如下标准进行过滤:

(1) SNP 的 reads 支持数不低于 4;

(2) SNP 的质量值 (MQ) 不低于 20;

### 2.2.2 InDel 检测结果

InDel 全称 Insertion and Deletion, 指小片段的插入和缺失。编码区或剪接位点处发生的插入缺失都可能会改变蛋白的翻译。移码变异, 其插入或缺失的碱基串的长度为 3 的非整数倍, 因此可能导致整个读框的改变; 移码变异与非移码变异相比较, 前者对基因功能的影响更大, 同时在群体 中受到更大的筛选压力。

在比对结果的基础上, SAMTOOLS(`mpileup -m 2 -F 0.002 -d 1000`) 检测长度小于 50bp 的小片段插入与缺失(InDel)。

### 2.2.3 CNV 检测

CNV(拷贝数变异)指基因组片段的拷贝数增加或者减少。可通过 Control-FREEC(Barillot et al., 2012) (参数 `window=100 step = 100`) 进行检测, 即通过基因组上不同的 reads 覆盖深度, 判断潜在的 deletion 和 duplication。

### 2.2.4 SV 检测

SV(结构变异)指基因组水平上大片段的插入、缺失、倒置、易位等序列。可利用 BreakDancer(Chen et al., 2009) 软件, 基于 pair-end reads 比对到参考基因组上面的关系及实际 Insert size 大小检测样品与参考基因组间的插入(insertion, INS)、缺失(deletion, DEL)、倒置(inversion, INV)、染色体内部迁移(intra-chromosomal translocation, ITX)、染色体间的迁移(inter-chromosomal translocation, CTX)。过滤去掉 PE reads 支持数小于 2 的 SV 结果。

## 2.3 注释

ANNOVAR(Wang et al., 2010) 是一种高效的软件工具, 它能利用最新的信息, 对由多个基因组检测出的基因变异进行功能注释。只要给出变异所在的染色体、起始位点、终止位点、参考核苷酸和变异核苷酸, ANNOVAR 就能进行 Gene-based annotation、Region-based annotations、Filter-based annotation 和 Other functionalities。

## 3 参考文献

Barillot E. Control-FREEC: a tool for assessing copy number and allelic content using next-generation sequencing data[J]. *Bioinformatics*, 2012, 28(3):423-425. doi: 10.1093/bioinformatics/btr670.

Chen K, Wallis JW, McLellan MD, et al. BreakDancer: an algorithm for high-resolution mapping of genomic structural variation. *Nat Methods*. 2009;6(9):677-681. doi:10.1038/nmeth.1363

Cock PJ, Fields CJ, Goto N, Heuer ML, Rice PM. The Sanger FASTQ file format for sequences with quality scores, and the Solexa/Illumina FASTQ variants. *Nucleic Acids*

Res. 2010;38(6):1767–1771. doi:10.1093/nar/gkp1137

Li H, Durbin R. Fast and accurate short read alignment with Burrows–Wheeler transform. *Bioinformatics*. 2009a;25(14):1754–1760. doi:10.1093/bioinformatics/btp324

Li H, Handsaker B, Wysoker A, et al. The Sequence Alignment/Map format and SAMtools. *Bioinformatics*. 2009b;25(16):2078–2079. doi:10.1093/bioinformatics/btp352

Wang K, Li M, Hakonarson H. ANNOVAR: functional annotation of genetic variants from high-throughput sequencing data. *Nucleic Acids Res*. 2010;38(16):e164. doi:10.1093/nar/gkq603