

动植物变异检测常见售后 Q&A

中国区-售后服务部

1: 常规 SNP 的过滤标准是什么?

动植物常规过滤标准: $DP \geq 4$, $QUAL \geq 20$ 。若老师有减少 SNP/InDel 位点数量的需求, 可提高过滤标准, 例如将过滤标准提高至 $DP \geq 10$, $QUAL \geq 30$ 。

2: 什么是群 call? 什么是单 call? 有什么区别, 分别用于解决什么问题?

做群体样本的变异检测, 即群 call; 单 call 只能检测个体样本与参考基因组的差别。若客户原本做的单 call, 后续需做群 call 时, 需提供 bam 文件。

3: 群 call 和单 call 使用的软件是否有不同?

单 call: 检测 SNP 等使用 GATK/SAMTOOLS, 多使用 SAMTOOLS。

群 call: 使用 GATK/SAMTOOLS。

4: 基因注释常见数据库。

基因功能注释数据库有 NR、NT、K0、Swissprot、PFAM、GO、KOG 等, 动植物流程中没有以上基因功能注释信息, 因此均属于个性化注释内容。

除了以上数据库外, 对于某些模式物种可能有其专门的数据库, 如拟南芥的 TIAR 数据库 (<https://www.arabidopsis.org/>), 可根据客户需要进行相应数据库的注释。

5: 基于位点特征的进化树构图。

不计算序列间的距离, 而是将序列中有差异的位点作为单独的特征, 并根据这些特征来建树。

6: 基于距离矩阵的进化树构图。


先通过各个物种之间的比较, 根据一定的假设 (进化距离模型) 推导得出分类群之间的进化距离, 构建一个进化距离矩阵。进化树的构建则是基于这个矩阵中的进化距离关系。

7: 构建进化树具体方法及软件。

目前最常使用的是将所有样本进行群 call, 得到所有样本的总 vcf 文件, 再根据全部样本中所有的 SNP 位点信息构建矩阵, 最终根据矩阵来进行图片的绘制。

矩阵中展示出不同列样本间 SNP 的相同和差异信息, 具体构建进化树方法为 NJ 法。

8: 进化树图片解读。



水平方向上的分支代表进化谱系随着时间的变化，分支长度越长表示该分支对应物种的变化越大。

标尺下部的数字 0.07 指该长度的分支代表基因组的遗传变异度为 0.07。其中，遗传变异度通常表示基因组中每个位点碱基的替换频率，计算公式为：变异度=变异碱基数/总碱基数（%）。通常情况下会以百分比的方式展示，进而可解释为每 100 个碱基位点的变异度。

垂直方向：无特别含义

节点：彩色圆圈

进化树上的节点有外部节点和内部节点两种。外部节点又称为叶节点（上图中绿色圆圈），代表参与分析的基因组数据（例图中是病毒的基因组序列），一般情况下一个基因组即代表一个物种。内节点用蓝色的圆圈表示假定祖先。

进化树的根（红色圆圈）代表终极祖先的位置，基于这个点依据不同分支在水平方向上的长度可以对不同物种近似进化时间进行排序。例如：在上图中我们可以说 A 物种比 B 和 C 物种在进化时间上更早，同时也可以认为水平方向上进化时间从左到右依次增加。

分支：因为分支长度代表基因序列相似度，只能代表近似进化时间。因此，需要根

据基因序列相似度与进化时间假说对这种进化距离进行转换，即分子钟。

Bootstrap 值：图中每个节点左边的灰色数字代表该节点的 bootstrap 值。该值范围从 0-1，也可用百分比的形式代表，值越大该节点置信度越高。

以上说明可参考的链接：<https://www.jianshu.com/p/07f1ff1318e3>

9：动植物 WGS 结题报告中多个样本绘制在同一图片上的图片调整排列顺序。

绘制的图片包括 SNP 质量累积分布；SNP 突变频谱；编码区 InDel 长度分布；全基因组 InDel 长度分布。

10：更改 Upstream 和 Downstream 区域范围重新注释。

我们目前定义的 Upstream 和 Downstream 是基因上下游 1kb 区域，若客户想找到基因另外 1.5kb 区域的变异信息，可在 Intergenic（基因间区）的注释中进行查找（如下图）。

AnnoPos	Gene
intergenic	GeneID00001(dist=1013),GeneID00003(dist=124986)
exonic	GeneID00002
intronic	GeneID00004
upstream	GeneID00005
downstream	GeneID00006

注：如果客户要求修改统计区间范围重新分析，需要进行评估。

11：特异性引物设计。

可根据样本间共有/特有 snp、indel 位点设计引物，默认为老师提供变异位点前后各 200bp 的序列信息（upstream、downstream），从中设计引物，可根据老师需求增加该序列的长度。即扩增产物长度。

12：NT 比对评估。

	A	B	C	D
1	Species	fq1_number(per	fq2_number(per	total percentage
2	Heridium americanum isolate	18(0.0036)	13(0.0026)	0.0031
3	Tricholoma matsutake internal	8(0.0016)	19(0.0038)	0.0027
4	Auriscalpium vulgare isolate	12(0.0024)	12(0.0024)	0.0024
5	Heridium erinaceum voucher	12(0.0024)	10(0.0020)	0.0022
6	Donkioporia expansa 28S	9(0.0018)	13(0.0026)	0.0022
7	Trametes versicolor strain	11(0.0022)	11(0.0022)	0.0022

对过滤后的高质量数据随机抽取 10000 对 Pair Reads 数据，通过 Blast 软件（参数：-a3-e 1e-05）比对 NT 库，并将比对次数排名前十的物种展示出来，此部分内容为

建库测序的项目中的常规内容，可评估出样本的相似物种，建议查看排名前 10 的结果。

13: 动植物 WGS 项目，若进行了售后 KEGG 富集分析，其通路图中各节点颜色代表什么意思？


红色底框和蓝色底框代表您项目本物种富集到的节点信息，这是网页标注的一种表示方法；绿色底框是拟南芥物种特有的注释结果。对于植物，通常默认选择植物模式物种拟南芥为参考物种进行数据库的富集分析。在进行查看时，可以重点关注红色底和蓝色底的分析即可。另外，由于通路富集分析仅为数据库注释结果，各基因具体的功能信息，还需进一步验证确认。

14: snp 和 indel 密度分布热图中，图例中数字表示什么意思？

密度值表示每 0.1MB 的突变频率，含 E 数值为科学计数法数值，对于较大或较小数值表示更精确和方便，详情可参考：

<http://www.chusan.com/zhongkao/66138.html>。

以 100kb 为窗口，统计每个窗口上的 snp/indel 密度。可根据客户需要调整窗口的大小以及染色体间的是否存在间隙。



15: 动植物 Breakdancer 检测 SV 变异的说明。

网站说明: <https://github.com/kenchen/breakdancer#readme>

16: 什么是样本 compare 分析（动植物）？

重测序获得的 150bp 的片段，无法直接利用这些序列进行比较。若需要对重测序样本之间进行互相比对，则是把标准参考基因组做桥梁，比对到参考基因组上之后，再基于 SNP/indel 位点结果互相比对，从而最精确地体现两个样本中碱基和频率的差异。若

有需要，可联系售后组安排该分析。

17: 样本 compare 结果说明。

compare 最终提供给客户的 excel 表格注释信息如下图所示。

Compare 结果:	
第一列: Chromosome	SNP 所在染色体 Chromosome
第二列: Position	SNP 所在染色体的位置 Position
第三列: Ref	参考基因组的基因型 Ref
第四列: Anno_Pos	SNP 注释的位置 Anno_Pos
第五列: Anno_Gene	SNP 注释到的基因 Anno_Gene
第六列: *.Genotype	样品的基因型 Genotype
第七列: Ref_depth/Alt_depth	参考深度/变异深度
第八列: Quality	深度质量值 Quality
此后是下一个样品的信息	

样本间 compare 分析内容为 snp 和 indel，不涉及 cnv 和 sv。重测序的 compare 分析是通过将样本分别和参考基因组比对得到样本间的变异检测结果。若需进行分组 compare，需要提供分组信息。

18: compare 结果中，InDel 表格里没有 exonic 区域的 InDel 结果？



在 compare 结果文件中，外显子区的 InDel 结果，显示为这种变异类型，非外显子区的 InDel 则显示为内含子、基因间区等变异位点信息。

19: compare 表格中是否可添加 0/1 或者 1/1 基因型？

可以根据样本基因型添加 0/1 或者 1/1，该基因型可在 vcf 文件中进行提取。

20: compare 结果的过滤标准。

10X 以上的测序深度时，深度>=4，质量值>=20。测序深度在 5X 左右的，深度>=2，

质量值 ≥ 20 的要求进行过滤；两个样本的基因型完全相同时会被过滤。此部分在交付的 readme 文档中也会进行说明。（以两个样本进行 compare 为例）

21：动植物单个变异检测的 vcf 文件直接合并进行后续分析可能会出现哪些异常。

理论上来说，如果客户后续想要进行群体的分析，我们建议客户直接从 bam 文件进行群 call 分析。

对于直接合并单个变异检测的 vcf 文件结果来说，由于 filter.snp.vcf 中没有 0/0 的情况列出，所以会将 0/0 写成缺失 ./., 这样合并后会导致缺失的位点异常偏多，一旦进行后续过滤会丢失掉大部分位点。对于这类问题，可使用中间文件 all.vcf 进行合并分析，该文件 0/0 位点有所保留，会改善以上异常情况。

22：动植物流程中，circos 图中展示的 SV 较少，和 SV 变异检测结果检测到的数目不符的原因。

在进行 circos 图可视化展示时进行了过滤，变异检测分值 score 小于 50，支持 reads 小于 30 的位点均被过滤不展示，过滤标准可以修改。

23：注释结果文件中：AF1 列的结果为 0.5 和 1，分别是什么意思？

AF (Allele Frequency) 表示 Allele 的频率，AF1 为第一个 ALT allele 发生频率的可能性评估。以单个样本来说，发生 0/1 杂合突变值为 0.5，1/1 纯合突变值为 1，如果只是将所有单个合并展示，通常显示第一个样本的值，可以不关注。

若是进行的群 call 分析，则该值会考虑到群体样本在该位点的纯合和杂合变异情况，数值将会出现多个。