

EM-seq 常见 Q&A

Q1: 影响 mapping 率的因素有哪些？一般 mapping 率要求高于多少？为什么同一样品的 EM-seq 项目 mapping 率要低于转录组 mapping 率？

A1: 首先，结题报告中的 mapping 率是 uniq mapping 率（双端比对），不包含多重比对的 reads 和单端比对的 reads，并且在默认参数下 bismark 软件比对相对较为严格，得到的结果具有较高的精确性。其次，酶处理 DNA 在比对过程中需要对 reads 进行转换，引起较低的熵值，对 mapping 率有一定的影响。最后，影响 mapping 率还有其它因素，例如参考基因组拼的程度、基因组重复序列的含量、参考基因组与样品亲缘的远近、样本的杂合性、以及样品的不同处理，样本污染等因素。对于甲基化项目，更看重用于分析的数据的覆盖度和深度，如果数据量足够，样本之间覆盖度差别较小的情况下，可以保证 mC 位点的检出和样本间差异分析的可信度。由于 EM-seq 是基于 DNA 水平的比对，转录组是基于 RNA 水平的比对，二者的比对软件也是有差别的：RNA 的使用比对软件需要考虑到剪切比对条件也更为宽松，所以会比甲基化 mapping 率高一些。

Q2: 甲基化密度是如何计算的？

A2: 甲基化密度的定义计算类型有多种，在此使用相对密度的计算方式：某区域内甲基化 C 的个数除以该区域 5X 以上 reads 覆盖的 C（用于鉴定甲基化的基数）的个数。

Q3: 甲基化水平是如何计算的？

A3: 甲基化水平定义计算方式有多种，我们采用 Schultz et al., 2012 文章中 Weighted methylation level，计算方法为：支持某位点（区域）甲基化 C 的 reads 条数除以覆盖该位点（区域）的总的 reads 条

数，即为某位点（区域）甲基化水平，计算公式为 $ML = mC / (mC + umC)$ 。例如：位点 A 覆盖的 reads 数为 10，支持 mC 的 reads 数为 2，不支持 mC 的 reads 数为 8，该位点的甲基化水平为 $2 / (2 + 8) = 0.2$ 。

Q4: mC calling 是什么过程，为什么要进行 mC calling?

A4: mC calling 也就是甲基化位点的鉴定。一般情况下，Bisulfite 处理的转化效率能达到 99%，但未发生甲基化的 C 位点不能全部被转化，某一位点是否为真实的 mC 位点是符合二项分布的，因此我们使用二项分布检验 $B(n, p)$ 来鉴定该位点是否为真正的甲基化位点。假设某一位点的甲基化的 C 的数量为 x ，该位点 read 覆盖度为 n ，甲基化非转化率为 p (Bisulfite non-conversion rate)，则需要验证在概率为 p 、测序深度为 n 的条件下，出现 x 个甲基化 C 的情况是否可靠。甲基化位点鉴定条件： $q\text{-value} < 0.01$ 且 $\text{read coverage} \geq 5$ 。