

生物信息分析流程

目录

原始下机数据处理.....	2
样品组装.....	2
基因组组分分析.....	2
编码基因.....	2
重复序列.....	2
非编码RNA.....	3
基因岛.....	3
转座子.....	3
前噬菌体.....	3
CRISPR.....	3
基因功能分析.....	3
基因功能注释.....	4
效应子.....	4
分泌蛋白预测.....	4
分泌系统蛋白及T3SS 效应蛋白预测.....	4
次级代谢基因簇分析.....	4
毒力或致病性分析.....	4
比较基因组分析.....	5
全基因组共线性分析.....	5
SNP 分析.....	5
InDel 分析.....	5
SV 分析.....	5
群体进化分析.....	5
共有和特有基因分析.....	5
基因家族分析.....	5
物种进化分析.....	6

原始下机数据处理

测序得到的原始数据(Raw Data)会存在一定比例的低质量数据, 为了保证后续信息分析结果的准确可靠, 首先要对原始数据进行过滤处理, 得到有效数据(Clean Data)。结果见“01.Cleandata.tar.gz 或 01.Cleandata”。

具体处理步骤如下:

- 1) 去除所含低质量碱基 (质量值 ≤ 20) 超过一定比例 (默认设为 40%) 的 reads;
- 2) 去除 N 碱基达到一定比例的 reads (默认设为 10%);
- 3) 去除与 Adapter 之间 overlap 超过一定阈值 (默认设为 15bp), 且错配数小于 3 的 reads;
- 4) 对于小基因组等项目, 如果样品存在宿主污染, 需与宿主数据库进行比对, 过滤掉可能来源于宿主的 reads。

样品组装

从各样品质控后的 Clean Data 出发, 进行基因组组装, 得到能反映样品基因组基本情况的序列文件, 并对组装结果进行评价。结果见“02.Assembly.tar.gz 或 02.Assembly”。

基因组组装的具体处理步骤如下:

- 1) 经过预处理后得到 Clean Data, 使用 SOAP denovo 组装软件进行组装:
选取不同的 K-mer (默认选取 95、107、119) 进行组装, 根据项目类型选择最优的 kmer, 选取最少 scaffold 的组装结果; 利用最优 kmer 并调节其他参数 (-d -u -R -F 等) 再次筛选得到初步组装结果;
- 2) 使用 SPAdes 软件进行组装:
选取不同的 K-mer (默认选取 99 和 127) 进行组装, 根据项目类型选择最优的 kmer, 选取最少 scaffold 的组装结果;
- 3) 使用 Abyss 软件进行组装:
选取 K-mer 64 进行组装, 获得组装结果;
- 4) 使用 CISA 软件整合三个软件的组装结果, 并挑选其中最少数 scaffold 的组装结果;
- 5) 采用 gapclose 软件对初步组装结果进行补洞, 并且通过过滤低测序深度 (小于平均深度的 0.35) 的 reads 去除同 lane 污染, 从而得到最终的组装结果;
- 6) 过滤掉 500bp 以下的片段, 并进行评估和统计分析以及后续基因预测。

基因组组分析

编码基因

从各样品最终的组装结果 (≥ 500 bp) 出发, 采用对应的软件进行 ORF (Open Reading Frame) 预测及过滤。结果见“03.Genome_Component.tar.gz 或 03.Genome_Component 中 Gene”。

对于细菌、古菌等样本采用 GeneMarkS 软件 (verison 4.17) (<http://topaz.gatech.edu/>) 进行编码基因预测及过滤。

重复序列

根据重复的序列在基因组上的分布, 分为两大类: 散在重复序列、串联重复序列。散在重复序列是与串联重复序列的组织形式不同的另一类重复序列, 是散在方式分布于基因组内的散在重复序列。串联重复序列 (Tandem Repeat, TR), 即相邻的、重复两次或多次特定核酸序列模式的重复序列。结果见“03.Genome_Component.tar.gz 或 03.Genome_Component 中 Repeat”。

通过 RepeatMasker 软件 (verison 4.0.5) 进行散在重复序列预测, TRF (Tandem repeats finder, verison 4.07b) 搜寻 DNA 序列中的串联重复序列。

非编码RNA

非编码RNA (ncRNA) 是一类广泛存在于小基因组、细菌、古生菌和真核生物生物体内, 执行多种生物学功能的RNA 分子, 其本身并不携带翻译为蛋白质的信息, 直接在RNA 水平对生命活动发挥作用。对于微生物而言, 非编码 RNA 的主要类型包括sRNA、rRNA、tRNA、snRNA、snoRNA 及 miRNA 等等。结果见“03.Genome_Component.tar.gz 或 03.Genome_Component 中 ncRNA”。

常见类型 ncRNA 预测方法如下:

- 1) tRNA: 通过 tRNAscan-SE 软件可预测tRNA 区域和tRNA 的二级结构。
- 2) rRNA: 通过比对 rRNA 库查找与数据库近缘的 rRNA (identity 默认 $\geq 50\%$), 并利用 rRNAmmer 软件预测新出现及未被注释的rRNAs, 综合二者结果。
- 3) sRNA: 首先用Rfam 软件进行Rfam database 比对注释, 接着用cmsearch 程序 (version 1.1rc4) 确定最终的sRNA。

基因岛

基因岛 (Genomics Islands, GIs) 是一些细菌、噬菌体或质粒中有横向起源迹象的一部分基因组。基因岛大小通常从 10 到 500 Kbp, 其 GC 含量和密码子选择与基因组的其余部分不同。基因岛的许多亚分类基于它们所表现出来的功能, 如病原性基因岛 (Pathogenicity islands, PAIs) 其上包含有毒力基因, 与致病机理相关, 抗生素抗性基因岛包含有许多抗生素抗性基因。结果见 “03.Genome_Component.tar.gz 或 03.Genome_Component 中 Genomic_Island”。

采用 IslandPath-DIOMB 软件预测基因岛, 其通过检测序列中二核苷酸偏向性 (phylogenetically bias) 和移动性基因 (mobility genes, 如转座酶或整合酶) 以判定基因岛以及潜在的水平基因转移。

转座子

转座子(transposon,简称 Tn),又称易位子,是存在于染色体 DNA 上可以自主复制和移位的基本单位。DNA 的转座,或称移位 (transposition),是由可移位因子(transposable elements)介导的遗传物质重排现象,与同源重组相比,转座发生的频率要低得多。转座子可以在不同复制子之间转移,以非正常重组方式从一个位点插入到另外一个位点,对新位点基因的结构与表达产生多种遗传效应。

采用 TransposonPSI 软件对转座子进行预测。其通过 PSI-Blast 同源比对来对基因组或者蛋白序列进行查找可能的转座子序列。结果见 “03.Genome_Component.tar.gz 或 03.Genome_Component 中 Transposon”。

前噬菌体

整合在宿主基因组上的温和噬菌体的核酸称之为前噬菌体。前噬菌体预测是使用 phiSpy 工具 (Nov11_v2.3), 这是一个预测精度和准确性都很高的工具, 支持 GenBank 格式格式文件, 结果见“03.Genome_Component.tar.gz 或 03.Genome_Component 中 Prophage”。

CRISPR

CRISPR (Clustered Regularly Interspaced Short Palindromic Repeat Sequences, 成簇的、规律间隔的短回文重复序列) 是在 40%已测序的细菌和 90%已测序的古细菌中都有报道过的、含有一个与噬菌体和质粒同源的短的重复序列, 通过对外来同源的 DNA 作用对噬菌体有抗性, 影响质粒的连接, 是原核生物的免疫系统一部分。

采用 CRISPRdigger 工具对样品基因组进行 CRISPR 预测, CRISPRdigger 准确性高并能预测其中的短回文重复结构。结果见 “03.Genome_Component.tar.gz 或 03.Genome_Component 中 CRISPR”。

基因功能分析

基因功能注释

目前提供注释的通用功能数据库主要有 GO (Gene Ontology, <http://geneontology.org/>)、KEGG (Kyoto Encyclopedia of Genes and Genomes, <http://www.genome.jp/kegg/>)、COG (Cluster of Orthologous Groups of proteins, <http://www.ncbi.nlm.nih.gov/COG/>)、KOG、eggNOG (evolutionary genealogy of genes: Non-supervised Orthologous Groups)、NR (Non-Redundant Protein Database)、TCDB (Transporter Classification Database)、Swiss-Prot (<http://www.ebi.ac.uk/uniprot/>)、CAZy (Carbohydrate-Active enZymes Database) 等。结果见“04.Genome_Function.tar.gz 或 Genome_Function 中 General_Gene_Annotation 内各数据库”。

功能注释基本步骤如下：

- 1) 将预测基因与各功能数据库进行 BLAST 比对 (blastp, $\text{evaluate} \leq 1e-5$) ;
- 2) BLAST 结果过滤：对于每一条序列的 BLAST 结果，选取 score 最高的比对结果 (默认 $\text{identity} \geq 40\%$, $\text{coverage} \geq 40\%$) 进行注释。

效应子

分泌蛋白预测

分泌蛋白是指在细胞内合成后，在信号肽的引导下穿过细胞膜分泌到细胞外起作用的蛋白质。分泌蛋白中有许多是生命活动所需的重要酶类。分泌蛋白的 N 端是由 15~30 个氨基酸组成的信号肽，对分泌蛋白的分泌起主导作用。

使用信号肽预测工具 SignalP 进行预测，检测是否含有信号肽及跨膜结果，综合预测蛋白质序列是否是分泌蛋白。结果见“04.Genome_Function.tar.gz 或 04.Genome_Function/*/Effector/Secretory_Protein”。

分泌系统蛋白及 T3SS 效应蛋白预测

病原菌通过分泌系统 TNSS (type N secretion systems, 目前确定的有 7 种, I 型-VII 型) 将该类蛋白分泌至胞外或是宿主细胞中，通过控制免疫应答反应以及细胞衰亡引起病理反应，而其中革兰氏阴性菌的 T3SS 通常用来从分子水平研究病原菌，感染机制，毒力作用等，是研究得比较多的分泌系统。

对于 TNSS 系统，通过蛋白序列功能数据库注释结果中，提取分泌系统相关蛋白进行注释。结果见“04.Genome_Function.tar.gz 或 04.Genome_Function/*/Effector/TnSS”。

对于革兰氏阴性菌，另外采用 EffectiveT3 软件预测 T3SS 效应蛋白。结果见“04.Genome_Function.tar.gz 或 04.Genome_Function/*/Effector/T3SS”。

次级代谢基因簇分析

次级代谢产物是微生物在一定的生长时期，以初级代谢产物为前体合成的对微生物的生命活动无明确功能，并非生长繁殖所必需的物质。采用 antiSMASH 程序 (version 2.0.2) 对基因组进行预测。

结果见“04.Genome_Function.tar.gz 或 04.Genome_Function/*/Effector/Secondary_Metabolism”。

毒力或致病性分析

对于细菌，目前提供注释的病原细菌致病性和耐药性数据库主要有 PHI (Pathogen Host Interactions Database)、VFDB (Virulence Factors of Pathogenic Bacteria)、ARDB (Antibiotic Resistance Genes Database)、CARD (Comprehensive Antibiotic Research Database)。结果见“04.Genome_Function.tar.gz 或 04.Genome_Function 中 Pathogenicity 内各数据库”。

比较基因组分析

全基因组共线性分析

共线性指的是遗传学中的基因连锁关系，是不同物种基因组上同源基因以相同顺序排列的现象。两个物种之间的共线性程度可以作为衡量他们之间进化距离的尺度，可以知道物种间的亲缘关系。结果见“05.Comparative_Genomics.tar.gz 或 05.Comparative_Genomics 中 Synteny”。

SNP 分析

SNP（单核苷酸多态性，single nucleotide polymorphism）主要是指在基因组水平上由单个核苷酸的变异所引起的DNA 序列多态性，包括单个碱基的转换、颠换等。

采用MUMmer（version 3.22）比对软件进行个体SNP 的检测，依照SNP 和基因之间的位置关系及相互作用，对 SNP 功能进行注释。结果见“05.Comparative_Genomics.tar.gz 或 05.Comparative_Genomics 中 SNP”。

InDel 分析

InDel 是指基因组中小片段的插入和缺失序列。利用 LASTZ 软件检测长度小于 50bp 的小片段插入与缺失（InDel），结果见“05.Comparative_Genomics.tar.gz 或 05.Comparative_Genomics 中 InDel”。

SV 分析

结构性变异（Structural Variation, SV）指基因组水平上大片段的插入、缺失、倒置、易位等序列。

使用 MUMmer（version 3.22）进行两个基因组的快速比对，确定序列的相对方向，并对基因组进行调整，对齐基因组起点。运用 Lastz（version 1.02.00）软件进行全基因组比对。使用 chainNet 等软件包将比较零散的比对结果连接成更长的比对结果（如 chain、net 等形式）。根据新的比对块顺序排列关系和相对方向，查找出属于易位（Translocation）、倒置（Inversion）和易位兼倒置（Trans+Inver）关系的比对块，再根据两个基因组上相邻比对块之间的距离关系确定比对块间的SV 区域。

结果见“05.Comparative_Genomics.tar.gz 或 05.Comparative_Genomics 中 SV”。

群体进化分析

共有和特有基因分析

所有样本中均存在的同源基因称为共有基因（Core gene），除去共有基因，其他的基因称为非共有基因（Dispensable gene），特有基因（Specific gene）是只有在某个样品中所特异的基因。所有非共有基因与共有基因合并作为泛基因集（Pan gene）。其中共有基因（Core gene）和特有基因（Specific gene）很可能与样品的共性和特性相对应，可以作为样本间功能差异的研究依据。结果见“05.Comparative_Genomics.tar.gz 或 05.Comparative_Genomics 中 Core-Pan”。

基因家族分析

基因组进化中，一个基因通过基因重复产生了两个或更多的拷贝，这些基因即构成一个基因家族。基因家族是具有共同祖先的一组基因，家族内不同基因往往具有相似的结构和功能。由于基因家族是随着物种分化而形成的，研究基因家族进化能揭示基因演化历史，基因功能和物种分化，为预测未知基因功能和研究基因进化历史 提供依据和线索。

使用BLAST 软件对多个目标基因组的蛋白进行两两比对，过滤比对不可信的结果，再使用 Solar 去除冗余，用Hcluster-sg 按照比对相似度对蛋白进行聚类，得到基因家族聚类结果。

结果见“05.Comparative_Genomics.tar.gz 或05.Comparative_Genomics 中 Gene_Family”。

物种进化分析

系统发生树（phylogenetic tree 或 evolutionary tree）是表明被认为具有共同祖先的各物种相互间演化关系的树，又被译作系统发育树、系统演化树、系统进化树、种系发生树、演化树、进化树、系统树。它用来表示系统发生研究的结果，用它描述物种之间的进化关系。

采用 NJ 法构建了系统发生树，结果见“05.Comparative_Genomics.tar.gz 或 05. Comparative_Genomics 中 Phylogenetic_Tree”。

