

生物信息分析流程

目录

原始下机数据处理	2
样品组装	2
基因组组分析	2
编码基因	2
重复序列	2
非编码RNA	2
基因功能分析	3
基因功能注释	3
效应子	3
分泌蛋白预测	3
细胞色素 P450 数据库注释	3
次级代谢基因簇分析	3
致病性分析	4
比较基因组分析	4
全基因组共线性分析	4
SNP 分析	4
InDel 分析	4
SV 分析	4
群体进化分析	4
共有和特有基因分析	4
基因家族分析	4
物种进化分析	5

原始下机数据处理

三代数据：

第三代测序仪 PacBio，采用单分子测序技术，拥有超长的读长优势，对于完整基因组的组装性有重要作用。原始下机数据以 bam 格式文件保存，其中包含了测序序列，碱基质量值等信息。通过对下机数据统计，得到数据总量，reads 读长，质量值分布等信息。

二代数据：

测序得到的原始数据(Raw Data)会存在一定比例的低质量数据，为了保证后续信息分析结果的准确可靠，首先要对原始数据进行过滤处理，得到有效数据(Clean Data)。具体处理步骤如下：

- 1) 去除所含低质量碱基（质量值 ≤ 38 ）超过一定比例（默认设为 40bp）的 reads；
- 2) 去除 N 碱基达到一定比例的 reads（默认设为 10bp）；
- 3) 去除与 Adapter 之间 overlap 超过一定阈值（默认设为 15bp）的 reads；
- 4) 对于小基因组等项目，如果样品存在宿主污染，需与宿主数据库进行比对，过滤掉可能来源于宿主的 reads。

样品组装

使用 Falcon 软件(<https://github.com/PacificBiosciences/FALCON/>)对三代 reads 进行基因组组装，得到能反映样品基因组基本情况的初步的组装结果，然后使用 Racon（version: 1.4.13）软件基于三代测序数据对拼接结果进行三轮纠错后，再进行三轮二代 reads 的 Pilon（version: 1.22）纠错，得到最终的组装结果。

基因组组分分析

编码基因

从各样品最终的组装结果（ $\geq 500\text{bp}$ ）出发，采用对应的软件进行 ORF (Open Reading Frame) 预测及过滤。结果见“03.Genome_Component.tar.gz 或 03.Genome_Component 中 Gene”。

对于真菌样本基因预测的方法如下：（1）若提供转录组数据，进行基于转录组数据 Transdecoder/Glimmer/Snap 的从头 PASA 预测、基于转录组数据的 Cufflinks 预测、从头 Augustu（sversion 2.7）预测和以近缘序列（若有提供）做参考的同源 Genewise（version 2.4.1）预测，然后将多种方法的结果进行 EVM 整合和 PASA 第二轮验证。（2）若未提供转录组数据，但提供近缘参考序列，则进行同源 Genewise 预测。（3）若未提供转录组数据和近缘参考序列，则进行从头 Augustus 预测。

重复序列

根据重复的序列在基因组上的分布，分为两大类：散在重复序列、串联重复序列。散在重复序列是与串联重复序列的组织形式不同的另一类重复序列，是散在方式分布于基因组内的散在重复序列。串联重复序列（Tandem Repeat, TR），即相邻的、重复两次或多次特定核酸序列模式的重复序列。结果见“03.Genome_Component.tar.gz 或 03.Genome_Component 中 Repeat”。

通过 RepeatMasker 软件（version 4.0.5）进行散在重复序列预测，TRF（Tandem repeats finder, version 4.07b）搜寻 DNA 序列中的串联重复序列。

非编码 RNA

非编码RNA (ncRNA) 是一类广泛存在于小基因组、细菌、古生菌和真核生物体内, 执行多种生物学功能的RNA 分子, 其本身并不携带翻译为蛋白质的信息, 直接在RNA 水平对生命活动发挥作用。对于微生物而言, 非编码 RNA 的主要类型包括sRNA、rRNA、tRNA、snRNA、snoRNA 及 miRNA 等等。结果见“03.Genome_Component.tar.gz 或 03.Genome_Component 中 ncRNA”。

常见类型 ncRNA 预测方法如下:

- 1) tRNA: 通过tRNAscan-SE 软件可预测tRNA 区域和tRNA 的二级结构。
- 2) rRNA: 通过比对 rRNA 库查找与数据库近缘的 rRNA (identity 默认 $\geq 50\%$), 并利用 rRNAmmer 软件预测新出现及未被注释的rRNAs, 综合二者结果。
- 3) sRNA: 首先用Rfam 软件进行Rfam database 比对注释, 接着用cmsearch 程序 (version 1.1rc4) 确定最终的sRNA。

基因功能分析

基因功能注释

目前提供注释的通用功能数据库主要有 GO (Gene Ontology, <http://geneontology.org/>)、KEGG (Kyoto Encyclopedia of Genes and Genomes, <http://www.genome.jp/kegg/>)、COG (Cluster of Orthologous Groups of proteins, <http://www.ncbi.nlm.nih.gov/COG/>)、KOG、eggNOG (evolutionary genealogy of genes: Non-supervised Orthologous Groups)、NR (Non-Redundant Protein Database)、TCDB (Transporter Classification Database)、Swiss-Prot (<http://www.ebi.ac.uk/uniprot/>)、CAZy (Carbohydrate-Active enZymes Database) 等。结果见“04.Genome_Function.tar.gz 或 04.Genome_Function 中 General_Gene_Annotation 内各数据库”。

功能注释基本步骤如下:

- 1) 将预测基因与各功能数据库进行 BLAST 比对 (blastp, $\text{evalue} \leq 1e-5$);
- 2) BLAST 结果过滤: 对于每一条序列的 BLAST 结果, 选取 score 最高的比对结果 (默认 $\text{identity} \geq 40\%$, $\text{coverage} \geq 40\%$) 进行注释。

效应子

分泌蛋白预测

分泌蛋白是指在细胞内合成后, 在信号肽的引导下穿过细胞膜分泌到细胞外起作用的蛋白质。分泌蛋白中有许多是生命活动所需的重要酶类。分泌蛋白的N 端是由15~30 个氨基酸组成的信号肽, 对分泌蛋白的分泌起主导作用。

使用信号肽预测工具 SignalP 进行预测, 检测是否含有信号肽及跨膜结果, 综合预测蛋白序列是否是分泌蛋白。结果见“04.Genome_Function.tar.gz 或 04.Genome_Function/*/Effector/Secretory_Protein”。

细胞色素 P450 数据库注释

细胞色素 P450 (cytochrome P450 或 CYP450, 简称 CYP450) 为一类亚铁血红素—硫醇盐蛋白的超家族, 它参与内源性物质和包括药物、环境化合物在内的外源性物质的代谢。

结果见“04.Genome_Function.tar.gz 或 04.Genome_Function/*/Effector/P450”。

次级代谢基因簇分析

次级代谢产物是微生物在一定的生长时期, 以初级代谢产物为前体合成的对微生物的生命活动无明确功能, 并非生长繁殖所必需的物质。采用 antiSMASH 程序 (version 2.0.2) 对基因组进行预测。

结果见“04.Genome_Function.tar.gz 或

04.Genome_Function/*/Effector/Secondary_Metabolism”。

致病性分析

对于真菌，目前提供注释的病原细菌致病性和耐药性数据库主要有 PHI (Pathogen Host Interactions Database)、DFVF (database of fungal virulence)。结果见“04.Genome_Function.tar.gz 或 04.Genome_Function 中 Pathogenicity 内各数据库”。

比较基因组分析

全基因组共线性分析

共线性指的是遗传学中的基因连锁关系，是不同物种基因组上同源基因以相同顺序排列的现象。两个物种之间的共线性程度可以作为衡量他们之间进化距离的尺度，可以知道物种间的亲缘关系。结果见“05.Comparative_Genomics.tar.gz 或 05.Comparative_Genomics 中 Synteny”。

SNP 分析

SNP (单核苷酸多态性, single nucleotide polymorphism) 主要是指在基因组水平上由单个核苷酸的变异所引起的 DNA 序列多态性，包括单个碱基的转换、颠换等。

采用 MUMmer (version 3.22) 比对软件进行个体 SNP 的检测，依照 SNP 和基因之间的位置关系及相互作用，对 SNP 功能进行注释。结果见“05.Comparative_Genomics.tar.gz 或 05.Comparative_Genomics 中 SNP”。

InDel 分析

InDel 是指基因组中小片段的插入和缺失序列。利用 LASTZ 软件检测长度小于 50bp 的小片段插入与缺失 (InDel)，结果见“05.Comparative_Genomics.tar.gz 或 05.Comparative_Genomics 中 InDel”。

SV 分析

结构性变异 (Structural Variation, SV) 指基因组水平上大片段的插入、缺失、倒置、易位等序列。

使用 MUMmer (version 3.22) 进行两个基因组的快速比对，确定序列的相对方向，并对基因组进行调整，对齐基因组起点。运用 Lastz (version 1.02.00) 软件进行全基因组比对。使用 chainNet 等软件包将比较零散的比对结果连接成更长的比对结果 (如 chain、net 等形式)。根据新的比对块顺序排列关系和相对方向，查找出属于易位 (Translocation)、倒置 (Inversion) 和易位兼倒置 (Trans+Inver) 关系的比对块，再根据两个基因组上相邻比对块之间的距离关系确定比对块间的 SV 区域。

结果见“05.Comparative_Genomics.tar.gz 或 05.Comparative_Genomics 中 SV”。

群体进化分析

共有和特有基因分析

所有样本中均存在的同源基因称为共有基因 (Core gene)，除去共有基因，其他的基因称为非共有基因 (Dispensable gene)，特有基因 (Specific gene) 是只有在某个样品中所特异拥有的基因。所有非共有基因与共有基因合并作为泛基因集 (Pan gene)。其中共有基因 (Core gene) 和特有基因 (Specific gene) 很可能与样品的共性和特性相对应，可以作为样本间功能差异的研究依据。结果见“05.Comparative_Genomics.tar.gz 或 05.Comparative_Genomics 中 Core-Pan”。

基因家族分析

基因组进化中，一个基因通过基因重复产生了两个或更多的拷贝，这些基因即构成一个基因家族。基因家族是具有共同祖先的一组基因，家族内不同基因往往具有相似的结构和功能。由于基因家族是随着物种分化而形成的，研究基因家族进化能揭示基因演化历史，基因功能和物种分化，为预测未知基因功能和研究基因进化历史提供依据和线索。

使用BLAST 软件对多个目标基因组的蛋白进行两两比对，过滤比对不可信的结果，再使用Solar 去除冗余，用Hcluster-sg 按照比对相似度对蛋白进行聚类，得到基因家族聚类结果。

结果见“05.Comparative_Genomics.tar.gz 或05.Comparative_Genomics 中 Gene_Family”。

物种进化分析

系统发生树（phylogenetic tree 或evolutionary tree）是表明被认为具有共同祖先的各物种相互间演化关系的树，又被译作系统发育树、系统演化树、系统进化树、种系发生树、演化树、进化树、系统树。它用来表示系统发生研究的结果，用它描述物种之间的进化关系。

采用 NJ 法构建了系统发生树，结果见“05.Comparative_Genomics.tar.gz 或05.Comparative_Genomics 中 Phylogenetic_Tree”。

