

生物信息分析流程

目录

生物信息分析流程	1
目录	1
原始下机数据处理	2
样品组装	2
基因组组分分析	2
编码基因	2
重复序列	2
非编码 RNA	3
基因功能分析	3
基因功能注释	3
效应子	3
致病性分析	4
比较基因组分析	4
全基因组共线性分析	4
SNP 分析	4
InDei 分析	4
SV 分析	4
群体进化分析	4
共有和特有基因分析	4
基因家族分析	5
物种进化分析	5
基因组可视化分析	5
ONT barcode 与接头序列信息	5

原始下机数据处理

三代数据：

第三代测序仪 Nanopore, 采用单分子测序技术, 拥有超长的读长优势, 对于完整基因组的组装性有重要作用。原始下机数据以 fast5 格式文件保存, 其中包含了测序序列, 碱基质量值等信息。通过对原始下机数据质控, 去除低质量 ($Q < 7$) 的序列后, 得到可用于分析的 Cleandata。对 cleandata 进行统计, 得到数据总量, reads 读长, 质量值分布等信息。

二代数据：

测序得到的原始数据 (RawData) 会存在一定比例的低质量数据, 为了保证后续信息分析结果的准确可靠, 首先要对原始数据进行过滤处理, 得到有效数据 (CleanData)。具体处理步骤如下：

- 1) 去除所含低质量碱基 (质量值 W38) 超过一定比例 (默认设为 40bp) 的 reads;
- 2) 去除 N 碱基达到一定比例的 reads (默认设为 10bp);
- 3) 去除与 Adapter 之间 overlap 超过一定阈值 (默认设为 15bp) 的 reads;
- 4) 对于小基因组等项目, 如果样品存在宿主污染, 需与宿主数据库进行比对, 过滤掉可能来源于宿主的 reads。

样品组装

使用 Unicycler (<https://github.com/rrwick/Unicycler>, v0. 4. 8 软件结合二代数据与三代数据进行组装, 得到组装结果, 根据序列长度及组装结果区分组装的序列为染色体序列还是质粒序列, 并检验序列是否成环。

- (1) 初步组装: 首先使用 SPAdes 将二代数据组装出一个框架图;
- (2) 创建桥接: 然后使用 miniasm 和 Racon 将三代数据加到框架图上, 使用三代的长读长数据创建桥接;
- (3) 桥接应用: 出现冲突时, Unicycler 根据创建的桥接对应的质量分数选择高分桥接;
- (4) 成环判断和最终确认: 1. cotig 两端是否已经有 overlap; 2. 默认 dnaA 或 repA, 通过 start_genes 进行起始位点矫正和最终确认, 筛分染色体与质粒序列, 并将染色体序列组装成为一个环状基因组 (如果是线性基因组即为线性基因组序列), 即最终的 Ogap 完成图序列。

基因组组分析

编码基因

从各样品最终的组装结果 ($\geq 500\text{bp}$) 出发, 采用对应的软件进行 ORF (Open Reading Frame) 预测及过滤。结果见“03.Genome_Component.tar.gz 或 03.Genome_Component 中 Gene”。

对于真菌样本基因预测的方法如下: (1) 若提供转录组数据, 进行基于转录组数据 Transdecoder/Glimmer/Snap 的从头 PASA 预测、基于转录组数据的 Cufflinks 预测、从头 Augustu (sversion2.7) 预测和以近缘序列 (若有提供) 做参考的同源 Genewise (version2.4.1) 预测, 然后将多种方法的结果进行 EVM 整合和 PASA 第二轮验证。(2) 若未提供转录组数据, 但提供近缘参考序列, 则进行同源 Genewise 预测。(3) 若未提供转录组数据和近缘参考序列, 则进行从头 Augustus 预测。

重复序列

根据重复的序列在基因组上的分布, 分为两大类: 散在重复序列、串联重复序列。散在重复序列是与串联重复序列的组织形式不同的另一类重复序列, 是散在方式分布于基因组内的散在重复序列。串联重复序列 (Tandem Repeat, TR), 即相邻的、重复两次或多次特定核酸序列模式的重复序列。结果见“03.Genome_Component.tar.gz 或

03.Genome_Component 中 Repeat”。

通过 RepeatMasker 软件 (version 4.0.5) 进行散在重复序列预测, TRF (Tandem repeats

finder, version 4.07b) 搜寻 DNA 序列中的串联重复序列。

非编码 RNA

非编码 RNA (ncRNA) 是一类广泛存在于小基因组、细菌、古生菌和真核生物生物体内, 执行多种生物学功能的 RNA 分子, 其本身并不携带翻译为蛋白质的信息, 直接在 RNA 水平对生命活动发挥作用。对于微生物而言, 非编码 RNA 的主要类型包括 sRNA、rRNA、tRNA、snRNA、snoRNA 及 miRNA 等等。结果见“03.Genome_Component.tar.gz 或 03.Genome_Component 中 ncRNA”。

常见类型 ncRNA 预测方法如下:

- 1) tRNA: 通过 tRNAscan-SE 软件可预测 tRNA 区域和 tRNA 的二级结构。
- 2) rRNA: 通过比对 rRNA 库查找与数据库近缘的 rRNA(identity 默认 $\geq 50\%$), 并利用 rRNAmmer 软件预测新出现及未被注释的 rRNAs, 综合二者结果。
- 3) sRNA: 首先用 Rfam 软件进行 Rfam database 比对注释, 接着用 cmsearch 程序(version 1.1rc4) 确定最终的 sRNA。

基因功能分析

基因功能注释

目前提供注释的通用功能数据库主要有 GO (GeneOntology, <http://geneontology.org/>)、KEGG (Kyoto Encyclopedia of Genes and Genomes, <http://www.genome.jp/kegg/>)、COG (Cluster of Orthologous Groups of proteins, <http://www.ncbi.nlm.nih.gov/COG/>)、KOG、eggNOG (evolutionary genealogy of genes: Non-supervised Orthologous Groups)、NR (Non-Redundant Protein Database)、TCDB (Transporter Classification Database)、Swiss-Prot (<http://www.ebi.ac.uk/uniprot/>)、CAZy (Carbohydrate-Active enZymes Database) 等。结果见“04.Genome_Function.tar.gz 或 04.Genome_Function 中 General_Gene_Annotation 内 各数据库”。

功能注释基本步骤如下:

- 1) 将预测基因与各功能数据库进行 BLAST 比对 (blastp, $\text{evalue} < 1e-5$);
- 2) BLAST 结果过滤: 对于每一条序列的 BLAST 结果, 选取 score 最高的比对结果 (默认 $\text{identity} \geq 40\%$, $\text{coverage} \geq 40\%$) 进行注释。

效应子

分泌蛋白预测

分泌蛋白是指在细胞内合成后, 在信号肽的引导下穿过细胞膜分泌到细胞外起作用的蛋白质。分泌蛋白中有许多是生命活动所需的重要酶类。分泌蛋白的 N 端是由 15~30 个氨基酸组成的信号肽, 对分泌蛋白的分泌起主导作用。

使用信号肽预测工具 SignalP 进行预测, 检测是否含有信号肽及跨膜结果, 综合预测蛋白质序列是否是分泌蛋白。结果见“04.Genome_Function.tar.gz 或 04.Genome_Function/*/Effector/Secretory_Protein”。

细胞色素 P450 数据库注释

细胞色素 P450 (cytochrome P450 或 CYP450, 简称 CYP450) 为一类亚铁血红素-硫醇盐蛋白的超家族, 它参与内源性物质和包括药物、环境化合物在内的外源性物质的代谢。

结果见“04.Genome_Function.tar.gz 或 04.Genome_Function/*/Effector/P450”。

次级代谢基因簇分析

次级代谢产物是微生物在一定的生长时期, 以初级代谢产物为前体合成的对微生物的生命活动

无明确功能，并非生长繁殖所必需的物质。采用 antiSMASH 程序(version 2.0.2) 对 基因组进行预测。

结果见“04.Genome_Function.tar.gz 或

04.Genome_Function/*/Effector/Secondary_Metabolism”。

致病性分析

对于真菌，目前提供注释的病原细菌致病性和耐药性数据库主要有 PHI(Pathogen Host Interactions Database)、DFVF (database of fungal virulence)。结果见“04.Genome_Function.tar.gz 或 04.Genome_Function 中 Pathogenicity 内各数据库”。

比较基因组分析

全基因组共线性分析

共线性指的是遗传学中的基因连锁关系，是不同物种基因组上同源基因以相同顺序排列的现象。两个物种之间的共线性程度可以作为衡量他们之间进化距离的尺度，可以知道物种间的亲缘关系。结果见“06.Comparative_Genomics.tar.gz 或 06.Comparative_Genomics 中 Synteny”。

SNP 分析

SNP (单核苷酸多态性, single nucleotide polymorphism)主要是指在基因组水平上由 单个核苷酸的变异所引起的 DNA 序列多态性，包括单个碱基的转换、颠换等。

采用 MUMmer(version 3.22)比对软件进行个体 SNP 的检测，依照 SNP 和基因之间的 位置关系及相互作用，对 SNP 功能进行注释。结果见“06.Comparative_Genomics.tar.gz 或 06.Comparative_Genomics 中 SNP”。

InDel 分析

InDel 是指基因组中小片段的插入和缺失序列。利用 LASTZ 软件检测长度小于 50bp 的小片段插入 与缺失 (InDel)， 结果见 “ 06.Comparative_Genomics.tar.gz 或 06.Comparative_Genomics 中 InDel”。

SV 分析

结构性变异 (Structural Variation, SV) 指基因组水平上大片段的插入、缺失、倒置、易位等序列。

使用 MUMmer (version 3.22) 进行两个基因组的快速比对，确定序列的相对方向，并对基因组进行调整，对齐基因组起点。运用 Lastz (version 1.02.00) 软件进行全基因组比对。使用 chainNet 等软件包将比较零散的比对结果连接成更长的比对结果 (如 chain、net 等形式)。根据新的比对块顺序排列关系和相对方向，查找出属于易位 (Translocation)、倒置 (Inversion) 和易位兼倒置 (Trans+Inver) 关系的比对块，再根据两个基因组上相邻比对块之间的距离关系确定比对块间的 SV 区域。

结果见“06.Comparative_Genomics.tar.gz 或 06.Comparative_Genomics 中 SV”。

群体进化分析

共有和特有基因分析

所有样本中均存在的同源基因称为共有基因 (Coregene)，除去共有基因，其他的基因

称为非共有基因 (Dispensable gene)，特有基因 (Specific gene) 是只有在某个样品中所特异 拥有的基因。所有非共有基因与共有基因合并作为泛基因集 (Pangene)。其中共有基因 (Coe gene) 和特有基因 (Specific gene) 很可能与样品的共性和特性相对应，可以作为样本间功能差异的研究依据。结果见“06.Comparative_Genomics.tar.gz 或 06.Comparative_Genomics 中 Core-Pan”。

基因家族分析

基因组进化中，一个基因通过基因重复产生了两个或更多的拷贝，这些基因即构成一个 基因家族。基因家族是具有共同祖先的一组基因，家族内不同基因往往具有相似的结构和 功能。由于基因家族是随着物种分化而形成的，研究基因家族进化能揭示基因演化历史，基 因功能和物种分化，为预测未知基因功能和研究基因进化历史提供依据和线索。

使用 BLAST 软件对多个目标基因组的蛋白进行两两比对，过滤比对不可信的结果，再 使用 Solar 去除冗余，用 Hcluster-sg 按照比对相似度对蛋白进行聚类，得到基因家族聚类结果。

结果见“06.Comparative_Genomics.tar.gz 或 06.Comparative_Genomics 中 Gene_Family”。

物种进化分析

系统发生树 (phylogenetic tree 或 evolutionary tree)是表明被认为具有共同祖先的各物 种相互间演化关系的树，又被译作系统发育树、系统演化树、系统进化树、种系发生树、演 化树、进化树、系统树。它用来表示系统发生研究的结果，用它描述物种之间的进化关系。

采用 NJ 法构建了系统发生树，结果见“ 06. Comparative_Genomics .tar.gz 或 06.Comparative_Genomics 中 Phylogenetic_Tree”。

基因组可视化分析

全基因组图谱

针对测序样品的组装基因组序列，结合样本基因组组分分析及各数据库功能注释，使用 Circos 软件对样品基因组进行可视化展示。

结果见 “05. Genome_Drawing. tar. gz 或 05. Genome_Drawing 中 Genome_Overview” 。

ONT barcode 与接头序列信息

接头信息:

Native Adapter (NA)

Top strand:

5'-TTTTTTTCTGTACTTCGTTACGTTACGTATTGCT-3'

Bottom strand:

5'-ACGTAAGTGAACGAAGTACAGG-3'

Barcode 信息:

Native barcode sequences

Component	Forward sequence	Reverse sequence
NB01	CACAAAGACACCGACAACCTTTCTT	AAGAAAGTTGTCGGTGTCTTTGTG
NB02	ACAGACGACTACAAACGGAATCGA	TCGATTCCGTTTGTAGTCGTCTGT
NB03	CCTGGTAACTGGGACACAAGACTC	GAGTCTTGTGTCCCAGTTACCAGG
NB04	TAGGGAAACACGATAGAATCCGAA	TTCGGATTCTATCGTGTTCCTTA
NB05	AAGGTTACACAAACCCTGGACAAG	CTTGTCCAGGGTTTGTGTAACCTT
NB06	GACTACTTTCTGCCTTTGCGAGAA	TTCTCGCAAAGGCAGAAAGTAGTC
NB07	AAGGATTCAATCCACGGTAACAC	GTGTTACCGTGGGAATGAATCCTT
NB08	ACGTAAGTGGTTTGTCCCTGAA	TTCAAGGAACAAACCAAGTTACGT
NB09	AACCAAGACTCGCTGTGCCTAGTT	AACTAGGCACAGCGAGTCTTGGTT
NB10	GAGAGGACAAAGGTTTCAACGCTT	AAGCGTTGAAACCTTTGTCCTCTC
NB11	TCCATTCCCTCCGATAGATGAAAC	GTTTCATCTATCGGAGGGAATGGA
NB12	TCCGATTCTGCTTCTTTCTACCTG	CAGGTAGAAAGAAGCAGAATCGGA

Component	Forward sequence	Reverse sequence
NB13	AGAACGACTTCCATACTCGTGTGA	TCACACGAGTATGGAAGTCGTTCT
NB14	AACGAGTCTCTTGGGACCCATAGA	TCTATGGGTCCCAAGAGACTCGTT
NB15	AGGTCTACCTCGCTAACACCACTG	CAGTGGTGTTAGCGAGGTAGACCT
NB16	CGTCAACTGACAGTGGTTCGTACT	AGTACGAACCACTGTCAGTTGACG
NB17	ACCCTCCAGGAAAAGTACCTCTGAT	ATCAGAGGTACTTTCCTGGAGGGT
NB18	CCAAACCCAACAACCTAGATAGGC	GCCTATCTAGGTTGTTGGGTTTGG
NB19	GTTCCCTCGTGCAGTGTCAAGAGAT	ATCTCTTGACACTGCACGAGGAAC
NB20	TTGCGTCCTGTTACGAGAACTCAT	ATGAGTTCTCGTAACAGGACGCAA
NB21	GAGCCTCTCATTGTCCGTTCTCTA	TAGAGAACGGACAATGAGAGGCTC
NB22	ACCACTGCCATGTATCAAAGTACG	CGTACTTTGATACATGGCAGTGGT
NB23	CTTACTACCCAGTGAACCTCCTCG	CGAGGAGGTTCACTGGGTAGTAAG
NB24	GCATAGTTCTGCATGATGGGTTAG	CTAACCCATCATGCAGAACTATGC
NB25	GTAAGTTGGGTATGCAACGCAATG	CATTGCGTTGCATACCCAACTTAC
NB26	CATACAGCGACTACGCATTCTCAT	ATGAGAATGCGTAGTCGCTGTATG
NB27	CGACGGTTAGATTACCTCTTACA	TGTAAGAGGTGAATCTAACCGTCG
NB28	TGAAACCTAAGAAGGCACCGTATC	GATACGGTGCCTTCTTAGGTTTCA
NB29	CTAGACACCTTGGGTTGACAGACC	GGTCTGTCAACCCAAGGTGTCTAG
NB30	TCAGTGAGGATCTACTTCGACCCA	TGGGTCGAAGTAGATCCTCACTGA
NB31	TGCGTACAGCAATCAGTTACATTG	CAATGTAAGTGAATGCTGTACGCA
NB32	CCAGTAGAAGTCCGACAACGTCAT	ATGACGTTGTGCGACTTCTACTGG
NB33	CAGACTTGGTACGGTTGGGTAAC	AGTTACCCAACCGTACCAAGTCTG
NB34	GGACGAAGAACTCAAGTCAAAGGC	GCCTTTGACTTGAGTTCTTCGTCC
NB35	CTACTTACGAAGCTGAGGGACTGC	GCAGTCCCTCAGCTTCGTAAGTAG
NB36	ATGTCCCAGTTAGAGGAGGAAACA	TGTTTCCTCCTCTAACTGGGACAT
NB37	GCTTGCGATTGATGCTTAGTATCA	TGATACTAAGCATCAATCGCAAGC
NB38	ACCACAGGAGGACGATACAGAGAA	TTCTCTGTATCGTCCTCCTGTGGT
NB39	CCACAGTGTCAACTAGAGCCTCTC	GAGAGGCTCTAGTTGACACTGTGG
NB40	TAGTTTGGATGACCAAGGATAGCC	GGCTATCCTTGGTCATCCAAACTA
NB41	GGAGTTCGTCCAGAGAAGTACACG	CGTGTACTTCTCTGGACGAACTCC
NB42	CTACGTGTAAGGCATACCTGCCAG	CTGGCAGGTATGCCTTACACGTAG
NB43	CTTTCGTTGTTGACTCGACGGTAG	CTACCGTCGAGTCAACAACGAAAG
NB44	AGTAGAAAGGGTTCCTTCCCCTC	GAGTGGGAAGGAACCCCTTCTACT
NB45	GATCCAACAGAGATGCCTTCAGTG	CACTGAAGGCATCTCTGTTGGATC
NB46	GCTGTGTTCCACTTCATTCTCCTG	CAGGAGAATGAAGTGAACACAGC
NB47	GTGCAACTTTCCACAGGTAGTTC	GAACTACCTGTGGGAAAGTTGCAC
NB48	CATCTGGAACGTGGTACACCTGTA	TACAGGTGTACCACGTTCCAGATG

Component	Forward sequence	Reverse sequence
NB49	ACTGGTGCAGCTTTGAACATCTAG	CTAGATGTTCAAAGCTGCACCAGT
NB50	ATGGACTTTGGTAACTTCCTGCGT	ACGCAGGAAGTTACCAAAGTCCAT
NB51	GTTGAATGAGCCTACTGGGTCCTC	GAGGACCCAGTAGGCTCATTCAAC
NB52	TGAGAGACAAGATTGTTCTGGAC	GTCCACGAACAATCTTGTCTCTCA
NB53	AGATTCTAGACCGTCTCATGCAAAG	CTTTGCATGAGACGGTCTGAATCT
NB54	CAAGAGCTTTGACTAAGGAGCATG	CATGCTCCTTAGTCAAAGCTCTTG
NB55	TGGAAGATGAGACCTGATCTACG	CGTAGATCAGGGTCTCATCTTCCA
NB56	TCACTACTCAACAGGTGGCATGAA	TTCATGCCACCTGTTGAGTAGTGA
NB57	GCTAGGTCAATCTCCTTCGGAAGT	ACTTCCGAAGGAGATTGACCTAGC
NB58	CAGGTTACTCCTCCGTGAGTCTGA	TCAGACTCACGGAGGAGTAACCTG
NB59	TCAATCAAGAAGGGAAAAGCAAGGT	ACCTTGCTTTCCCTTCTTGATTGA
NB60	CATGTTCAACCAAGGCTTCTATGG	CCATAGAAGCCTTGGTGAACATG
NB61	AGAGGGTACTATGTGCCTCAGCAC	GTGCTGAGGCACATAGTACCCTCT
NB62	CACCCACACTTACTTCAGGACGTA	TACGTCCTGAAGTAAGTGTGGGTG
NB63	TTCTGAAGTTCCTGGGTCTTGAAC	GTTCAAGACCCAGGAACTTCAGAA
NB64	GACAGACACCGTTCATCGACTTTC	GAAAGTCGATGAACGGTGTCTGTC
NB65	TTCTCAGTCTTCCTCCAGACAAGG	CCTTGTCTGGAGGAAGACTGAGAA
NB66	CCGATCCTTGTGGCTTCTAACTTC	GAAGTTAGAAGCCACAAGGATCGG
NB67	GTTTGTCTACTCGTGTGCTCACC	GGTGAGCACACGAGTATGACAAAC
NB68	GAATCTAAGCAAACACGAAGGTGG	CCACCTTCGTGTTTGCTTAGATTC
NB69	TACAGTCCGAGCCTCATGTGATCT	AGATCACATGAGGCTCGGACTGTA
NB70	ACCGAGATCCTACGAATGGAGTGT	ACACTCCATTTCGTAGGATCTCGGT
NB71	CCTGGGAGCATCAGGTAGTAACAG	CTGTTACTACCTGATGCTCCCAGG
NB72	TAGCTGACTGTCTTCCATACCGAC	GTCGGTATGGAAGACAGTCAGCTA
NB73	AAGAAACAGGATGACAGAACCCTC	GAGGGTTCTGTCATCCTGTTTCTT
NB74	TACAAGCATCCCAACACTTCCACT	AGTGGAAGTGTGAGGATGCTTGTA
NB75	GACCATTTGTGATGAACCCTGTTGT	ACAACAGGGTTCATCACAATGGTC
NB76	ATGCTTGTTACATCAACCCTGGAC	GTCCAGGGTTGATGTAACAAGCAT
NB77	CGACCTGTTTCTCAGGGATACAAC	GTTGTATCCCTGAGAAACAGGTCG
NB78	AACAACCGAACCTTTGAATCAGAA	TTCTGATTCAAAGGTTCCGTTGTT
NB79	TCTCGGAGATAGTTCTCACTGCTG	CAGCAGTGAGAACTATCTCCGAGA
NB80	CGGATGAACATAGGATAGCGATTC	GAATCGCTATCCTATGTTTCATCCG
NB81	CCTCATCTTGTGAAGTTGTTTCGG	CCGAAACAACCTTCACAAGATGAGG
NB82	ACGGTATGTCGAGTTCCAGGACTA	TAGTCCTGGAACCTGACATACCGT
NB83	TGGCTTGATCTAGGTAAGGTCGAA	TTCGACCTTACCTAGATCAAGCCA
NB84	GTAGTGGACCTAGAACCTGTGCCA	TGGCACAGGTTCTAGGTCCACTAC

Component	Forward sequence	Reverse sequence
NB85	AACGGAGGAGTTAGTTGGATGATC	GATCATCCAATAACTCCTCCGTT
NB86	AGGTGATCCCAACAAGCGTAAAGTA	TACTTACGCTTGTTGGGATCACCT
NB87	TACATGCTCCTGTTGTTAGGGAGG	CCTCCCTAACAACAGGAGCATGTA
NB88	TCTTCTACTACCGATCCGAAGCAG	CTGCTTCGGATCGGTAGTAGAAGA
NB89	ACAGCATCAATGTTTGGCTAGTTG	CAACTAGCCAAACATTGATGCTGT
NB90	GATGTAGAGGGTACGGTTTGAGGC	GCCTCAAACCGTACCCTCTACATC
NB91	GGCTCCATAGGAACTCACGCTACT	AGTAGCGTGAGTTCCTATGGAGCC
NB92	TTGTGAGTGGAAGATACAGGACC	GGTCCTGTATCTTTCCACTCACAA
NB93	AGTTTCCATCACTTCAGACTTGGG	CCCAAGTCTGAAGTGATGGAAACT
NB94	GATTGTCCTCAAAGTGCCACCTAC	GTAGGTGGCAGTTTGAGGACAATC
NB95	CCTGTCTGGAAGAAGAATGGACTT	AAGTCCATTCTTCTTCCAGACAGG
NB96	CTGAACGGTCATAGAGTCCACCAT	ATGGTGGACTCTATGACCGTTCAG