

生物信息分析流程

目录

原始下机数据处理	2
样品组装	2
基因组组分分析	2
编码基因	2
重复序列	2
非编码RNA	2
基因岛	3
转座子	3
前噬菌体	3
CRISPR	3
基因功能分析	3
基因功能注释	3
效应子	4
分泌蛋白预测	4
分泌系统蛋白及T3SS 效应蛋白预测	4
次级代谢基因簇分析	4
毒力或致病性分析	4
比较基因组分析	4
全基因组共线性分析	4
SNP 分析	5
InDel 分析	5
SV 分析	5
群体进化分析	5
共有和特有基因分析	5
基因家族分析	5
物种进化分析	5
甲基化分析	6
基因组可视化分析	6
全基因组图谱	6

原始下机数据处理

三代数据：

第三代测序仪 PacBio，采用单分子测序技术，拥有超长的读长优势，对于完整基因组的组装性有重要作用。原始下机数据以 bam 格式文件保存，其中包含了测序序列，碱基质量值等信息。通过对下机数据统计，得到数据总量，reads 读长，质量值分布等信息。

二代数据：

测序得到的原始数据(Raw Data)会存在一定比例的低质量数据，为了保证后续信息分析结果的准确可靠，首先要对原始数据进行过滤处理，得到有效数据(Clean Data)。具体处理步骤如下：

- 1) 去除所含低质量碱基（质量值 ≤ 38 ）超过一定比例（默认设为 40bp）的 reads；
- 2) 去除 N 碱基达到一定比例的 reads（默认设为 10bp）；
- 3) 去除与 Adapter 之间 overlap 超过一定阈值（默认设为 15bp）的 reads；
- 4) 对于小基因组等项目，如果样品存在宿主污染，需与宿主数据库进行比对，过滤掉可能来源于宿主的 reads。

样品组装

使用 Canu 软件(<https://github.com/marbl/canu/>, version: 2.0)对三代 reads 进行基因组组装，得到能反映样品基因组基本情况的初步的组装结果，然后使用 Racon (version: 1.4.13) 软件基于三代测序数据对拼接结果进行三轮纠错后，再进行三轮二代 reads 的 Pilon (version: 1.22) 纠错，得到最终的组装结果。

基因组组分析

编码基因

从各样品最终的组装结果 ($\geq 500\text{bp}$) 出发，采用对应的软件进行 ORF (Open Reading Frame) 预测及过滤。结果见“03.Genome_Component.tar.gz 或 03.Genome_Component 中 Gene”。

对于细菌、古菌等样本采用 GeneMarkS 软件 (version 4.17) (<http://topaz.gatech.edu/>) 进行编码基因预测及过滤。

重复序列

根据重复的序列在基因组上的分布，分为两大类：散在重复序列、串联重复序列。散在重复序列是与串联重复序列的组织形式不同的另一类重复序列，是散在方式分布于基因组内的散在重复序列。串联重复序列 (Tandem Repeat, TR)，即相邻的、重复两次或多次特定核酸序列模式的重复序列。结果见“03.Genome_Component.tar.gz 或 03.Genome_Component 中 Repeat”。

通过 RepeatMasker 软件 (version 4.0.5) 进行散在重复序列预测，TRF (Tandem repeats finder, version 4.07b) 搜寻 DNA 序列中的串联重复序列。

非编码RNA

非编码 RNA (ncRNA) 是一类广泛存在于小基因组、细菌、古生菌和真核生物生物体内，执行多种生物学功能的 RNA 分子，其本身并不携带翻译为蛋白质的信息，直接在 RNA 水平对生命活动发挥作用。对于微生物而言，非编码 RNA 的主要类型包括 sRNA、rRNA、tRNA、snRNA、snoRNA 及 miRNA 等等。结果见“03.Genome_Component.tar.gz 或 03.Genome_Component 中 ncRNA”。

常见类型 ncRNA 预测方法如下：

- 1) tRNA: 通过 tRNAscan-SE 软件可预测tRNA 区域和tRNA 的二级结构。
- 2) rRNA: 通过比对 rRNA 库查找与数据库近缘的 rRNA (identity 默认 $\geq 50\%$), 并利用 rRNAmmer 软件预测新出现及未被注释的rRNAs, 综合二者结果。
- 3) sRNA: 首先用Rfam 软件进行Rfam database 比对注释, 接着用cmsearch 程序 (version 1.1rc4) 确定最终的sRNA。

基因岛

基因岛 (Genomics Islands, GIs) 是一些细菌、噬菌体或质粒中有横向起源迹象的一部分基因组。基因岛大小通常从10 到500 Kbp, 其GC 含量和密码子选择与基因组的其余部分不同。基因岛的许多亚分类基于它们所表现出来的功能, 如病原性基因岛 (Pathogenicity islands, PAIs) 其上包含有毒力基因, 与致病机理相关, 抗生素抗性基因岛包含有许多抗生素抗性基因。结果见 “03.Genome_Component.tar.gz 或 03.Genome_Component 中 Genomic_Island”。

采用 IslandPath-DIOMB 软件预测基因岛, 其通过检测序列中二核苷酸偏向性 (phylogenetically bias) 和移动性基因 (mobility genes, 如转座酶或整合酶) 以判定基因岛以及潜在的水平基因转移。

转座子

转座子(transposon,简称Tn),又称易位子,是存在于染色体DNA上可以自主复制和移位的基本单位。DNA 的转座,或称移位 (transposition),是由可移位因子(transposable elements)介导的遗传物质重排现象,与同源重组相比,转座发生的频率要低得多。转座子可以在不同复制子之间转移,以非正常重组方式从一个位点插入到另外一个位点,对新位点基因的结构与表达产生多种遗传效应。

采用TransposonPSI 软件对转座子进行预测。其通过 PSI-Blast 同源比对来对基因组或者蛋白序列进行查找可能的转座子序列。结果见 “03.Genome_Component.tar.gz 或 03.Genome_Component 中 Transposon”。

前噬菌体

整合在宿主基因组上的温和噬菌体的核酸称之为前噬菌体。前噬菌体预测是使用 phiSpy 工具 (Nov11_v2.3), 这是一个预测精度和准确性都很高的工具, 支持 GenBank 格式格式文件, 结果见“03.Genome_Component.tar.gz 或03.Genome_Component 中 Prophage”。

CRISPR

CRISPR (Clustered Regularly Interspaced Short Palindromic Repeat Sequences, 成簇的、规律间隔的短回文重复序列) 是在 40%已测序的细菌和 90%已测序的古细菌中都有报道过的、含有一个与噬菌体和质粒同源的短的重重复序列, 通过对外来同源的 DNA 作用对噬菌体有抗性, 影响质粒的连接, 是原核生物的免疫系统一部分。

采用CRISPRdigger 工具对样品基因组进行 CRISPR 预测, CRISPRdigger 准确性高并能预测其中的短回文重复结构。结果见 “03.Genome_Component.tar.gz 或 03.Genome_Component 中 CRISPR”。

基因功能分析

基因功能注释

目前提供注释的通用功能数据库主要有 GO (Gene Ontology, <http://geneontology.org/>)、KEGG (Kyoto Encyclopedia of Genes and Genomes, <http://www.genome.jp/kegg/>)、COG (Cluster of Orthologous Groups of proteins, <http://www.ncbi.nlm.nih.gov/COG/>)、KOG、eggNOG (evolutionary genealogy of genes: Non-supervised Orthologous Groups)、NR (Non-Redundant Protein Database)、TCDB (Transporter Classification Database)、Swiss-

Prot (<http://www.ebi.ac.uk/uniprot/>)、CAZy (Carbohydrate-Active enZymes Database) 等。结果见“04.Genome_Function.tar.gz 或 Genome_Function 中 General_Gene_Annotation 内各数据库”。

功能注释基本步骤如下:

- 1) 将预测基因与各功能数据库进行 BLAST 比对 (blastp, $\text{evalue} \leq 1e-5$);
- 2) BLAST 结果过滤: 对于每一条序列的 BLAST 结果, 选取 score 最高的比对结果 (默认 $\text{identity} \geq 40\%$, $\text{coverage} \geq 40\%$) 进行注释。

效应子

分泌蛋白预测

分泌蛋白是指在细胞内合成后, 在信号肽的引导下穿过细胞膜分泌到细胞外起作用的蛋白质。分泌蛋白中有许多是生命活动所需的重要酶类。分泌蛋白的N端是由15~30个氨基酸组成的信号肽, 对分泌蛋白的分泌起主导作用。

使用信号肽预测工具 SignalP 进行预测, 检测是否含有信号肽及跨膜结果, 综合预测蛋白质序列是否是分泌蛋白。结果见“04.Genome_Function.tar.gz 或 04.Genome_Function/*/Effector/Secretory_Protein”。

分泌系统蛋白及T3SS 效应蛋白预测

病原菌通过分泌系统TNSS (type N secretion systems, 目前确定的有7种, I型-VII型) 将该类蛋白分泌至胞外或是宿主细胞中, 通过控制免疫应答反应以及细胞衰亡引起病理反应, 而其中革兰氏阴性菌的T3SS 通常用来从分子水平研究病原菌, 感染机制, 毒力作用等, 是研究得比较多的分泌系统。

对于TNSS 系统, 通过蛋白序列功能数据库注释结果中, 提取分泌系统相关蛋白进行注释。结果见“04.Genome_Function.tar.gz 或 04.Genome_Function/*/Effector/TnSS”。

对于革兰氏阴性菌, 另外采用 EffectiveT3 软件预测 T3SS 效应蛋白。结果见“04.Genome_Function.tar.gz 或 04.Genome_Function/*/Effector/T3SS”。

次级代谢基因簇分析

次级代谢产物是微生物在一定的生长时期, 以初级代谢产物为前体合成的对微生物的生命活动无明确功能, 并非生长繁殖所必需的物质。采用 antiSMASH 程序 (version 2.0.2) 对基因组进行预测。

结果见“04.Genome_Function.tar.gz 或

04.Genome_Function/*/Effector/Secondary_Metabolism”。

毒力或致病性分析

对于细菌, 目前提供注释的病原细菌致病性和耐药性数据库主要有 PHI (Pathogen Host Interactions Database)、VFDB (Virulence Factors of Pathogenic Bacteria)、ARDB (Antibiotic Resistance Genes Database)、CARD (Comprehensive Antibiotic Research Database)。结果见“04.Genome_Function.tar.gz 或 04.Genome_Function 中 Pathogenicity 内各数据库”。

比较基因组分析

全基因组共线性分析

共线性指的是遗传学中的基因连锁关系, 是不同物种基因组上同源基因以相同顺序排列的现象。两个物种之间的共线性程度可以作为衡量他们之间进化距离的尺度, 可以知道物种间的亲缘关系。结果见“06.Comparative_Genomics.tar.gz 或 06.Comparative_Genomics 中

Synteny”。

SNP 分析

SNP（单核苷酸多态性，single nucleotide polymorphism）主要是指在基因组水平上由单个核苷酸的变异所引起的DNA序列多态性，包括单个碱基的转换、颠换等。

采用MUMmer（version 3.22）比对软件进行个体SNP的检测，依照SNP和基因之间的位置关系及相互作用，对SNP功能进行注释。结果见“06.Comparative_Genomics.tar.gz或06.Comparative_Genomics中SNP”。

InDel 分析

InDel是指基因组中小片段的插入和缺失序列。利用LASTZ软件检测长度小于50bp的小片段插入与缺失（InDel），结果见“06.Comparative_Genomics.tar.gz或06.Comparative_Genomics中InDel”。

SV 分析

结构性变异（Structural Variation，SV）指基因组水平上大片段的插入、缺失、倒置、易位等序列。

使用MUMmer（version 3.22）进行两个基因组的快速比对，确定序列的相对方向，并对基因组进行调整，对齐基因组起点。运用Lastz（version 1.02.00）软件进行全基因组比对。使用chainNet等软件包将比较零散的比对结果连接成更长的比对结果（如chain、net等形式）。根据新的比对块顺序排列关系和相对方向，查找出属于易位（Translocation）、倒置（Inversion）和易位兼倒置（Trans+Inver）关系的比对块，再根据两个基因组上相邻比对块之间的距离关系确定比对块间的SV区域。

结果见“06.Comparative_Genomics.tar.gz或06.Comparative_Genomics中SV”。

群体进化分析

共有和特有基因分析

所有样本中均存在的同源基因称为共有基因（Core gene），除去共有基因，其他的基因称为非共有基因（Dispensable gene），特有基因（Specific gene）是只有在某个样品中所特异拥有的基因。所有非共有基因与共有基因合并作为泛基因集（Pan gene）。其中共有基因（Core gene）和特有基因（Specific gene）很可能与样品的共性和特性相对应，可以作为样本间功能差异的研究依据。结果见“06.Comparative_Genomics.tar.gz或06.Comparative_Genomics中Core-Pan”。

基因家族分析

基因组进化中，一个基因通过基因重复产生了两个或更多的拷贝，这些基因即构成一个基因家族。基因家族是具有共同祖先的一组基因，家族内不同基因往往具有相似的结构和功能。由于基因家族是随着物种分化而形成的，研究基因家族进化能揭示基因演化历史，基因功能和物种分化，为预测未知基因功能和研究基因进化历史提供依据和线索。

使用BLAST软件对多个目标基因组的蛋白进行两两比对，过滤比对不可信的结果，再使用Solar去除冗余，用Hcluster-sg按照比对相似度对蛋白进行聚类，得到基因家族聚类结果。

结果见“06.Comparative_Genomics.tar.gz或06.Comparative_Genomics中Gene_Family”。

物种进化分析

系统发生树（phylogenetic tree或evolutionary tree）是表明被认为具有共同祖先的各物种相互间演化关系的树，又被译作系统发育树、系统演化树、系统进化树、种系发生树、演化树、进化树、系统树。它用来表示系统发生研究的结果，用它描述物种之间的进化关系。

采用 NJ 法构建了系统发生树，结果见“06.Comparative_Genomics.tar.gz 或 06. Comparative_Genomics 中 Phylogenetic_Tree”。

甲基化分析

使用 SMRT Link v8.0.0，对最终的基因组组装结果进行甲基化位点检测和可能的甲基化转移酶识别的核苷酸基序（motif）的预测。能够预测到的修饰类型包括 6mA，4mC 和 5mC，以及未知类型(modified_base)。

基因组可视化分析

全基因组图谱

针对测序样品的组装基因组序列，结合样本基因组组分分析及各数据库功能注释，使用 Circos 软件对样品基因组进行可视化展示。

结果见“05.Genome_Drawing.tar.gz 或05.Genome_Drawing 中Genome_Overview”。

