


基因集富集分析（GSEA）介绍

基本概念

GSEA(Gene Set Enrichment Analysis): 基因集富集分析,其基本思想是使用预定义的基因集,把基因按照在两组样本中的差异表达程度进行排序,然后采用统计学方法检验预先设定的基因集合是否在排序列表的顶端或底端富集。



GSEA 分析与常规富集分析的区别在哪里？

传统的 GO/KEGG 富集结果,如果富集到的同一通路下,既有上调差异基因,也有下调差异基因,那么这条通路总体的表现形式究竟是怎样?是被抑制还是激活?或者更直观点说,这条通路下的基因表达水平在实验处理后是上升了呢,还是下降了呢?

传统的富集分析,针对总体的差异基因,其实是不能区分通路的上下调情况的。

这是因为,传统的富集分析根本不考虑基因表达量的变化趋势,其算法的核心只关注这些差异基因的分布是否和随机抽样得到的分布一致,由于没有采用有效的统计学手段去分析某条通路下的差异基因的总体的变化趋势,这使得传统的富集分析结果无法回答上述的问题。

想要回答这个问题,我们就需要用到 GSEA 富集分析方法。

此外,GO/KEGG 差异基因的一刀切法--常规的基于超几何分布的富集分析依赖于显著上调或下调的基因,容易遗漏部分差异表达不显著但有重要生物学意义的基因,忽略一些基因的生物特性、基因调控网络之间的关系及基因功能和意义等有

价值的信息。基因集富集分析（GSEA）不需要指定明确的差异基因阈值，算法根据实际整体趋势分析，从基因集的富集角度出发，更容易囊括细微但协同变化对生物通路的影响，尤其是差异倍数较小的基因集。在结果解读时应该是侧重于 **GSEA 分析还是常规富集分析？其中哪个更好呢？** 没有哪个更好的说法，只有哪个结果更符合我们的研究目的，只要有富集结果，就具有一定生物学意义。

基本原理

GSEA 主要包括四个步骤：1：基因排序 2：计算富集得分（Enrichment Score）3：估计富集得分的显著性水平 4：多重假设检验。

Step1、基因排序

- 1) 根据所有基因的表达数据,计算每个基因在分组间的差异（signal2 noise），然后按照在两个表型中的差异度从大到小排序，形成一个排好序的基因列表。
- 2) 根据排序好的基因列表，判断基因集 S 中的基因是否在排序表的顶端或者底端富集。

Step2 、计算基因集 S 的 ES（Enrichment Score）富集得分

计算方法：从目标基因列表 L 的第一个基因开始，计算一个累计统计值。当遇到一个落在基因集 S 里面的基因，则加分。遇到一个不在基因集 S 里面的基因，则减分，增量的大小取决于基因与表型的相关性。最高峰为富集得分值（ES）


Step3、计算 ES 的显著性水平（名义 P 值）

利用 empirical phenotype-based permutation test 来计算 ES 的名义 P 值，保留了原始表达数据的复杂相关性。

Step4、ES 标准化和多重假设检验

考虑该基因集的大小,将每个基因集的 ES 标准化,得到标准化的富集分数(NES); 通过计算 false discovery rate (FDR) 值，来控制假阳性率。

其中 FDR、p 值：FDR<0.25，p<0.05 且 |NES| >1 则表示结果有统计学意义。




GSEA 原理图

结果解读

以上就是我们 GSEA 分析的原理了，那么如何进行 GSEA 的结果解读呢？

GSEA 保存文件路径中会生成非常多的文件：



如此多的文件使我们眼花缭乱无从下手，那么我们应该重点关注哪些，哪些又是常用结果呢？

点开 **gsea report for*** 的文件，可以进入 GSEA 的富集列表，GSEA 最常见富集列表如下：

该表表头的具体含义为：

GS follow link to MSigDB: 该基因集在 GO、KEGG 和 Reactome 等数据库中所对应的 ID 号

GS DETAILS: 列举了前 20 个基因集的详细信息。

SIZE: 基因集中包含的基因个数。

ES: Enrichment Score 富集得分值。


NES: normalized enrichment score, 考虑该基因集的大小，将每个基因集的 ES 值标准化，得到标准化的富集分数。

NOM p-val: nominal P value ， 名义 p 值， 富集分析统计学显著水平。

FDR q-val: false discovery rate q-val ， 假阳性率 P 值， 多重假设检验后得到的富集分析统计学显著水平。

FWER p-val: familywise-error rate p-val ， 总体错误率 P 值。

RANK AT MAX: 基因集在基因列表里的最大排名。



第一部分为基因 ES 的折线图，横轴为该基因下的每个基因，纵轴为对应的 Running ES，折线图上的峰值，即这个基因集的 Enrichment score；第二部分为 hit，用线条标记位于该基因集下的基因；第三部分为所有基因的 rank 值分布图，一般默认采用 Signal2Noise 算法，对应了纵轴的标题。

对于 Enrichment score 为正数的基因集而言，其核心基因是峰值之前的基因，对于 Enrichment score 为负数的基因集而言，其核心基因是峰值之后的基因。

除上述结果文件中可以一一查看每个图，也可点击 GSEA reports 查看网页报告：

Enrichment in phenotype: EF_A (4 samples)

- 340 / 815 gene sets are upregulated in phenotype **EF_A**
- 1 gene sets are significant at FDR < 25%
- 48 gene sets are significantly enriched at nominal pvalue < 1%
- 72 gene sets are significantly enriched at nominal pvalue < 5%
- [Snapshot](#) of enrichment results
- Detailed [enrichment results in html](#) format
- Detailed [enrichment results in excel](#) format (tab delimited text)
- [Guide to](#) interpret results

Enrichment in phenotype: EF_F (4 samples)

- 475 / 815 gene sets are upregulated in phenotype **EF_F**
- 89 gene sets are significant at FDR < 25%
- 122 gene sets are significantly enriched at nominal pvalue < 1%
- 162 gene sets are significantly enriched at nominal pvalue < 5%
- [Snapshot](#) of enrichment results
- Detailed [enrichment results in html](#) format
- Detailed [enrichment results in excel](#) format (tab delimited text)
- [Guide to](#) interpret results

该报告点击“enrichment results in html”也会出现上述富集列表

	GS follow link to MSigDB	GS DETAILS	SIZE	ES	NES	NOM p-val	FDR q-val	FWER p-val	RANK AT MAX	LEADING EDGE
1	QUORUM_SENSING(SMY02024)	Details...	26	0.54	1.78	0.000	0.058	0.000	284	tags=27%, list=6%, signal=29%
2	BACTERIAL_SECRETION_SYSTEM(SMY03070)	Details...	27	0.64	1.72	0.000	0.098	0.089	874	tags=52%, list=19%, signal=64%
3	MISMATCH_REPAIR(SMY03430)	Details...	19	0.47	1.70	0.000	0.085	0.089	230	tags=21%, list=5%, signal=22%
4	PEPTIDOGLYCAN_BIOSYNTHESIS(SMY00550)	Details...	22	0.60	1.70	0.000	0.078	0.089	1176	tags=68%, list=26%, signal=92%
5	PYRIMIDINE_METABOLISM(SMY00240)	Details...	19	0.66	1.69	0.000	0.074	0.089	1287	tags=79%, list=29%, signal=110%
6	FRUCTOSE_AND_MANNOSE_METABOLISM(SMY00051)	Details...	16	0.60	1.67	0.176	0.090	0.141	440	tags=38%, list=10%, signal=41%
7	PHENYLALANINE, TYROSINE AND TRYPTOPHAN BIOSYNTHESIS(SMY00400)	Details...	21	0.65	1.59	0.060	0.121	0.185	780	tags=52%, list=17%, signal=63%

点击“details”也会出现该基因集详细信息。上述即 GSEA 相关结果说明，如果有需要，也可以直接查看官方详细文档：

http://www.gsea-msigdb.org/gsea/doc/GSEAUUserGuideFrame.html?_Interpreting_GSEA_Results