

中文版 methods

仅供客户在文章写作时参考，分析内容和方法请以结题报告
为准，请客户自行承担文章查重等相关风险。

1 实验流程

1.1 样品检测

详见样本检测报告。

1.2 文库构建与质检

普通建库

使用 Oligo dT 磁珠从总RNA中富集 mRNA。在片段化之后，使用随机六聚体引物合成第一链 cDNA，随后进行第二链 cDNA 的合成。经过末端修复、加 A 尾、接头连接、片段选择、扩增和纯化后，文库准备就绪。

文库通过 Qubit 仪和实时荧光定量 PCR 进行定量，并通过生物分析仪进行片段大小分布检测。

链特异性建库

使用 Oligo dT 磁珠从总RNA中富集 mRNA。在片段化之后，使用随机六聚体引物合成第一链 cDNA。然后，使用 dUTP 而不是 dTTP 合成第二链 cDNA。经过末端修复、加 A 尾、接头连接、片段选择、扩增和纯化后，定向文库准备就绪。

文库通过 Qubit 仪和实时荧光定量 PCR 进行定量，并通过生物分析仪进行片段大小分布检测。

1.3 上机测序

库检合格后，按照有效浓度及目标下机数据量的需求将不同文库 pooling 至一起，进行 Illumina 测序。测序原理是边合成边测序（Sequencing by Synthesis），在测序的 flow cell 中加入四种荧光标记的 dNTP、DNA 聚合酶以及接头引物进行扩增，在每一个测序簇延伸互补链时，每加入一个被荧光标

记的 dNTP 就能释放出相对应的荧光，测序仪捕获荧光信号，并使用计算机软件将光信号转化为测序峰，最终获得待测片段的序列信息。

2 生物信息分析

2.1 数据质控

原始数据 (raw reads) 首先通过 fastp 软件进行处理。在这一步骤中，通过从原始数据中移除含有接头的reads、含有poly-N的reads以及低质量的reads, 获得 clean reads。同时对 clean data 进行Q20、Q30 和GC含量计算。所有下游分析都基于这些高质量的 clean data 进行。

具体数据质控过程如下：

- (1) 当任一测序 read 中含有接头序列，去除此 paired reads。
- (2) 当任一测序 read 中 N 含量超过该 read 碱基数的 10%时，去除此 paired reads。
- (3) 当任一测序 read 中含有的低质量 ($Q \leq 5$) 碱基数超过该条 read 碱基数的 50%时，去除此 paired reads。

2.2 序列比对到参考基因组

从基因组网站下载参考基因组和基因模型注释文件。使用 HISAT2 (2.2.1) 构建参考基因组的索引，并使用 HISAT2 将配对末端 clean reads 与参照基因组比对。HISAT2 可以基于基因模型注释文件生成拼接连接的数据库，比其它非拼接比对工具有更好的比对效果。

2.3 新转录本预测

采用 StringTie (v2.2.3) (Mihaela Pertea.et al. 2015) 软件进行新基因预测。StringTie 应用网络流算法以及可选的从头组装来拼接转录本。相对于

cufflinks 等软件, stringtie 有以下优势: (1) 拼接出更完整的转录本; (2) 拼接出更准确的转录本; (3) 更好的估计转录本的表达水平; (4) 拼接速度更快。

2.4 基因表达水平定量

使用 featureCounts (2.0.6) 计算映射到每个基因的读数。然后根据基因的长度计算每个基因的 FPKM, 并计算映射到该基因的读数。FPKM 指每百万碱基对测序的转录本序列片段的每千碱基片段的预期数量。同时考虑了测序深度和基因长度对读数计数的影响, 并且是当前最常用于估计基因表达水平的方法。

2.5 差异表达分析

对于有生物重复的样品: 使用 DESeq2 R 包 (1.42.0) 进行两个条件/组的差异表达分析。DESeq2 提供统计程序, 用于使用基于负二项分布的模型确定数字基因表达数据中的差异表达。使用 Benjamini 和 Hochberg 方法调整得到的 P 值, 以控制错误发现率。显著差异表达阈值: $\text{padj} \leq 0.05$ & $|\log_2(\text{foldchange})| \geq 1$ 。

对于没有生物重复的样品: 在差异基因表达分析之前, 对每个测序文库, 使用 edgeR R 包 (4.0.16) 通过缩放归一化因子(scaling normalization factors) 调整读取计数, 消除样本间测序深度的差异, 然后进行差异表达分析。使用 Benjamini 和 Hochberg 方法调整得到的 P 值, 以控制错误发现率。显著差异表达阈值: $\text{padj} \leq 0.05$ & $|\log_2(\text{foldchange})| \geq 1$ 。

2.6 差异表达基因的GO和KEGG富集分析

使用 clusterProfiler (4.8.1) 软件实现差异表达基因的 GO 富集分析, 其中修正了基因长度偏差。考虑具有小于 0.05 的校正的 P 值的 GO term 通过

差异表达基因显著富集。KEGG 是一个数据库资源，用于从分子水平的信息，特别是基因组测序产生的大规模分子数据集和其他高通量数据库中了解生物系统的高级功能和效用，如细胞，生物体和生态系统等。使用 clusterProfiler 软件分析 KEGG 通路中差异表达基因的统计富集。

2.7 基因集富集分析

基因集富集分析(Gene Set Enrichment Analysis, GSEA)不需要指定明确的差异基因阈值，使用预先定义的基因集（通常来自功能注释或先前实验的结果），将基因按照在两类样本中的差异表达程度排序，然后检验预先设定的基因集合是否在这个排序表的顶端或者底端富集。基因集富集分析检测基因集合而不是单个基因的表达变化，因此可以包含这些细微的表达变化，预期得到更为理想的结果。使用本地版GSEA分析工具<http://www.broadinstitute.org/gsea/index.jsp>，分别对该物种的 GO、KEGG 数据集进行 GSEA 分析。

2.8 差异基因蛋白网络互作分析

差异表达基因的 PPI 分析基于已知和预测蛋白质-蛋白质相互作用的 STRING 数据库。对于数据库中存在的物种，我们通过从数据库中提取目标基因列表来构建网络；否则，使用 diamond 将目标基因序列与选择的参考蛋白序列进行比对，然后根据所选参考物种的已知相互作用建立网络。

2.9 可变剪接分析

选择性剪接是调控基因表达和蛋白质变量的重要机制。使用 rMATS (4.3.0) 软件分析 AS 事件，主要包括 SE (skipped exon), RI (retained intron), MXE (mutually exclusive exons), A5SS (5' alternative splice site), and A3SS (3' alternative splice site) 五种可变剪接事件。

2.10 SNP 分析

使用变异检测软件 GATK (4.6.0.0) 对样本数据进行变异位点分析。

2.11 WGCNA 分析

加权基因共表达网络分析 (WGCNA, Weighted correlation network analysis) 是用来描述不同样品之间基因关联模式的系统生物学方法, 可以用来鉴定高度协同变化的基因集, 并根据基因集的内连性和基因集与表型之间的关联鉴定候补生物标记基因或治疗靶点。WGCNA R 包 (1.71) 是用于计算各种加权关联分析的功能集合, 可用于网络构建, 基因筛选, 基因簇鉴定, 拓扑特征计算, 数据模拟和可视化等。WGCNA 适用于多样品数据模式, 一般要求样本数多于 15 个, 样本数多于 20 时效果更好, 样本越多, 结果越稳定。输入数据文件一个是样本信息的文件, 即描述样本性状特征的矩阵: 用于关联分析的性状必须是数值型特征; 如果是区域或分类变量, 需要转换为 0-1 矩阵的形式。另外一个基因表达数据的文件, 对于转录组测序即可以用基因表达的 FPKM 数据。