

转录调控个性化分析手册

转录调控业务线

2018.03

目 录

1 WGCNA 分析	6
1.1 分析背景及方法介绍	6
1.2 结果展示	7
1.2.1 模块层次聚类树	7
1.2.2 模块间相关性热图	8
1.2.3 模块基因聚类热图	9
1.2.4 模块基因表达图	10
1.2.5 样本表达模式热图	11
1.2.6 Cytoscape 结果	11
1.3 参考文献	12
2 GSEA 分析	12
2.1 分析背景及方法介绍	12
2.2 结果展示	13
2.2.1 GSEA 富集分析结果总概览	13
2.2.2 GSEA 富集结果	14
2.2.3 GSEA 富集结果的详细信息展示	15
2.2.4 GSEA 富集基因热图	16
2.3 参考文献	16
3 STEM 分析	17
3.1 分析背景及方法介绍	17
3.2 结果展示	17
3.2.1 STEM 分析出的基因表达模块	17
3.2.2 基因表达折线图	19
3.2.3 基因表达模式的向量明细	20
3.3 参考文献	20
4 RNA 编辑分析	20

4.1 分析背景及方法介绍.....	20
4.2 结果展示.....	21
4.2.1 RNA 编辑位点鉴定	21
4.2.2 编辑位点在染色体上的分布	22
4.2.3 RNA 编辑类型分布	24
4.2.4 RNA 编辑类型堆积柱状图	25
4.2.5 RNA 编辑位点在基因不同功能域的分布	26
4.2.6 编辑位点在不同功能域的堆积柱状图	27
4.2.7 编辑位点引起的有义突变与无义突变分析	27
4.2.8 编辑簇分析	29
4.2.9 不同样品中编辑位点的韦恩图	30
4.2.10 不同样品中 RNA 编辑水平的聚类分析	31
4.2.11 A-I 编辑位点的鉴定	31
4.2.12 编辑位点保守性分析	32
4.2.13 GO 富集分析	33
4.2.14 KEGG 富集分析	35
4.3 参考文献.....	37
5 个性化热图绘制.....	38
5.1 多样品差异基因热图分析.....	38
5.2 展示横纵向标签的热图.....	39
6 个性化 Circos 图绘制	40
6.1 差异基因在染色体上的分布图.....	40
6.2 多信息数据可视化 circos 图.....	41
7 维诺图分析.....	42
7.1 分析背景及方法介绍.....	42
7.2 结果展示.....	42
7.3 参考文献.....	43

8 iPath 分析	43
8.1 分析背景及方法介绍.....	43
8.2 结果展示.....	43
8.2.1 提取 KOs 结果.....	43
8.2.2 多样品代谢通路比较分析图	44
8.3 参考文献.....	45
9. 节律基因分析.....	45
9.1 分析背景及方法介绍.....	45
9.2 结果展示.....	45
9.2.1 节律基因的筛选结果	45
9.2.2 节律基因的注释结果	46
9.2.3 节律基因聚类分析	48
9.2.4 节律基因 GO 富集分析	48
9.2.5 节律基因 KEGG 富集分析	49
9.3 参考文献.....	49
10 预测分泌蛋白分析.....	50
10.1 分析背景及方法介绍.....	50
10.2 结果展示.....	50
10.2.1 SignalP v4.1 预测结果.....	50
10.2.2 TMHMM v2.0 预测结果	51
10.2.3 TargetP v1.1 预测结果.....	51
10.3 参考文献.....	52
11 等位基因差异性表达（ASE）分析	53
11.1 分析背景及方法介绍.....	53
11.2 结果展示	53
11.2.1 等位基因偏向性分析	53
11.3 参考文献.....	54

12 基因表达偏向性分析.....	54
12.1 分析背景及方法介绍.....	54
12.2 结果展示.....	54
12.2.1 表达偏向性统计结果	54
12.2.2 表达偏向性分类基因明细	55
12.3 参考文献.....	56
13 lncRNA Rfam 家族分析	56
13.1 分析背景及方法介绍.....	56
13.2 结果展示.....	56
13.2.1 lncRNA 的 Rfam 注释结果.....	56
13.3 参考文献.....	57
14 内参基因分析.....	57
14.1 分析背景及方法介绍.....	57
14.2 结果展示.....	58
14.2.1 NormFinder 筛选出的内参基因	58
14.3 参考文献.....	58
15 密码子偏好性分析.....	58
15.1 分析背景及方法介绍.....	58
15.2 结果展示.....	60
15.2.1 密码子偏好性分析结果	60
15.3 参考文献.....	60

1 WGCNA 分析

1.1 分析背景及方法介绍

WGCNA(weighted geneco-expression network analysis)算法是一种构建基因共表达网络的典型系统生物学算法，该算法基于高通量的基因信使 RNA(mRNA)表达数据，被广泛应用于国际生物医学领域。WGCNA 算法首先假定基因网络服从无尺度分布，并定义基因共表达相关矩阵、基因网络形成的邻接函数，然后计算不同节点的相异系数，并据此构建分层聚类树(hierarchical clusteringtree)。该聚类树的不同分支代表不同的基因模块(module)，模块内基因共表达程度高，而分数不同模块的基因共表达程度低。最后，探索模块与特定表型或疾病的关联关系，以此达到鉴定目标的靶点基因、基因网络的目的。

由于 WGCNA 是基于相关系数的表达调控网络分析方法，当样本数过低的时候，相关系数的计算不可靠，得到的调控网络价值不大。所以，我们推荐的样本数如下：

当独立样本数 ≥ 8 （非重复样本）时，可以考虑基于 Pearson 相关系数的 WGCNA 共表达网络的方法（效果看实际情况而定）。

当样本数 ≥ 15 （可以包含生物学重复）时，WGCNA 方法会有更好的效果。

当样品数 < 8 时，不建议进行该项分析。

1.2 结果展示

1.2.1.模块层次聚类树




图 1.2.1 模块层次聚类树

此图是根据基因间表达量的相关性构建聚类树，并划分模块，不同的颜色代表不同的模块。

1.2.2 模块间相关性热图




图 1.2.2 模块间相关性热图

此图每一行和列代表一个模块，模块颜色越深（越红或越绿），相关性越强；模块颜色越浅，相关性越弱。

1.2.3 模块基因聚类热图





图 1.2.3 模块基因聚类热图

此图每一行和列代表一个基因，每个点的颜色越深，代表行和列对应的两个基因间的连通性越强。


1.2.4 模块基因表达图



1.2.4 模块基因表达图

此图表示模块特征值在不同样本中的表达模式。

1.2.5 样本表达模式热图



1.2.5 样本表达模式热图

此图横坐标为样本，纵坐标为模块，用模块特征值作图。红色代表高表达量，绿色代表低表达量。该图能直观反映各模块在各个样本中的表达模式。

1.2.6 Cytoscape 结果

fromNode	toNode	weight
evm.model.scaffold3.230	evm.model.scaffold73.188	0.053839248
evm.model.scaffold3.230	evm.model.scaffold190.1	0.021097413
evm.model.scaffold3.230	evm.model.scaffold137.42	0.049560525
evm.model.scaffold3.230	evm.model.scaffold118.3	0.022129998
evm.model.scaffold3.230	evm.model.scaffold103.39	0.0380439
evm.model.scaffold3.230	evm.model.scaffold179.17.3	0.038650399

表 1.2.6 Cytoscape 结果

此表中 CytoscapeInput.edge.txt 第一、二列相互作用的 geneID，第三列是基因间的互作系数，客户可根据此表中数据使用 Cytoscape 软件做相互作用关系图。

1.3 参考文献

【1】 Langfelder P, Horvath S. WGCNA: an R package for weighted correlation network analysis[J]. BMC Bioinformatics, 2008, 9(1): 559.

2 GSEA 分析

2.1 分析背景及方法介绍

基因集富集分析 (Gene Set Enrichment Analysis, GSEA) 的基本思想是使用预定义的基因集 (通常来自功能注释或先前实验的结果)，将基因按照在两类样本中的差异表达程度排序，然后检验预先设定的基因集合是否在这个排序表的顶端或者底端富集。基因集富集分析检测基因集合而不是单个基因的表达变化，因此可以包含这些细微的表达变化，预期得到更为理想的结果。

我们使用本地版 GSEA 分析工具 <http://www.broadinstitute.org/gsea/index.jsp>，通过 MSigDB 数据库预定义的数据集（物种仅限于人和小鼠）进行分析。GSEA 富集过程包括三个步骤：

1. 计算富集分数 (Enrichment Score) ；
2. 估计富集分数的显著性水平；
3. 矫正多重假设检验；

2.2 结果展示

2.2.1 GSEA 富集分析结果总概览

GSEA Report for Dataset OlavsV_fpkm

Enrichment in phenotype: Ola (2 samples)

- 34 / 50 gene sets are upregulated in phenotype **Ola**
- 18 gene sets are significant at FDR < 25%
- 8 gene sets are significantly enriched at nominal pvalue < 1%
- 14 gene sets are significantly enriched at nominal pvalue < 5%
- [Snapshot](#) of enrichment results
- Detailed [enrichment results in html](#) format
- Detailed [enrichment results in excel](#) format (tab delimited text)
- [Guide to](#) interpret results

Enrichment in phenotype: V (2 samples)

- 16 / 50 gene sets are upregulated in phenotype **V**
- 9 gene sets are significant at FDR < 25%
- 8 gene sets are significantly enriched at nominal pvalue < 1%
- 8 gene sets are significantly enriched at nominal pvalue < 5%
- [Snapshot](#) of enrichment results
- Detailed [enrichment results in html](#) format
- Detailed [enrichment results in excel](#) format (tab delimited text)
- [Guide to](#) interpret results

Dataset details

- The dataset has 31172 features (genes)
- No probe set => gene symbol collapsing was requested, so all 31172 features were used

Gene set details

- Gene set size filters (min=15, max=500) resulted in filtering out 0 / 50 gene sets
- The remaining 50 gene sets were used in the analysis
- List of [gene sets used and their sizes](#) (restricted to features in the specified dataset)

图 2.2.1 GSEA 富集分析结果总概览（见结果文件 index.html）

2.2.2 GSEA 富集结果




图 2.2.2 GSEA 富集结果

此图上半部分展示了基因的富集过程，最高点为富集得分（ES）。中间部分每条黑线代表一个基因，及其在基因列表中的排序位置。下半部分展示的是基因与表型关联的矩阵，红色为与第一个表型(Ola)正相关，在 Ola 中表达高，蓝色与第二个表型(V)正相关，在 V 中表达高。

2.2.3 GSEA 富集结果的详细信息展示

Table: GSEA details [plain text format]

	PROBE	DESCRIPTION (from dataset)	GENE SYMBOL	GENE_TITLE	RANK IN GENE LIST	RANK METRIC SCORE	RUNNING ES	CORE ENRICHMENT
1	CD82	ENSG00000085117			84	2.321	0.0211	Yes
2	PHLDA3	ENSG00000174307			98	2.283	0.0440	Yes
3	FDXR	ENSG00000161513			107	2.228	0.0666	Yes
4	NDRG1	ENSG00000104419			115	2.198	0.0889	Yes
5	CYFIP2	ENSG00000055163			117	2.192	0.1113	Yes
6	CDKN1A	ENSG00000124762			139	2.124	0.1323	Yes
7	BTG2	ENSG00000159388			180	2.021	0.1517	Yes
8	JUN	ENSG00000177606			235	1.846	0.1689	Yes
9	KRT17	ENSG00000128422			325	1.673	0.1832	Yes
10	LIF	ENSG00000128342			374	1.621	0.1982	Yes
11	PLK2	ENSG00000145632			420	1.575	0.2129	Yes
12	PDGFA	ENSG00000197461			493	1.513	0.2261	Yes
13	DDB2	ENSG00000134574			567	1.412	0.2382	Yes
14	SESN1	ENSG00000080546			689	1.321	0.2478	Yes

表 2.2.3 GSEA 富集结果的详细信息展示

第一列：基因名称

第二列：基因 ID

第五列：基因排名顺序。

第六列：基因排名得分。

第七列：计算出的 ES 值。

第八列：是否显著富集。

2.2.4 GSEA 富集基因热图




图 2.2.4 GSEA 富集基因热图

此图是基于显著富集基因在不同样本中的表达量做的聚类热图，红色表示高表达，蓝色表示低表达。

2.3 参考文献

【1】 Subramanian A, Tamayo P, Mootha V K, et al. From the Cover: Gene set enrichment analysis: A knowledge-based approach for interpreting genome-wide expression profiles[J]. Proceedings of the National Academy of Sciences of the United States of America, 2005, 102(43):15545.

3 STEM 分析

3.1 分析背景及方法介绍

在一个生物体内,不同细胞之间的 DNA 是相同的,那为什么会存在功能各异的组织呢?这主要是选择性表达导致的。选择性表达不仅体现在空间上,而且在生命过程各阶段都存在选择性表达的现象。捕捉这些不同发育阶段表达不同的基因,有助于我们了解生物体的发育过程,所以了解基因在不同时期的表达量至关重要。

我们使用 STEM 软件进行分析,STEM 是一个 Java 程序,用于聚类、比较和可视化短时间序列的基因表达数据(少于或等于 8 个时间点)。它是第一个专门为短时间序列微阵列基因表达数据分析而设计的软件程序,基于独特的方法来聚类、比较和可视化这些数据。我们只要输入基因在不同时间点的表达量,选取我们想要的聚类算法,就可以将我们的基因进行聚类。具有相同表达模式的基因会聚为一类,我们就可以根据感兴趣的基因表达模式找到一些感兴趣的基因,或者根据基因找到其表达趋势。

3.2 结果展示

3.2.1 STEM 分析出的基因表达模块




图 3.2.1 基因表达模块图

此图每个方框代表一个模块表达的轮廓图,有颜色的表示富集的基因的数目在统计学上有显著意义。

另外,点击此图中的每个方框可以详细展示每个 **profile** 的信息,如下图:

3.2.2 基因表达折线图




图 3.2.2 基因表达折线图

此图表示的是在不同时间点下的基因表达的情况 Profile #0:the model profile ID (0,-2,-3,-2):代表表达模式的向量。

另外，点击此图中的 Profile Gene Table，可以得到下表：

3.2.3 基因表达模式的向量明细

Gene Table for Profile 0							
Selected	Weight	geneID	SPOT	P3	P2	C	P1
	1.00	ENSG00000000971	ID_6	0.00	-1.37	-2.04	-1.92
	1.00	ENSG00000002587	ID_24	0.00	-4.55	-5.01	-3.79
	1.00	ENSG00000002745	ID_26	0.00	-1.75	-2.51	-1.55
	1.00	ENSG00000002746	ID_27	0.00	-1.75	-1.93	-1.21
	1.00	ENSG00000002933	ID_31	0.00	-2.63	-4.10	-1.77
	1.00	ENSG00000004799	ID_60	0.00	-4.79	-5.47	-3.41
	1.00	ENSG00000004848	ID_64	0.00	-4.54	-5.04	-5.76
	1.00	ENSG00000004939	ID_68	0.00	-2.91	-3.36	-3.34
	1.00	ENSG00000005020	ID_74	0.00	-1.10	-2.03	-1.39
	1.00	ENSG00000005486	ID_101	0.00	-3.52	-3.58	-4.11
	1.00	ENSG00000005844	ID_107	0.00	-3.89	-4.25	-2.47
	1.00	ENSG00000005961	ID_113	0.00	-3.42	-3.43	-2.34
	1.00	ENSG00000006555	ID_144	0.00	-3.00	-3.08	-2.91
	1.00	ENSG00000006715	ID_157	0.00	-1.54	-1.67	-1.67
	1.00	ENSG00000007062	ID_169	0.00	-1.08	-1.20	-1.13
	1.00	ENSG00000007174	ID_174	0.00	-1.63	-2.27	-1.92
	1.00	ENSG00000007255	ID_178	0.00	-1.97	-2.31	-2.59
	1.00	ENSG00000007264	ID_179	0.00	-3.17	-4.61	-2.82
	1.00	ENSG00000007944	ID_198	0.00	-1.00	-0.93	-0.88
	1.00	ENSG00000008311	ID_217	0.00	-2.72	-2.49	-2.54
	1.00	ENSG00000009790	ID_243	0.00	-1.78	-1.87	-1.38
	1.00	ENSG00000010278	ID_256	0.00	-0.77	-1.02	-0.62
	1.00	ENSG00000010295	ID_259	0.00	-1.57	-1.71	-1.26
	1.00	ENSG00000010327	ID_264	0.00	-2.01	-3.66	-1.16
	1.00	ENSG00000012124	ID_315	0.00	-1.40	-1.46	-1.62

Copy Table

Save Table

Copy Gene Names

Save Gene Names

Chromosome View

表 3.2.3 基因表达模式的向量明细

3.3 参考文献

【1】 Ziv B J, Jason E. STEM: a tool for the analysis of short time series gene expression data[J]. Bmc Bioinformatics, 2006, 7(1):191.

4 RNA 编辑分析

4.1 分析背景及方法介绍

RNA 编辑是指在 mRNA 水平上改变遗传信息的过程，是多种生命形式的遗传编码变异的重要来源。RNA 编辑的主要机制是前体 mRNA 分子中腺苷的去氨基，脱氨基的事件，即 A-to-I 编辑，将特殊的腺苷（A）转换为肌苷（I）。在翻译中，肌苷被解码为鸟苷（G），从而导致密码子的变化，往往会引起蛋白质产物中的氨基酸替换。

我们使用 REDIttools 软件进行 RNA 编辑位点的鉴定，并基于此结果进行多样品编辑位点信息的整合，各样品变异位点编辑水平的比较，RNA 编辑位点类型的分布，RNA 编辑位点在染色体上的分布，RNA 编辑簇的鉴定，A->I 编辑位点的鉴定，RNA 编辑位点有义突变和无义突变的鉴定等分析。

此分析需构建链特异性文库，可以更好的区分正负链的编辑信息，并且最好联合样本的 DNA 重测序数据进行校正，可大幅度降低编辑位点的假阳性，提高鉴定结果的准确性。

4.2 结果展示

4.2.1 RNA 编辑位点鉴定

我们使用主流的 REDIttools 软件进行 RNA 编辑位点的鉴定。鉴定结果如下：

Region	Position	Reference	Strand	Coverage-q25	MeanQ	BaseCount[A,C,G,T]
GL892783.2	4690	A	0	38	38.89	[32, 0, 6, 0]
GL896000.1	7174	C	0	56	40.05	[0, 23, 33, 0]
GL896000.1	16580	G	0	91	40.58	[0, 0, 41, 50]
JH118443.1	104001	T	0	19	38.95	[19, 0, 0, 0]
JH118445.1	47935	G	1	27	39.78	[27, 0, 0, 0]
JH118445.1	47941	G	1	27	40	[11, 0, 16, 0]

因表格太多列，做了表格拆分，横列接上表

AllSubs	Frequency	gCoverage-q25	gMeanQ	gBaseCount[A,C,G,T]	gAllSubs	gFrequency
AG	0.16	-	-	-	-	-
CG	0.59	15	41	[0, 7, 8, 0]	CG	0.53
GT	0.55	35	39.86	[0, 0, 18, 17]	GT	0.49
TA	1	15	39	[15, 0, 0, 0]	TA	1
GA	1	16	39.06	[16, 0, 0, 0]	GA	1
GA	0.41	16	39.31	[7, 0, 9, 0]	GA	0.44

表 4.2.1 RNA 编辑位点鉴定

Region: RNA editing 位点所在染色体。

Position: RNA editing 位点坐标。

Reference: 参考序列在该位点的坐标。

Strand: 参考序列在该位点的链方向, 0 表示 '+', 1 表示 '-', 2 表示未知。

Coverage-q25: 该位点的碱基覆盖度(质量值 ≥ 25)。

MeanQ: 该位点上所有碱基的 Qpred 的均值。

BaseCount[A,C,G,T]: 依次为 A,C,G,T 类型的碱基在该位点的 reads 数, 用逗号隔开。

AllSubs: RNA editing 类型, '-' 表示未发生 RNA editing。

Frequency: 发生 RNA editing 的频率。

gCoverage-q25: DNA 数据, 该位点的碱基覆盖度(质量值 ≥ 25)。

gMeanQ: DNA 数据, 该位点上所有碱基的 Qpred 的均值。

gBaseCount[A,C,G,T]: DNA 数据, 依次为 A,C,G,T 类型的碱基在该位点的 reads 数, 用逗号隔开。

gAllSubs: DNA 数据, 突变类型, '-' 表示未发生突变。

gFrequency: DNA 数据, 发生突变的频率。

4.2.2 编辑位点在染色体上的分布

我们将参考基因组的每条染色体按照 100000bp 为一个单位进行均分 (不足 100000bp 按照实际长度统计), 统计每个 bin 内的 RNA 编辑位点数目。




图 4.2.2 编辑位点在染色体上的分布

此图中柱状图的高度代表该bin内的RNA编辑位点数目,最内圈为负链上鉴定出的RNA编辑位点在染色体上的分布信息,中间圈代表的是正链上鉴定出的RNA编辑位点在染色体上的分布信息,最外边的一圈代表不区分正负链,总体上鉴定出的RNA编辑位点在染色体上的分布信息。

4.2.3 RNA 编辑类型分布




图 4.2.3 RNA 编辑类型分布

此图横坐标代表不同的编辑类型，纵坐标代表发生该编辑类型位点的个数，每个样品会提供三张图，分别是正链，负链，总的编辑类型分布。

4.2.4 RNA 编辑类型堆积柱状图




图 4.2.4 RNA 编辑类型堆积柱状图

此图横坐标代表不同样品，纵坐标代表不同编辑类型的个数。

4.2.5 RNA 编辑位点在基因不同功能域的分布




图 4.2.5 编辑位点在基因不同功能域的分布

此图横坐标代表基因不同功能域，纵坐标代表不同功能域的编辑位点个数。

4.2.6 编辑位点在不同功能域的堆积柱状图




图 4.2.6 编辑位点在不同功能域的堆积柱状图

此图横坐标代表不同样品，纵坐标代表不同的基因功能域中编辑类型的个数。

4.2.7 编辑位点引起的有义突变与无义突变分析

Mutation type	Gene:transcript:exon:base:aa	chrom	Start	End	REF	ALT
nonsynonymous SNV	ENSSSCG00000004038:ENSSSCT00000004466:exon16:c.A1972C:p.K658Q,	1	8778416	8778416	A	C
nonsynonymous SNV	ENSSSCG00000028867:ENSSSCT00000024741:exon11:c.A1015G:p.S339G,	1	18733884	18733884	A	G
nonsynonymous SNV	ENSSSCG00000028867:ENSSSCT00000024741:exon11:c.G1016A:p.S339N,	1	18733885	18733885	G	A
synonymous	ENSSSCG00000004313:ENSSSCT00000004768:exon3:c.G315A:p.S10	1	63804245	6380424	G	A

SNV	5S,			5		
-----	-----	--	--	---	--	--

因表格太多列，做了表格拆分，横列接上表。

Strand	Edit type	Coverage-DNA	Coverage-RNA	Edit level	Codon variation type
+	A->C	11,0,0,0	3,6,0,0	4.62816777e-16*	ENSSSCT000000004466:AAG->CAG
+	A->G	23,0,0,0	0,0,36,0	4.99095477e-107*	ENSSSCT000000024741:AGT->GGT
+	G->A	0,0,25,0	35,0,0,0	4.89261084e-104*	ENSSSCT000000024741:AGT->AAT
+	G->A	0,0,14,0	26,0,17,0	1.31473611e-65*	ENSSSCT000000004768:TCG->TCA

表 4.2.7 编辑位点引起的有义突变与无义突变分析

注：该项分析是针对于 **exon** 上的编辑位点进行分析

第一列： 突变类型，一般分为 5 种： **synonymous**， **nonsynonymous**， **stopgain**， **stoploss** 和 **unknown**,分别对应：同义突变，非同义突变，突变获得性终止密码子，突变缺失终止密码子，不可判定类型（原因是由于基因组结构注释不完整导致的未知功能位点）。

第二列： **gene:transcript:exon:base:aa** 该列为突变情况的详细说明，包括突变位点的 **gene ID**，转录本 ID，外显子位置，碱基突变类型和氨基酸突变类型；其中碱基突变类型：**c.A186G**:表示：指该基因的 186 位的碱基 A 突变为 G,相同的 **p.G62G**:指第 62 位的甘氨酸突变为甘氨酸，即同义突变。

第三列：染色体。

第四列：突变发生的起始位置。

第五列：突变发生的终止位置。

第六列：参考基因组该位点的碱基。

第七列：该位点发生突变后的碱基。

第八列：正负链。

第九列：编辑类型。

第十列： DNA 数据，该位点的碱基覆盖度。

第十一列： RNA 数据，该位点的碱基覆盖度。

第十二列：编辑水平。

第十三列：密码子变化类型。

4.2.8 编辑簇分析

我们通过编辑簇分析可以查找到染色体编辑位点相对集中的区域。编辑簇鉴定方法：编辑簇内 RNA 编辑位点的最小数目为 5；相邻编辑簇的最低距离为 50bp；编辑簇最小长度为 20bp。

Chrom	edit box	edit site in box
1	34436936--34437013	34436936,34436943,34436944,34436977,34437013
1	39468190--39468371	39468190,39468197,39468214,39468226,39468238,39468274,39468292,39468310,39468323,39468348,39468371
1	75141908--75142038	75141908,75141932,75141939,75141956,75141957,75141980,75141985,75142017,75142038
1	105556331--105556429	105556331,105556342,105556361,105556362,105556407,105556410,105556429
1	106527330--106527443	106527330,106527366,106527379,106527400,106527412,106527423,106527442,106527443
1	132678291--132678363	132678291,132678337,132678350,132678362,132678363

表 4.2.8 编辑簇分析

第一列：染色体。

第二列：编辑簇区间。

第三列：编辑簇内的编辑位点。

4.2.9 不同样品中编辑位点的韦恩图




图 4.2.9 不同样品编辑位点韦恩图

此图中每个圆圈代表不同样本中的编辑位点个数，中间的交集为样品间共有的编辑位点数目。

4.2.10 不同样品中 RNA 编辑水平的聚类分析




图 4.2.10 不同样品中 RNA 编辑水平的聚类分析

此图横向代表不同的样本，基于 RNA 编辑水平的高低进行的聚类做图，黄色表示编辑水平较高，黑色表示编辑水平较低。

4.2.11 A-I 编辑位点的鉴定

一般认为在三个样品以上某个位点均发生了 A->I 的变化，认为该位点有 A->I 的 RNA 编辑事件发生。我们将为客户提供所有 A->I 编辑的位点。

Chromosome	Position	Strand	Edit type&numbers
1	105574403	-	AG,AG,AG,AG,AG
1	115118113	-	AG,AG,AG,AG,AG
1	120110940	+	AG,AG,AG
1	120226893	-	AG,AG,AG

1	120227712	-	AG,AG,AG
1	121965628	-	AG,AG,AG

表 4.2.11 A-I 编辑位点的鉴定

- 第一列：染色体。
- 第二列：编辑位点。
- 第三列：正负链信息。
- 第四列：编辑类型，及出现的次数（均为 AG）。

4.2.12 编辑位点保守性分析

我们选取编辑位点前后各 5bp，共计 11bp 进行序列保守性分析。




图 4.2.12.1 编辑位点保守性分析

另外，对于 A->I 编辑类型，我们选取未发生 RNA 编辑的 A 位点作为对照，进一步探索 A->I 编辑位点的临近序列特征。




图 4.2.12.2 编辑位点保守性分析

此图上部分序列特征为 A->I 编辑位点周边序列环境特征，下部分序列为非编辑 A 位点周边序列环境特征。

4.2.13 GO 富集分析

我们对在 exon 区间含有编辑位点的基因进行 GO 富集分析。结果如下表所示：

GO accession	Description	Term type	Over represented p-Value	Corrected p-Value	DEG item	DEG list
GO:1903561	extracellular vesicle	cellular_component	9.0287e-85	1.1892e-80	915	8690
GO:0043230	extracellular organelle	cellular_component	1.2774e-84	1.1892e-80	916	8690
GO:0065010	extracellular membrane-bounded organelle	cellular_component	2.825e-84	1.7532e-80	908	8690
GO:0070062	extracellular exosome	cellular_component	5.4733e-84	2.5475e-80	907	8690

表 4.2.13.1 GO 富集列表

(1) GO accession： Gene Ontology 数据库中唯一的标号信息。

(2) Description： Gene Ontology 功能的描述信息。

(3) Term type: 该 GO 的类别(cellular_component: 细胞组分; biological_process: 生物学过程; molecular_function: 分子功能)。


(4) Over represented p-Value: 富集分析统计学显著水平。

(5) Corrected p-Value: 矫正后的 P-Value, 一般情况下, $\text{Corrected_pValue} < 0.05$ 该功能为富集项。

(6) DEG item: 与该 GO 相关的基因的数目。

(7) DEG list: GO 注释的基因数目。

上述列表后, 统计被显著富集的各个 GO term 中的基因数, 以柱状图的形式展示。



4.2.13.2 GO 富集柱状图

此图纵坐标为富集的 GO term, 横坐标为该 term 中基因个数。不同颜色用来区分生物学过程、细胞组分和分子功能, 带“*”为显著富集的 GO term。




图 4.2.13.3 GO 富集有向无环图

每个节点代表一个 GO 术语，方框代表的是富集程度为 TOP10 的 GO，颜色的深浅代表富集程度，颜色越深就表示富集程度越高，每个节点上展示了该 TERM 的名称及富集分析的 CORRECTED P-VALUE。

4.2.14 KEGG 富集分析

我们对在 exon 区间含有编辑位点的基因进行 KEGG 富集分析。结果如下表所示：

#Term	Database	ID	Sample number	Background number	P-Value	Corrected P-Value
Metabolic pathways	KEGG	ssc01100	770	1166	1.01963364868e-08	2.79379619739e-06
Retinol metabolism	KEGG	ssc00830	54	54	0.000371473789845	0.0366226268339
Complement and	KEGG	ssc04610	67	73	0.000400977666065	0.0366226268339

coagulation cascades						
Peroxisome	KEGG	ssc04146	70	80	0.000737422426016	0.0484083461065

表 4.2.14.1 KEGG 富集列表

- (1) #Term: KEGG 通路的描述信息。
- (2) Database: KEGG 数据库。
- (3) ID: KEGG 数据库中通路唯一的编号信息。
- (4) Sample number: 该通路下基因的个数。
- (5) Background number: 该通路下注释基因的个数。
- (6) P-value: 富集分析统计学显著水平。
- (7) Corrected P-value: 矫正后的统计学显著水平，Corrected P-value < 0.05 该功能为富集项。




图 4.2.14.2 KEGG 富集散点图

此图纵轴表示 pathway 名称，横轴表示 Rich factor，点的大小表示此 pathway 中候选靶基因个数多少，而点的颜色对应于不同的 qvalue 范围。




图 4.2.14.3 显著富集的 KEGG pathway 代谢通路图

其中的小方框代表蛋白，红色的小方框代表基因对应的蛋白，鼠标悬停于该节点，会弹出相应的靶基因 id。以上步骤可脱机实现，如连接互联网，点击各个节点，可以连接到 KEGG 官方数据库中各个 KO 的具体信息页。

4.3 参考文献

- 【1】 Chen J Y, Peng Z, Zhang R, et al. RNA Editome in Rhesus Macaque Shaped by Purifying Selection[J]. Plos Genetics, 2014, 10(4):e1004274.
- 【2】 Zhu S, Xiang J F, Tian C, et al. Prediction of constitutive A-to-I editing sites from human transcriptomes in the absence of genomic sequences[J]. BMC Genomics, 2013, 14(1):206.

5 个性化热图绘制

5.1 多样品差异基因热图分析

在多阶段性或者多时期样品比对分析项目中，客户做了多阶段样品间两两样品间的差异比对分析，此热图可以直观展示多样品两两比较间的上调下调基因个数，可以间接展示各样品间的差异变化。




图 5.1 多样品差异基因热图分析

此图颜色越深，代表差异基因越多，蓝色表示下调差异基因个数，红色表示上调差异基因个数。如图所示，stage1vs stage8，可以看出上调基因有 1972 个，下调基因个数 4729 个。

参考文献：

Letunic I, Yamada T, Kanehisa M, et al. iPath: interactive exploration of biochemical pathways and networks[J]. Trends in Biochemical Sciences, 2008, 33(3):101.

5.2 展示横纵向标签的热图




图 5.2 展示横纵向标签的热图

此图根据基因在不同样本中的表达量做聚类，并在横纵轴进行了标签分类标记，横轴表示不同的样本分类，纵轴表示不同的代谢途径。

6 个性化 Circos 图绘制

6.1 差异基因在染色体上的分布图




图 6.1 差异基因在染色体上的分布图

此图展示差异基因在染色体分布的 circos 图，绿色为下调差异基因，红色为上调差异基因，并在图中标记了重要基因的名称。

6.2 多信息数据可视化 circos 图





图 6.2 多信息数据可视化 circos 图

此图为多个分析数据可视化的展示 circos 图，从外向内方向，第一圈：染色体位置，第二圈：外层为基于原注释文件的基因分布，内层为基于含新基因注释文件的基因分布，第三圈：外层为基于原注释文件的转录本分布，内层为基于含新基因注释文件的转录本分布，第四圈：AS 分布，第五圈：lncRNA 分布，第六圈：融合基因分布，黑色线代表 intra-chromosome，橘黄色线代表 inter-chromosome。

7.1 分析背景及方法介绍

数据库包括：KEGG orthology、Gene Ontology、Reactome hierarchy；工具链接为

7.2 结果展示



此图展示的是 KEGG 第三层级的结果，每个 cell 颜色对应该 term 注释的基因的表达量的平均值，红色表示高表达，蓝色表示低表达。在交互模式下，双击每个 cell 会弹出对应基因集热图。

7.3 参考文献

【1】 Santamaría R, Pierre P. Voronto: mapper for expression data to ontologies[J]. Bioinformatics, 2012, 28(17):2281-2282.

8 iPath 分析

8.1 分析背景及方法介绍

iPath(Interactive Pathways Explorer) (<http://pathways.embl.de>)是一个网页版的通路图可视化分析软件。iPath3.0 可提供 3 种不同通路的概括图:代谢通路、调控通路以及生物合成和次生代谢通路。其中，代谢通路属于第一层级 **Metabolism** 大类。代谢通路图中的节点对应各种化合物，边代表一系列的酶类反应。对多个样品来说，通过对它们的代谢途径进行比较与分析，找出它们的共性和特性，特别是对它们特殊代谢途径的分析，能够为进一步深入研究和利用样品的功能提供理论依据。

我们根据 KEGG PATHWAY 数据库的注释结果，提取多个样品功能类—新陈代谢(Metabolism)相关的KOs(KEGG orthologous groups)，然后计算每个 KOs 在每个样品中的丰度，根据丰度大小来确定对应代谢途径所表示的边的颜色以及宽度。

8.2 结果展示

8.2.1 提取 KOs 结果

KO ID	Width	Color
gga:101750307	W25.0	#FF0000
gga:101750439	W15.0	#00FF00
gga:101750781	W25.0	#FF0000
gga:101750818	W5.0	#FF0000
gga:101750922	W25.0	#FF0000
gga:101751202	W25.0	#FF0000
gga:101751526	W25.0	#FF0000

表 8.2.1 提取 KOs 结果

第一列：代表 KO 的编号。

第二列：代表其在 KEGG 通路中的显示宽度。

第三列：代表显示颜色。

8.2.2 多样品代谢通路比较分析图

将提取 KOs 结果导入 iPath 可得到代谢通路图,在 iPath 网站中用户可进行一系列放大,查找等基本操作,更多详细信息可参考官方帮助文档:<http://pathways.embl.de/help.html>。




图 8.2.2 多样品代谢通路比较分析图

8.3 参考文献

【1】 Letunic I, Yamada T, Kanehisa M, et al. iPath: interactive exploration of biochemical pathways and networks[J]. Trends in Biochemical Sciences, 2008, 33(3):101.

【2】 Yamada T, Letunic I, Okuda S, et al. iPath2.0: interactive pathway explorer[J]. Nucleic Acids Research, 2011, 39(Web Server issue):W412.

9.节律基因分析

9.1 分析背景及方法介绍

周期性的过程在生物体内广泛存在，如昼夜节律与细胞周期，识别具有周期性表达的基因是研究这些过程及发现受其调控的其他生物学过程的关键。周期性识别算法有 COSOPOT，Fisher's G-test，JTK_CYCLE,ARSER，LSPR 等，我们选用主流的 COSOPOT 软件预测节律基因，并对节律基因进行数据库注释（KOG,NR,eggNOG,GO,KEGG 注释等）和聚类富集分析（GO,KEGG）。此分析适用于具有不同时间点或周期性的实验设定，一般要求时间点在 6 个以上。

9.2 结果展示

9.2.1 节律基因的筛选结果

GeneID	Gene symbol	sample1	Sample2	Sample40	Fold Change
ENSMUSG00000041750	Cd1d2	0.135833	0.0642468	0	INF
ENSMUSG00000024121	Atp6v0c	179.5736757	212.7346532	230.252193	1.293445804
ENSMUSG00000053559	Smagp	38.77651	23.793014	14.937901	2.595847301

因表格太多列，做了表格拆分，横列接上表。

MeanExpLev	Period	Phase	Beta	pMMC-Beta	pMMC-Beta<0.2	MIN FPKM>0.1	Circadian genes or not
6.45E-02	2.42E+01	0.00E+00	7.96E-02	3.19E-03	yes	no	no
2.09E+02	2.42E+01	1.21E+01	2.78E+01	3.27E-03	yes	yes	yes
2.56E+01	2.43E+01	2.43E-01	1.34E+01	3.32E-03	yes	yes	yes

表 9.2.1 节律基因的筛选结果

- 第一列 ID：基因 ID。
- 第二列 Gene symbol :基因名称。
- 第三-五列 Sample：样品表达量。
- 第六列 Fold Change:组内表达量平均值的最高表达量/组内表达量平均值的最低表达量。
- 第七列 MeanExpLev：平均表达值。
- 第八列 pMMC-Beta：筛选阈值,一般选择 pMMC-Beta <0.2。
- 第九列 pMMC-Beta<0.2：筛选出阈值小于 0.2 的基因。
- 第十列 MIN FPKM>0.1：所有样本的表达量至少大于 0.1。
- 第十一列 Circadian genes or not：是否是候选的节律基因。

9.2.2 节律基因的注释结果

Gene ID	GO_annotation	KEGG_annotation	KEGG_pathway_anno tation	KOG_class	KOG_class_an notation
ENSMUSG00000004 1750	Biological Process: positive regulation of T cell mediated cytotoxicity (GO:0001916)	K06448 0 mmu:12479 Cd1d1, A1747460, CD1.1, Cd1a, Cd1d, Ly-38	Hematopoietic cell lineage (ko04640)	--	--
ENSMUSG00000002 4121	Cellular Component: lysosome (GO:0005764)	K02155 1.15313e-84 rno:170667 Atp6v0c, Atp6c, Atp6f	Oxidative phosphorylation (ko00190)	[C]	Energy production and conversion

ENSMUSG00000005	Cellular Component:	--	--	--	--
3559	nucleolus (GO:0005730);				

因表格太多列，做了表格拆分，横列接上表。

Pfam_annotation	Swiss-Prot_annotation	eggNOG_class	eggNOG_class_annotation	NR_annotation
Immunoglobulin C1-set domain	Antigen-presenting glycoprotein CD1d2	R	General function prediction only	antigen-presenting glycoprotein CD1d2 precursor [Mus musculus]
ATP synthase subunit C	V-type proton ATPase 16 kDa proteolipid	C	Energy production and conversion	mCG22073 [Mus musculus]
--	Small cell adhesion glycoprotein	S	Function unknown	cDNA sequence BC004728 [Mus musculus]

9.2.2 节律基因的注释结果

- 第一列：基因 ID。
- 第二列：GO 注释。
- 第三列：KEGG 注释。
- 第四列：KEGG 通路注释。
- 第五列：KOG 分类。
- 第六列：KOG 分类注释。
- 第七列：Pfam 注释。
- 第八列：Swiss-Prot 注释。
- 第九列：eggNOG 分类。
- 第十列：eggNOG 分类注释。
- 第十一列：NR 注释。

9.2.3 节律基因聚类分析




图 9.2.3 节律基因聚类分析热图

此图横轴代表不同的样本，纵轴表示不同的节律基因，颜色的深浅代表基因的表达量 $\log_{10}(\text{FPKM}+1)$ 高低。

9.2.4 节律基因 GO 富集分析

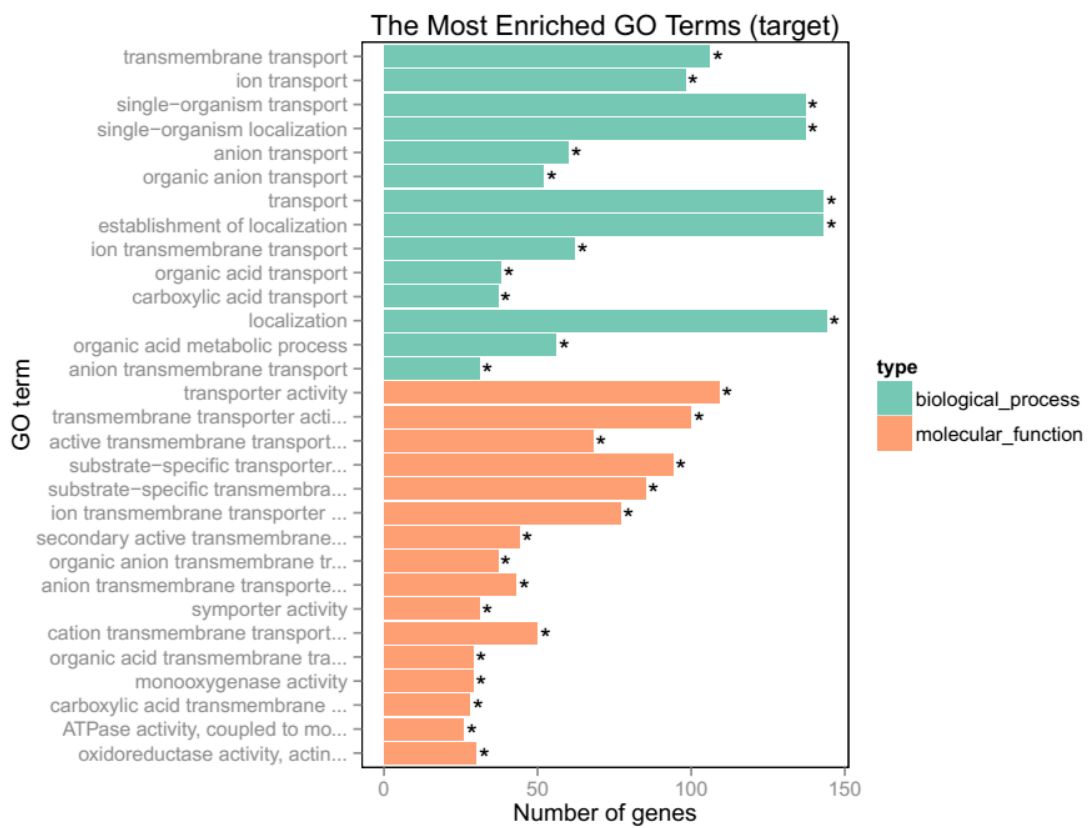


图 9.2.4 GO 富集柱状图

此图纵坐标为富集的 GO term，横坐标为该 term 中基因个数。不同颜色用来区分生物过程、细胞组分和分子功能，带“*”为显著富集的 GO term。

9.2.5 节律基因 KEGG 富集分析




图 9.2.5 KEGG 富集散点图

此图纵轴表示 pathway 名称，横轴表示 Rich factor，点的大小表示此 pathway 中候选靶基因个数多少，而点的颜色对应于不同的 qvalue 范围。

9.3 参考文献

【1】Straume M. DNA microarray time series analysis: automated statistical assessment of circadian rhythms in gene expression patterning[J]. Methods in Enzymology, 2004, 383(2):149.

10 预测分泌蛋白分析

10.1 分析背景及方法介绍

分泌蛋白是指在细胞内合成后，分泌到细胞外起作用的蛋白质。其特点主要有：含有 N 端信号肽，无跨膜结构域，无 GPI 锚定位点，没有将蛋白输送到线粒体或其他胞内细胞器。

对于无参项目需先对 Unigene 用 TransDecoderv3.0.1 进行 unigene 的全长 ORF 预测,然后对 complete.pep 预测分泌蛋白,有参考基因组项目直接下载蛋白序列，然后使用 SignalP v4.1 进行信号肽鉴定，获得分泌蛋白序列，再通过 TMHMM v2.0 进行跨膜结构域分析，将不跨膜及单跨膜初步推断为分泌蛋白,最后用 TargetP v1.1 预测真核蛋白的亚细胞定位,筛选 LOC 为 S 的作为最终分泌蛋白。

10.2 结果展示

10.2.1 SignalP v4.1 预测结果

# Measure	Position	Value	Cutoff	signal peptide?
max. C	56	0.113		
max. Y	56	0.106		
max. S	23	0.117		
mean S	1-55	0.098		
D	1-55	0.101	0.450	NO
Name=Gene.138645::Cluster-100.0::g.138645::m.138645				

表 10.2.1 SignalP v4.1 预测结果

C-score: raw cleavage site score

S-score: signal peptide score

Y-score: combined cleavage site score

D-Score: discrimination score

mean S: The average S-score of the possible signal peptide (from position 1 to the position immediately before the maximal Y-score)

10.2.2 TMHMM v2.0 预测结果

Gene.113457::Cluster-16046.18247::g.113457::m.113457 Length: 384
Gene.113457::Cluster-16046.18247::g.113457::m.113457 Number of predicted TMHs: 0
Gene.113457::Cluster-16046.18247::g.113457::m.113457 Exp number of AAs in TMHs: 10.48217
Gene.113457::Cluster-16046.18247::g.113457::m.113457 Exp number, first 60 AAs: 0.03979
Gene.113457::Cluster-16046.18247::g.113457::m.113457 Total prob of N-in: 0.29189
Gene.113457::Cluster-16046.18247::g.113457::m.113457

表 10.2.2 TMHMM v2.0 预测结果

第一行 Length: 蛋白长度。

第二行 Number of predicted TMHs: 预测 transmembrane helices 数量。

第三行 Exp number of AAs in TMHs: 在 TMHs 中 AA 的数量，一般>18 可能为 transmembrane protein 或有信号肽。

第四行 Exp number, first 60 AAs: The expected number of amino acids in transmembrane helices in the first 60 amino acids of the protein。

10.2.3 TargetP v1.1 预测结果

Name	Len	mTP	SP	other	Loc	RC
Gene.113652::Cluster-16046.39476::g.113652::m.113652	262	0.024	0.962	0.059	S	1
Gene.61144::Cluster-16046.58501::g.61144::m.61144	175	0.019	0.96	0.05	S	1
Gene.143839::Cluster-16046.67724::g.143839::m.143839	287	0.029	0.94	0.062	S	1
Gene.97411::Cluster-16046.81299::g.97411::m.97411	113	0.045	0.881	0.094	S	2
Gene.71563::Cluster-16046.44972::g.71563::m.71563	273	0.052	0.927	0.032	S	1
Gene.8982::Cluster-9386.0::g.8982::m.8982	132	0.05	0.891	0.153	S	2

表 10.2.3 TargetP v1.1 预测结果

第一列 Name:基因 ID。

第二列 Len:长度。

第三，四，五列 mTP,SP,other:Final NN scores on which the final prediction is based (Loc, see below). Note that the scores are not really probabilities, and they do not necessarily add to one. However, the location with the highest score is the most likely according to TargetP, and the relationship between the scores (the reliability class, see below) may be an indication of how certain the prediction is。

第五列 Loc:C Chloroplast, i.e. the sequence contains cTP, a chloroplast transit peptide;

M Mitochondrion, i.e. the sequence contains mTP, a mitochondrial targeting peptide;

S Secretory pathway, i.e. the sequence contains SP, a signal peptide;

_ Any other location;

第六列 RC:Reliability class, from 1 to 5, where 1 indicates the strongest prediction. RC is a measure of the size of the difference ('diff') between the highest (winning) and the second highest output scores. There are 5 reliability classes, defined as follows。

10.3 参考文献

【1】 Liu J J, Sturrock R N, Snieszko R A, et al. Transcriptome analysis of the white pine blister rust pathogen *Cronartium ribicola* : de novo assembly, expression profiling, and identification of candidate effectors[J]. *Bmc Genomics*, 2015, 16(1):678.

11 等位基因差异性表达（ASE）分析

11.1 分析背景及方法介绍

等位基因（allele 又作 allelomorph）一般指位于一对同源染色体的相同位置上控制着相对性状的一对基因。其在生物体内普遍存在差异性表达的现象。我们利用转录组测序数据鉴定的 SNP 结果，通过一系列筛选和标准化处理，最终鉴定出偏向性的结果。

此分析需要测序样本有亲代与子代信息。

11.2 结果展示

11.2.1 等位基因偏向性分析

gene_id	DY_6h_snp.gene.nor malized(TW_6h)	DY_6h_snp.gene.nor malized(JP_6h)	pvalue	qvalue	signature	bias	Description
evm.model.1	313,588.4	274,417.3	3.57E-20	3.62E-19	TRUE	TW_6h	-/-
evm.model.2	12,28.0	14,42.5	0.01659	0.02706	TRUE	JP_6h	-/-
evm.model.3	16,24.3	13,43.9	0.2682	0.3245	FALSE	None	sp Q6AY55 D CAKD_RAT
evm.model.4	68,82.8	15,100.2	0.2885	0.3464	FALSE	None	sp Q91ZN5 S3 5B2_MOUSE
evm.model.5	57,29.2	25,166.1	0.003353	0.006133	TRUE	TW_6h	sp Q9H0J9 PA R12_HUMAN

表 11.2.1 等位基因偏向性分析结果

- 第一列：基因 ID。
- 第二-三列：子代（父本/母本）标准化后的 reads 数，以逗号分隔。
- 第四列：二项分布检验计算的 pvalue 值。
- 第五列：利用 BenjaminiandHochberg 的方法（简称 BH 法）计算的 qvalue 值。

第六列：偏向性指标，FALSE 为不具有偏向性，TRUE 为具有偏向性（阈值 $pvalue < 0.05$ ）。

第七列：偏向性的亲本信息，none 为非偏向性表达。

第八列：基因注释信息。

11.3 参考文献

【1】刁西洲. 玉米穗部性状遗传和杂种优势分析及雌穗发育杂种优势转录组分析[D]. 中国农业科学院, 2015.

【2】翟荣荣. 超级稻协优 9308 根系杂种优势的转录组分析[D]. 中国农业科学院, 2013.

12 基因表达偏向性分析

12.1 分析背景及方法介绍

杂交优势指具有不同遗传型的物种经过杂交，其后代的某些性状如生长速度、生活力、繁殖率、抗逆性和产量等优于亲本的现象。对于杂交项目，往往会分析杂交种中和亲本中出现的表达偏向性，以下方法是基于亲本之间以及 F1 代与亲本之间的差异分析的结果，对杂交 F1 代的基因进行表达偏向分类分析。

12.2 结果展示

12.2.1 表达偏向性统计结果

Classification	Expression in parental	Expression in progeny	in F1
parental condition	A=C	A=C	15450
	A>C	A>C	1282
	C>A	C>A	1712
no bias in hybrid	A>C	A=C	2366
	C>A	C=A	2574

novel bias in hybrid	A=C	A>C	1166
	A=C	A<C	1144
	A>C	A<C	94
	A<C	A>C	95

表 12.2.1 表达偏向性统计结果

Classification: 表达偏向性分类

parental condition: F1 代与亲本的表达方式一致的基因数量

no bias in hybrid: F1 代表达无差异，但亲本表达有差异的基因数量

novel bias in hybrid: 亲本无表达偏向，F1 代有表达偏向的基因，以及 F1 代表达偏向于亲本表达偏向相反的基因数量

expression in parental: 根据父本 vs 母本差异分析的结果分类，其中 A 代表母本，C 代表父本；A=C 为父本 vs 母本无差异；A>C 为父本 vs 母本下调；C>A 为上调

expression in progeny: 根据 F1 代分别与父本，母本差异分析的结果分类，A=C 为 F1 代表达不偏向于父本也不偏向于母本；A>C 为 F1 代表达偏向于母本；C>A 为 F1 代表达偏向于父本

12.2.2 表达偏向性分类基因明细

Gene_id	readcount_CC	readcount_AA	log2FoldChange	pval	padj	significant
evm.TU.BraA01000013	0	0	NA	NA	NA	FALSE
evm.TU.BraA01000016	622.5369922	643.402368	-0.047562	0.922	0.988	FALSE

因表格太多列，做了表格拆分，横列接上表。

readcount_AACC_CC1	readcount_AACC_AA1	log2FoldChange	pval	padj	significant
0.295517975	0.309091417	-0.064788	1	1	FALSE
359.3837998	382.0701415	-0.088312	0.76606	1	FALSE

表 12.2.2 表达偏向性分类基因明细

Gene_id: 基因 id。

readcount_CC: 父本矫正后的 readcount 值。

readcount_AA: 母本矫正后的 readcount 值。

log2FoldChange: $\log_2(\text{Sample1}/\text{Sample2})$ 。

pvalue(pval): 统计学差异显著性检验指标。

qvalue(padj): 校正后的 pvalue; qvalue 越小, 表示基因表达差异越显著。

significant: 差异显著性, 非差异基因为 FALSE, 上调基因为 UP, 下调基因为 DOWN。

12.3 参考文献

【1】 Yoo M J, Szadkowski E, Wendel J F. Homoeolog expression bias and expression level dominance in allopolyploid cotton[J]. Heredity, 2013, 110(2):171-180.

13 lncRNA Rfam 家族分析

13.1 分析背景及方法介绍

lncRNA 可能是一些 sRNA 前体, 为预测来源于 lncRNA 的 sRNA 的信息, 我们使用了 Rfam 数据库来对 lncRNA 序列进行 sRNA 前体预测。Rfam 是代表非编码 RNA 家族的多重序列比对和协方差模型的一个收集。使用软件 `infernal 1.02` 中自带的 `cmsearch` 工具以及 `rfamscan` 可以对 lncRNA 进行家族分析, 以期得到部分 lncRNA 可能的 Rfam 家族分类信息。

13.2 结果展示

13.2.1 lncRNA 的 Rfam 注释结果

lncRNA_id	source	start	end	strand	Evalue	rfam-acc	rfam-id
LNC_000163	Rfam	1	110	-	7.66e-38	RF02002	mir
LNC_000011	Rfam	1	71	+	2.79e-34	RF00005	tRNA

表 13.2.1 lncRNA 的 Rfam 注释结果

LncRNA_ID：用于预测的 lncRNA id。

source：用于比对的 Rfam 数据库。

start：比对到 lncRNA 的起始位置。

end：比对到 lncRNA 的终止位置。

strand：比对到的正负链信息。

Evalue：比对上的 e 值。

rfam-acc：Rfam 数据库的编号。

rfam-id：Rfam 数据库 id。

13.3 参考文献

【1】Nawrocki E P. Annotating functional RNAs in genomes using Infernal[J]. Methods Mol Biol, 2014, 1097:163-197.

14 内参基因分析

14.1 分析背景及方法介绍

将所有基因进行如下处理：保留在所有样品中均表达的基因（有参 fpkm>1,无参 fpkm>0.3，至少 fpkm>0）；与比较组合的差异基因进行比较，过滤掉差异基因；根据表达量大小自大到小排序，选取表达量前 20 的基因利用 NormFinder 软件进行内参基因的筛选。

14.2 结果展示

14.2.1 NormFinder 筛选出的内参基因

Gene name	Stability value	Best gene	hsa-miR-550a-3-5p
hsa-miR-1307-5p	0.246	Stability value	0.097
hsa-miR-26b-5p	0.269	Best combination of two genes	hsa-miR-550a-3-5p and hsa-miR-550a-5p
hsa-miR-29b-3p	0.221	Stability value for bestcombination of two genes	0.069
hsa-miR-3157-3p	0.224		

14.2.1 NormFinder 筛选出的内参基因

第一列 Gene name：表达量前 20 的基因

第二列 Stability value：基因稳定性值，Stability value 越小，越稳定

第三-四列 Best gene/Best combination of two genes：筛选的最佳内参基因与内参基因对

14.3 参考文献

【1】 Daniel R, Wu Q, Williams V, et al. A Panel of MicroRNAs as Diagnostic Biomarkers for the Identification of Prostate Cancer:[J]. International Journal of Molecular Sciences, 2017, 18(6).

15 密码子偏好性分析

15.1 分析背景及方法介绍

每种氨基酸至少对应一个遗传密码子（一般不超过 6 个），编码同一种氨基酸的密码子称为同义密码子,同义密码子在使用频率中存在一定的差异，这种现象称为密码子使用偏好

性 (codon usage bias, CUB) , 并且在某一特定物种或者基因中比较倾向使用的同义密码子称为最优密码子 (optimal codons) 。

影响密码子偏好性的因素有突变压力 (如 GC 含量、基因碱基组成)、选择作用 (如基因表达水平、tRNA 丰度、蛋白结构与长度、翻译的起始信号) 。此分析主要适用于原核物种和低高等真核生物。我们利用 CodonW 中进行密码子使用偏性的分析。

使用指标:

CAI (密码子适应指数) : 基因表达水平测量, 0-1

ENc(有效密码子数): 一个基因中所用到的密码子种类的多少。20-61

20: 每个氨基酸只使用一个密码子; 61: 各个密码子均被平均使用

CBI(密码子偏爱指数): 一个具体基因中高表达优越密码子的组分情况

FOP(最优密码子使用频数): 使用最优密码子占总数百分比。

RSCU(相对同义密码子使用度):指某一特定密码子在使用频率与其无偏好性使用时预期频率之间的比值。密码子偏好性程度的有效指标。

RSCU 比值等于 1 说明该密码子无使用偏好性, 若 RSCU 比值大于 1 说明该密码子的使用频率较高。

15.2 结果展示

15.2.1 密码子偏好性分析结果

num RSCU															
Phe	UUU	10722	0.39	Ser	UCU	11258	0.55	Tyr	UAU	7827	0.37	Cys	UGU	11018	0.65
	UUC	43762	1.61		UCC	21608	1.06		UAC	34797	1.63		UGC	23078	1.35
Leu	UUA	3645	0.13		UCA	11062	0.54	TER	UAA	431	0.37	TER	UGA	1902	1.65
	UUG	12720	0.44		UCG	34396	1.68		UAG	1128	0.98	Trp	UGG	20640	1.00
	CUU	11872	0.41	Pro	CCU	10373	0.43	His	CAU	10876	0.43	Arg	CGU	14209	0.62
	CUC	36988	1.29		CCC	22900	0.94		CAC	39732	1.57		CGC	50447	2.22
	CUA	6785	0.24		CCA	15685	0.64	Gln	CAA	12413	0.31		CGA	15548	0.68
	CUG	100022	3.49		CCG	48432	1.99		CAG	67322	1.69		CGG	35712	1.57
Ile	AUU	11417	0.56	Thr	ACU	11655	0.50	Asn	AAU	11347	0.46	Ser	AGU	12072	0.59
	AUC	41057	2.02		ACC	34791	1.50		AAC	38069	1.54		AGC	32295	1.58
	AUA	8573	0.42		ACA	14007	0.60	Lys	AAA	18043	0.51	Arg	AGA	8948	0.39
Met	AUG	38457	1.00		ACG	32417	1.40		AAG	53097	1.49		AGG	11721	0.51
Val	GUU	12087	0.38	Ala	GCU	20790	0.51	Asp	GAU	22588	0.46	Gly	GGU	18692	0.62
	GUC	40273	1.25		GCC	72796	1.78		GAC	76191	1.54		GGC	71447	2.38
	GUA	9710	0.30		GCA	18277	0.45	Glu	GAA	24400	0.48		GGA	16714	0.56
	GUG	66525	2.07		GCG	52052	1.27		GAG	77555	1.52		GGG	13279	0.44

1740652 codons in Average of genes (used Universal Genetic code)

表 15.2.1 密码子偏好性分析结果

RSCU 是指相对同义密码子使用度，RSCU 比值等于 1 说明该密码子无使用偏好性，若 RSCU 比值大于 1 说明该密码子的使用频率较高

15.3 参考文献

- [1]** Peden J F. Analysis of codon usage.[J]. University of Nottingham, 2011, 90(1):73–74.