

中文版 methods

仅供客户在文章写作时参考，分析内容和方法请以结题报告
为准，请客户自行承担文章查重等相关风险。

1 实验流程

1.1 样品检测

详见样本检测报告。

1.2 文库构建和上机测序

取样本的 1 μg 基因组 DNA，用 Covaris 超声波破碎仪随机打断成长度约为 350 bp 的片段后进行文库的构建，经末端修复、加 A 尾、加测序接头、纯化、PCR 扩增等步骤完成整个文库制备。文库构建完成后，先使用 AAT1 检测文库片段的完整性及插入片段大小，符合预期后，使用 Q-PCR 方法对文库的有效浓度进行准确定量(文库有效浓度 $>3 \text{ nM}$)，以保证文库质量。库检合格后，把不同文库按照有效浓度及目标下机数据量的需求 pooling 后进行 PE150 测序。

2 生物信息分析

2.1 测序结果预处理

二代测序数据预处理

使用 fastp (<https://github.com/OpenGene/fastp>)对 NovaSeq 测序平台获得的原始数据(raw data)进行预处理，获取用于后续分析的有效数据(clean data)。具体处理步骤如下:a)当任一测序 read 中含有接头序列，去除此 paired reads; b)当任一测序 read 中含有的低质量($Q \leq 5$)碱基数超过该条 read 碱基数的 50%时，去除此 paired reads; c)当任一测序 read 中 N 含量超过该 read 碱基数的 10%时，去除此 paired reads。

如果样品存在宿主污染，需与宿主序列进行比对，过滤掉可能来源于宿主的 reads，默认采用 Bowtie2 软件 (<http://bowtie-bio.sourceforge.net/bowtie2/index.shtml>)，参数设置 --end-to-end, --sensitive, -I 200, -X 400 (Karlsson FH et al., 2012; Karlsson FH et al., 2013; Scher JU et al., 2013)。

三代测序数据预处理

Nanopore sequencing 是基于纳米孔的单分子实时电信号测序技术，下机数据原始格式为 fast5 格式，使用 Guppy 软件 basecalling 将 fast5 转化为 fastq 格式。我们采用软件 NanoPlot (Version: NanoPlot 1.18.2), <https://github.com/wdecoster/NanoPlot/>对数据进行质控，并用 NanoFilt 软件对序列进行过滤，选用阈值 $Q > 7$ ，长度 $\text{length} > 500$ 的 reads 作为最终的有效数据。

如果样品存在宿主污染，需与宿主序列进行比对，过滤掉可能来源于宿主的 reads，默认采用 Blasr 软件(<https://github.com/mchaisso/blasr>)，参数设置 --maxScore -1000 --maxLCPLength 16 (Karlsson FH et al., 2012; Karlsson FH et al., 2013; Scher JU et al., 2013)。

2.2 Metagenome 组装

基于样品质控后的 Clean Data，采用 Flye 软件对 ONT 长读数据进行 de novo 组装，生成初始的 scaffigs(Kolmogorov et al., 2019)。随后，使用 BWA 将 Illumina 短读比对到组装结果上(Li and Durbin, 2009)，并通过 Samtools 对比对文件进行排序、压缩和变异调用等处理，实现对组装结果的抛光校正(Li et al., 2009)，最终获得高质量的 scaffigs 用于下游分析。

2.3 分箱 Binning

Binning 模块使用 MetaWRAP 集成了三种主流宏基因组分箱软件：MaxBin2、MetaBAT2 和 CONCOCT(Uritskiy et al., 2018)。首先，使用 bwa-index 对宏基因组组装结果进行索引构建，然后将任意数量样本的成对 reads 比对到组装体上。比对结果通过 samtools 进行排序和压缩，同时收集文库插入片段大小的统计数据（包括插入片段平均值和标准差）。接着，使用 MetaBAT2 的 jgi_summarize_bam_contig_depths 函数生成 contig 丰度表，并将其转换为适合每个分箱软件的输入格式。MaxBin2、MetaBAT2 和 CONCOCT 在默认设置下完成对 contig 的分箱，最终生成包含已格式化 bin fasta 文件的 bin 文件夹，便于基于 bins 进行后续扩展分析。

Bin_refinement 模块采用混合方法，将由不同软件（或相同软件使用不同参数）获得的两个或三个 bin 集合整合为一个改进的 bin 集合(Uritskiy et al., 2018)。首先，使用 binning_refiner 从每个可能的组合中生成混合 bin。如果有三个 bin 集合：A、B 和 C，那么 binning_refiner 将生成以下混合集合：AB、BC、AC 和 ABC。然后运行 CheckM 评估每个 bin 集合（3 个原始集合和 4 个混合集合）中 bin 的完成度和污染情况(Parks et al., 2015)。随后，对 bin 集合进行迭代比较，并将每对 bin 集合合并为一个改进的 bin 集合。为此，通过至少 80% 的基因组长度重叠确定两个 bin 集合中的相同 bin，并根据得分较高的 bin 确定最佳 bin。得分函数为 $S = \text{完成度} - 5 \times \text{污染度}$ 。在所有 bin 集合被合并到最终的 bin 集合后，去重功能会删除任何重复的 contig：如果一个 contig 存在于多个 bin 中，它将从所有 bin 中删除，只保留评分最高的 bin。然后再次运行 CheckM 评估最终 bin 集合，并生成包含每个 bin 的完成度、污染度和 CheckM 生成的其他统计数据的最终报告文件。此外，还会生成完成度和污染度排名图，以评估 Bin_refinement 模块的成功性，并将其输出与原始 bin 的质量进行比较。

2.4 基因组质量评估

在 Bin_refinement 模块优化后，为整合所有样本的 bins 结果并去除潜在冗余，使用 dRep 对优化后的 bins 进行聚类去冗余处理(Olm et al., 2017)。该步骤首先通过 Mash 进行全基因组相似性初筛，随后基于 ANI (Average Nucleotide Identity) 阈值（默认 95%）和 CheckM 质量分数（包括完整度和污染度）选择代表性 bins，最终生成项目整体的去冗余 MAGs 集合。这确保了 bins 的唯一性和高质量，避免重复表示影响下游分析，并为后续的最终质量评估提供可靠基础。

CheckM 是宏基因组分析中用于评估基因组质量（Binning 结果）的关键工具，它通过识别特定的标记基因 (marker genes) 来估计基因组的完整度 (Completeness) 和污染度 (Contamination) (Parks et al., 2015)。其核心优势在于能根据基因组在系统发育树中的位置，选用谱系特异性的标记基因集进行评估，这使得评估结果更为准确，尤其适用于复杂微生物群落的 MAGs 分析。

GTDB-Tk (Genome Taxonomy Database Toolkit) 是一款基于基因组分类数据库 (GTDB) 对细菌和古菌基因组进行标准化物种注释的工具(Chaumeil et al., 2019)。其核心优势在于采用全基因组系统发育分析而非传统的 16S rRNA 基因序列，提供更客观、准确的分类框架，尤其适用于宏基因组分箱 (Binning) 获得的基因组草图 (MAGs) 的物种分类。

2.5 基因预测与功能注释

基因预测是宏基因组分析中的关键步骤，旨在从组装后的序列（如 contigs 或 scaffolds）或 binning 结果中识别蛋白质编码基因（CDS）和非编码 RNA（如 rRNA、tRNA、tmRNA），为下游功能注释和代谢分析提供基础数据。Prokka 是一个快速的原核基因组注释工具，专用于高效预测和注释细菌或古菌基因组(Seemann, 2014)。其核心方法包括：使用 Prodigal 进行从头（ab initio）开放阅读框（ORF）预测，以识别 CDS；结合 RNAmmer 和 Aragorn 等工具检测 rRNA、tRNA 和 tmRNA 等非编码 RNA；并整合同源比对（如 BLAST 对 Swiss-Prot 或 UniProt 的搜索）来提升注释准确性。

dbCAN（Carbohydrate-active enzyme ANnotation）是一个专用于自动化碳水化合物活性酶（CAZymes）注释的网络服务器和工具包(Zheng et al., 2023)。dbCAN 的主要目的是通过整合多种计算方法，对基因组或宏基因组序列中的 CAZyme 基因进行高效识别、分类和功能预测，帮助研究者揭示微生物在碳水化合物代谢中的作用，尤其适用于宏基因组学分析。

eggNOG-mapper（evolutionary genealogy of genes: Non-supervised Orthologous Groups - mapper）是一个专用于通过 orthology assignment 进行快速全基因组功能注释的工具(Cantalapiedra et al., 2021)。它基于 eggNOG 数据库的预计算 orthologous groups 和 phylogenies，从精细的 orthologs 中转移功能信息，避免了传统同源搜索（如 BLAST）中因 paralogs 功能分化导致的低精度问题。

CARD（Comprehensive Antibiotic Resistance Database，全称综合抗生素抗性数据库）是一个生物信息学数据库，专注于抗生素抗性基因（ARGs）、其产物以及相关表型的严谨整理和注释(Alcock et al., 2023)。CARD 的核心是 Antibiotic Resistance Ontology（ARO），一个用于组织抗性决定因素、抗生素和相关数据的本体框架。

BacMet2（Antibacterial Biocide and Metal Resistance Genes Database，全称抗菌生物杀灭剂和金属抗性基因数据库）是一个生物信息学数据库，专注于细菌对金属和抗菌生物杀灭剂（如消毒剂、防腐剂）的抗性基因的整理和注释(Pal et al., 2014)。该数据库基于对科学文献的深入审查，提供手动策展的内容，并与相关资源如抗生素抗性数据库联动。

VFDB（Virulence Factor Database，全称毒力因子数据库）是一个生物信息学数据库，专注于细菌毒力因子（VFs）的整理、分类和注释，提供各种细菌病原体的毒力相关知识(Chen et al., 2005)。

为揭示移动遗传元件（Mobile Genetic Elements, MGEs）在微生物群落中的分布及其在抗生素耐药基因（ARGs）和毒力因子（VFs）水平基因转移中的潜在作用，本研究对去冗余后的 MAGs 序列进行专项 MGEs 注释。主要采用 geNomad 作为主力工具，该工具基于深度神经网络和标记基因数据库，能够高效、准确地同时识别和分类病毒（包括前噬菌体）、质粒以及复合 MGEs，在宏基因组组装序列（特别是 MAGs）中表现出较高的敏感性和低假阳性率(Camargo et al., 2024)。geNomad 的 end-to-end 模式直接对输入 FASTA 序列进行基因预测、分类和功能提示，输出包括元件类型、置信分数、hallmark 基因数量以及潜在的接合转移基因和抗性基因信息。为互补 geNomad 对插入序列（IS）和转座子等元件的覆盖不足，进一步使用 MobileElementFinder 进行补充检测，该工具通过比对专用数据库（MGEdb）快速识别 IS、复合转座子、单元转座子和整合接合元件（ICEs）等，提供精确的位置、方向和类型信息(Johansson et al., 2021)。通过这一综合策略，可全面评估 MGEs 的丰度和功能负载，为理解微生物群落的进化动态、抗性传播机制以及生态风险提供重要依据。

3 参考文献

- Camargo, A. P., Roux, S., Schulz, F., Babinski, M., Xu, Y., Hu, B., ... & Woyke, T. (2024). Identification of mobile genetic elements with geNomad. *Nature Biotechnology*, 42(8), 1208–1216. <https://doi.org/10.1038/s41587-023-01953-y>
- Cantalapiedra, C. P., Hernández-Plaza, A., Letunic, I., Bork, P., & Huerta-Cepas, J. (2021). eggNOG-mapper v2: Functional annotation, orthology assignments, and pathway inference at the metagenomic scale. *Molecular Biology and Evolution*, 38(12), 5825 – 5829. <https://doi.org/10.1093/molbev/msab293>
- Chaumeil, P.-A., Mussig, A. J., Hugenholtz, P., & Parks, D. H. (2019). GTDB-Tk: a toolkit to classify genomes with the Genome Taxonomy Database. *Bioinformatics*, 36(6), 1925 – 1927. <https://doi.org/10.1093/bioinformatics/btz848>
- Chen, I.-M. A., et al. (2005). Title of the paper. *Journal Name*, Volume(Issue), Pages. DOI or URL.
- Johansson, M. H. K., Bortolaia, V., Tansirichaiya, S., Aarestrup, F. M., Roberts, A. P., & Petersen, T. N. (2021). Detection of mobile genetic elements associated with antibiotic resistance in *Salmonella enterica* using a newly developed web tool: MobileElementFinder. *Journal of Antimicrobial Chemotherapy*, 76(1), 101–109. <https://doi.org/10.1093/jac/dkaa390>
- Kolmogorov, M., Yuan, J., Lin, Y., & Pevzner, P. A. (2019). Assembly of long, error-prone reads using repeat graphs. *Nature Biotechnology*, 37(5), 540 – 546. <https://doi.org/10.1038/s41587-019-0072-8>
- Li, H., & Durbin, R. (2009). Fast and accurate short read alignment with Burrows–Wheeler transform. *Bioinformatics*, 25(14), 1754–1760. <https://doi.org/10.1093/bioinformatics/btp324>
- Li, H., Handsaker, B., Wysoker, A., Fennell, T., Ruan, J., Homer, N., Marth, G., Abecasis, G., & Durbin, R. (2009). The Sequence Alignment/Map format and SAMtools. *Bioinformatics*, 25(16), 2078–2079. <https://doi.org/10.1093/bioinformatics/btp352>
- Olm, M. R., Brown, C. T., Brooks, B., & Banfield, J. F. (2017). dRep: a tool for fast and accurate genomic comparisons that enables improved genome recovery from metagenomes through de-replication. *The ISME Journal*, 11(12), 2864–2868. <https://doi.org/10.1038/ismej.2017.126>
- Pan, S., Zhu, C., Zhao, X. M., & Coelho, L. P. (2022). A deep siamese neural network improves metagenome-assembled genomes in microbiome datasets across different environments. *Nature Communications*, 13(1), 2326. <https://doi.org/10.1038/s41467-022-29843-y>
- Parks, D. H., Imelfort, M., Skennerton, C. T., Hugenholtz, P., & Tyson, G. W. (2015). CheckM: assessing the quality of microbial genomes recovered from isolates, single cells, and metagenomes. *Genome Research*, 25(7), 1043–1055. <https://doi.org/10.1101/gr.186072.114>

Qin, J., Li, R., Raes, J., Arumugam, M., Burgdorf, K. S., Manichanh, C., Nielsen, T., Pons, N., Levenez, F., Yamada, T., Mende, D. R., Li, J., Xu, J., Li, S., Li, D., Cao, J., Wang, B., Liang, H., Zheng, H., ... Wang, J. (2010). A human gut microbial gene catalogue established by metagenomic sequencing. *Nature*, 464(7285), 59–65. <https://doi.org/10.1038/nature08821>

Sedlar, K., Kupkova, K., & Provaznik, I. (2017). Bioinformatics strategies for taxonomy independent binning and visualization of sequences in shotgun metagenomics. *Computational and Structural Biotechnology Journal*, 15, 3–12. <https://doi.org/10.1016/j.csbj.2016.10.005>

Seemann, T. (2014). Prokka: rapid prokaryotic genome annotation. *Bioinformatics*, 30(14), 2068–2069. <https://doi.org/10.1093/bioinformatics/btu153>

Uritskiy, G. V., DiRuggiero, J., & Taylor, J. (2018). MetaWRAP — a flexible pipeline for genome-resolved metagenomic data analysis. *Microbiome*, 6(1), 158. <https://doi.org/10.1186/s40168-018-0541-1>

Wick, R. R., Judd, L. M., Gorrie, C. L., & Holt, K. E. (2017). Unicycler: Resolving bacterial genome assemblies from short and long sequencing reads. *PLOS Computational Biology*, 13(6), e1005595. <https://doi.org/10.1371/journal.pcbi.1005595>

Zheng, J., Ge, Q., Yan, Y., Zhang, X., Zhao, L., Cai, R., Ren, H., Zhang, Z., Wang, Q., Gao, X., Ouyang, Z., & Yin, Y. (2023). dbCAN3: automated carbohydrate-active enzyme and substrate annotation. *Nucleic Acids Research*, 51(W1), W115–W121. <https://doi.org/10.1093/nar/gkad328>