

中文版 methods

仅供客户在文章写作时参考，分析内容和方法请以结题报告
为准，请客户自行承担文章查重等相关风险。

1 实验流程

1.1 样品检测

详见样本检测报告。

1.2 文库构建和上机测序

取样本的 1 μg 基因组 DNA，用 Covaris 超声波破碎仪随机打断成长度约为 350 bp 的片段后进行文库的构建，经末端修复、加 A 尾、加测序接头、纯化、PCR 扩增等步骤完成整个文库制备。文库构建完成后，先使用 AAT1 检测文库片段的完整性及插入片段大小，符合预期后，使用 Q-PCR 方法对文库的有效浓度进行准确定量(文库有效浓度 $>3\text{ nM}$)，以保证文库质量。库检合格后，把不同文库按照有效浓度及目标下机数据量的需求 pooling 后进行 PE150 测序。

2 生物信息分析

2.1 测序结果预处理

二代测序数据预处理

使用 fastp (<https://github.com/OpenGene/fastp>)对 NovaSeq 测序平台获得的原始数据(raw data)进行预处理，获取用于后续分析的有效数据(clean data)。具体处理步骤如下:a)当任一测序 read 中含有接头序列，去除此 paired reads; b)当任一测序 read 中含有的低质量($Q\leq 5$)碱基数超过该条 read 碱基数的 50%时，去除此 paired reads; c)当任一测序 read 中 N 含量超过该 read 碱基数的 10%时，去除此 paired reads。

如果样品存在宿主污染，需与宿主序列进行比对，过滤掉可能来源于宿主的 reads，默认采用 Bowtie2 软件 (<http://bowtie-bio.sourceforge.net/bowtie2/index.shtml>)，参数设置 --end-to-end, --sensitive, -I 200, -X 400 (Karlsson FH et al., 2012; Karlsson FH et al., 2013; Scher JU et al., 2013)。

三代测序数据预处理

Nanopore sequencing 是基于纳米孔的单分子实时电信号测序技术，下机数据原始格式为 fast5 格式，使用 Guppy 软件 basecalling 将 fast5 转化为 fastq 格式。我们采用软件 NanoPlot (Version: NanoPlot 1.18.2), <https://github.com/wdecoster/NanoPlot/>对数据进行质控，并用 NanoFilt 软件对序列进行过滤，选用阈值 $Q>7$ ，长度 $\text{length}>500$ 的 reads 作为最终的有效数据。

如果样品存在宿主污染，需与宿主序列进行比对，过滤掉可能来源于宿主的 reads，默认采用 Blasr 软件(<https://github.com/mchaisso/blasr>)，参数设置 --maxScore -1000 --maxLCPLength 16 (Karlsson FH et al., 2012; Karlsson FH et al., 2013; Scher JU et al., 2013)。

2.2 Metagenome 组装

基于样品质控后的 Clean Data，采用 Flye 软件对 ONT 长读数据进行 de novo 组装，生成初始的 scaffigs(Kolmogorov et al., 2019)。随后，使用 BWA 将 Illumina 短读比对到组装结果上(Li and Durbin, 2009)，并通过 Samtools 对比对文件进行排序、压缩和变异调用等处理，实现对组装结果的抛光校正(Li et al., 2009)，最终获得高质量的 scaffigs 用于下游分析。

2.3 分箱 Binning

Binning 模块使用 MetaWRAP 集成了三种主流宏基因组分箱软件：MaxBin2、MetaBAT2 和 CONCOCT(Uritskiy et al., 2018)。首先，使用 bwa-index 对宏基因组组装结果进行索引构建，然后将任意数量样本的成对 reads 比对到组装体上。比对结果通过 samtools 进行排序和压缩，同时收集文库插入片段大小的统计数据（包括插入片段平均值和标准差）。接着，使用 MetaBAT2 的 jgi_summarize_bam_contig_depths 函数生成 contig 丰度表，并将其转换为适合每个分箱软件的输入格式。MaxBin2、MetaBAT2 和 CONCOCT 在默认设置下完成对 contig 的分箱，最终生成包含已格式化 bin fasta 文件的 bin 文件夹，便于基于 bins 进行后续扩展分析。

Bin_refinement 模块采用混合方法，将由不同软件（或相同软件使用不同参数）获得的两个或三个 bin 集合整合为一个改进的 bin 集合(Uritskiy et al., 2018)。首先，使用 binning_refiner 从每个可能的组合中生成混合 bin。如果有三个 bin 集合：A、B 和 C，那么 binning_refiner 将生成以下混合集合：AB、BC、AC 和 ABC。然后运行 CheckM 评估每个 bin 集合（3 个原始集合和 4 个混合集合）中 bin 的完成度和污染情况(Parks et al., 2015)。随后，对 bin 集合进行迭代比较，并将每对 bin 集合合并为一个改进的 bin 集合。为此，通过至少 80% 的基因组长度重叠确定两个 bin 集合中的相同 bin，并根据得分较高的 bin 确定最佳 bin。得分函数为 $S = \text{完成度} - 5 \times \text{污染度}$ 。在所有 bin 集合被合并到最终的 bin 集合后，去重功能会删除任何重复的 contig：如果一个 contig 存在于多个 bin 中，它将从所有 bin 中删除，只保留评分最高的 bin。然后再次运行 CheckM 评估最终 bin 集合，并生成包含每个 bin 的完成度、污染度和 CheckM 生成的其他统计数据的最终报告文件。此外，还会生成完成度和污染度排名图，以评估 Bin_refinement 模块的成功性，并将其输出与原始 bin 的质量进行比较。

2.4 基因组质量评估

在 Bin_refinement 模块优化后，为整合所有样本的 bins 结果并去除潜在冗余，使用 dRep 对优化后的 bins 进行聚类去冗余处理(Olm et al., 2017)。该步骤首先通过 Mash 进行全基因组相似性初筛，随后基于 ANI (Average Nucleotide Identity) 阈值（默认 95%）和 CheckM 质量分数（包括完整度和污染度）选择代表性 bins，最终生成项目整体的去冗余 MAGs 集合。这确保了 bins 的唯一性和高质量，避免重复表示影响下游分析，并为后续的最终质量评估提供可靠基础。

CheckM 是宏基因组分析中用于评估基因组质量（Binning 结果）的关键工具，它通过识别特定的标记基因 (marker genes) 来估计基因组的完整度 (Completeness) 和污染度 (Contamination) (Parks et al., 2015)。其核心优势在于能根据基因组在系统发育树中的位置，选用谱系特异性的标记基因集进行评估，这使得评估结果更为准确，尤其适用于复杂微生物群落的 MAGs 分析。

GTDB-Tk (Genome Taxonomy Database Toolkit) 是一款基于基因组分类数据库 (GTDB) 对细菌和古菌基因组进行标准化物种注释的工具(Chaumeil et al., 2019)。其核心优势在于采用全基因组系统发育分析而非传统的 16S rRNA 基因序列，提供更客观、准确的分类框架，尤其适用于宏基因组分箱 (Binning) 获得的基因组草图 (MAGs) 的物种分类。

2.5 基因预测与功能注释

基因预测是宏基因组分析中的关键步骤，旨在从组装后的序列（如 contigs 或 scaffolds）或 binning 结果中识别蛋白质编码基因（CDS）和非编码 RNA（如 rRNA、tRNA、tmRNA），为下游功能注释和代谢分析提供基础数据。Prokka 是一个快速的原核基因组注释工具，专用于高效预测和注释细菌或古菌基因组(Seemann, 2014)。其核心方法包括：使用 Prodigal 进行从头（ab initio）开放阅读框（ORF）预测，以识别 CDS；结合 RNAmmer 和 Aragorn 等工具检测 rRNA、tRNA 和 tmRNA 等非编码 RNA；并整合同源比对（如 BLAST 对 Swiss-Prot 或 UniProt 的搜索）来提升注释准确性。

dbCAN (Carbohydrate-active enzyme ANnotation) 是一个专用于自动化碳水化合物活性酶 (CAZymes) 注释的网络服务器和工具包(Zheng et al., 2023)。dbCAN 的主要目的是通过整合多种计算方法，对基因组或宏基因组序列中的 CAZyme 基因进行高效识别、分类和功能预测，帮助研究者揭示微生物在碳水化合物代谢中的作用，尤其适用于宏基因组学分析。

eggNOG-mapper (evolutionary genealogy of genes: Non-supervised Orthologous Groups - mapper) 是一个专用于通过 orthology assignment 进行快速全基因组功能注释的工具(Cantalapiedra et al., 2021)。它基于 eggNOG 数据库的预计算 orthologous groups 和 phylogenies，从精细的 orthologs 中转移功能信息，避免了传统同源搜索（如 BLAST）中因 paralogs 功能分化导致的低精度问题。

CARD (Comprehensive Antibiotic Resistance Database, 全称综合抗生素抗性数据库) 是一个生物信息学数据库，专注于抗生素抗性基因 (ARGs)、其产物以及相关表型的严谨整理和注释(Alcock et al., 2023)。CARD 的核心是 Antibiotic Resistance Ontology (ARO)，一个用于组织抗性决定因素、抗生素和相关数据的本体框架。

BacMet2 (Antibacterial Biocide and Metal Resistance Genes Database, 全称抗菌生物杀灭剂和金属抗性基因数据库) 是一个生物信息学数据库，专注于细菌对金属和抗菌生物杀灭剂（如消毒剂、防腐剂）的抗性基因的整理和注释(Pal et al., 2014)。该数据库基于对科学文献的深入审查，提供手动策展的内容，并与相关资源如抗生素抗性数据库联动。

VFDB (Virulence Factor Database, 全称毒力因子数据库) 是一个生物信息学数据库，专注于细菌毒力因子 (VFs) 的整理、分类和注释，提供各种细菌病原体的毒力相关知识(Chen et al., 2005)。

3 参考文献

Cantalapiedra, C. P., Hernández-Plaza, A., Letunic, I., Bork, P., & Huerta-Cepas, J. (2021). eggNOG-mapper v2: Functional annotation, orthology assignments, and pathway inference at the metagenomic scale. *Molecular Biology and Evolution*, 38(12), 5825 – 5829. <https://doi.org/10.1093/molbev/msab293>

Chaumeil, P.-A., Mussig, A. J., Hugenholtz, P., & Parks, D. H. (2019). GTDB-Tk: a toolkit to classify genomes with the Genome Taxonomy Database. *Bioinformatics*, 36(6), 1925 – 1927. <https://doi.org/10.1093/bioinformatics/btz848>

Chen, I.-M. A., et al. (2005). Title of the paper. *Journal Name*, Volume(Issue), Pages. DOI or URL.

Kolmogorov, M., Yuan, J., Lin, Y., & Pevzner, P. A. (2019). Assembly of long, error-prone reads using repeat graphs. *Nature Biotechnology*, 37(5), 540 – 546. <https://doi.org/10.1038/s41587-019-0072-8>

Li, H., & Durbin, R. (2009). Fast and accurate short read alignment with Burrows–Wheeler transform. *Bioinformatics*, 25(14), 1754–1760. <https://doi.org/10.1093/bioinformatics/btp324>

Li, H., Handsaker, B., Wysoker, A., Fennell, T., Ruan, J., Homer, N., Marth, G., Abecasis, G., & Durbin, R. (2009). The Sequence Alignment/Map format and SAMtools. *Bioinformatics*, 25(16), 2078–2079. <https://doi.org/10.1093/bioinformatics/btp352>

Olm, M. R., Brown, C. T., Brooks, B., & Banfield, J. F. (2017). dRep: a tool for fast and accurate genomic comparisons that enables improved genome recovery from metagenomes through de-replication. *The ISME Journal*, 11(12), 2864–2868. <https://doi.org/10.1038/ismej.2017.126>

Pan, S., Zhu, C., Zhao, X. M., & Coelho, L. P. (2022). A deep siamese neural network improves metagenome-assembled genomes in microbiome datasets across different environments. *Nature Communications*, 13(1), 2326. <https://doi.org/10.1038/s41467-022-29843-y>

Parks, D. H., Imelfort, M., Skennerton, C. T., Hugenholtz, P., & Tyson, G. W. (2015). CheckM: assessing the quality of microbial genomes recovered from isolates, single cells, and metagenomes. *Genome Research*, 25(7), 1043–1055. <https://doi.org/10.1101/gr.186072.114>

Qin, J., Li, R., Raes, J., Arumugam, M., Burgdorf, K. S., Manichanh, C., Nielsen, T., Pons, N., Levenez, F., Yamada, T., Mende, D. R., Li, J., Xu, J., Li, S., Li, D., Cao, J., Wang, B., Liang, H., Zheng, H., ... Wang, J. (2010). A human gut microbial gene catalogue established by metagenomic sequencing. *Nature*, 464(7285), 59–65. <https://doi.org/10.1038/nature08821>

Sedlar, K., Kupkova, K., & Provaznik, I. (2017). Bioinformatics strategies for taxonomy independent binning and visualization of sequences in shotgun metagenomics. *Computational and Structural Biotechnology Journal*, 15, 3–12. <https://doi.org/10.1016/j.csbj.2016.10.005>

Seemann, T. (2014). Prokka: rapid prokaryotic genome annotation. *Bioinformatics*, 30(14), 2068–2069. <https://doi.org/10.1093/bioinformatics/btu153>

Uritskiy, G. V., DiRuggiero, J., & Taylor, J. (2018). MetaWRAP — a flexible pipeline for genome-resolved metagenomic data analysis. *Microbiome*, 6(1), 158. <https://doi.org/10.1186/s40168-018-0541-1>

Wick, R. R., Judd, L. M., Gorrie, C. L., & Holt, K. E. (2017). Unicycler: Resolving bacterial genome assemblies from short and long sequencing reads. *PLOS Computational Biology*, 13(6), e1005595. <https://doi.org/10.1371/journal.pcbi.1005595>

Zheng, J., Ge, Q., Yan, Y., Zhang, X., Zhao, L., Cai, R., Ren, H., Zhang, Z., Wang, Q., Gao, X.,

Ouyang, Z., & Yin, Y. (2023). dbCAN3: automated carbohydrate-active enzyme and substrate annotation. *Nucleic Acids Research*, 51(W1), W115–W121. <https://doi.org/10.1093/nar/gkad328>