

数据处理

(1)原始的测序 reads 是包含两端接头的哑铃型结构序列，称为 Polymerase reads。原始数据从接头处打断并过滤掉接头序列后得到 subreads，subreads 按照标准 Filtering subreads by minimum length = 50 进行过滤。

(2)在 subreads 基础上，采用 ccs 软件(SMRT Link v8.0.0)(<https://github.com/PacificBiosciences/ccs>) 产生高精度的 HiFi reads^[1]，在这里我们设定的标准是 min-passes=3,min-rq=0.99，即所有的 reads 质量值都在 Q20 以上。一般来说，该部分数据为下游分析的有效输入数据。

样品组装

从各样品质控后的 Clean Data 出发，使用 hifiasm-meta^[2,3]进行基因组组装，得到能反映样品基因组基本情况的序列文件，并对组装结果进行评价。

对长度 $\geq 1\text{M}$ 的 Contig 进行使用 dRep 进行去冗余处理^[4]，之后使用 CheckM 软件 (<https://ecogenomics.github.io/CheckM/>) 进行基因组完整度评估^[5]。

基因组分类分析

基因组分类数据库 GTDB (Genome Taxonomy Database) 是基于大量基因组的系统发育分析来构建基因组分类学研究的标准流程，从而对微生物进行分类^[6,7]，数据库主页：

(<http://gtdb.ecogenomic.org/>)。我们使用 GTDB 将组装序列进行基因组层面的分类，参数为：gtdbtk classify_wf --cpus 1。

基因组组分析

编码基因

从各样品最终的组装结果出发，采用对应的软件进行 ORF (Open Reading Frame) 预测及过滤。采用 GeneMarkS 软件 (version 4.17) [8] (<http://topaz.gatech.edu/>) 进行编码基因预测及过滤。

重复序列

根据重复的序列在基因组上的分布，分为两大类：散在重复序列、串联重复序列。散在重复序列是与串联重复序列的组织形式不同的另一类重复序列，是散在方式分布于基因组内的散在重复序列。串联重复序列 (Tandem Repeat, TR)，即相邻的、重复两次或多次特定核苷酸序列模式的重复序列。通过 RepeatMasker 软件 (version 4.0.5) [9] 进行散在重复序列预测，TRF (Tandem repeats finder, version 4.07b) [10] 搜寻 DNA 序列中的串联重复序列。

非编码 RNA

非编码 RNA (ncRNA) 是一类广泛存在于小基因组、细菌、古生菌和真核生物生物体内，执行多种生物学功能的 RNA 分子，其本身并不携带翻译为蛋白质的信息，直接在 RNA 水平对生命活动发挥作用。对于微生物而言，非编码 RNA 的主要类型包括 sRNA、rRNA、tRNA、snRNA、snoRNA 及 miRNA 等等。常见类型 ncRNA 预测方法如下：

- 1) tRNA: 通过 tRNAscan-SE 软件[11]可预测 tRNA 区域和 tRNA 的二级结构。
- 2) rRNA: 通过比对 rRNA 库查找与数据库近缘的 rRNA (identity 默认 $\geq 50\%$)，并利用 rRNAmmer 软件预测新出现及未被注释的 rRNAs，综合二者结果。
- 3) sRNA: 首先用 Rfam 软件[12]进行 Rfam database 比对注释，接着用 cmsearch 程序 (version 1.1rc4) 确定最终的 sRNA。

基因岛

基因岛（Genomics Islands, GIs）是一些细菌、噬菌体或质粒中有横向起源迹象的一部分基因组。基因岛大小通常从 10 到 500 Kbp，其 GC 含量和密码子选择与基因组的其余部分不同。基因岛的许多亚分类基于它们所表现出来的功能，如病原性基因岛

（Pathogenicity islands, PAIs）其上包含有毒力基因，与致病机理相关，抗生素抗性基因岛包含有许多抗生素抗性基因。采用 IslandPath-DIOMB 软件^[13]预测基因岛，其通过检测序列中二核苷酸偏向性（phylogenetically bias）和移动性基因（mobility genes，如转座酶或整合酶）以判定基因岛以及潜在的水平基因转移。

转座子

转座子(transposon,简称 Tn),又称易位子,是存在于染色体 DNA 上可以自主复制和移位的 基本单位。DNA 的转座,或称移位 (transposition),是由可移位因子(transposable element s) 介导 的遗传物质重排现象,与同源重组相比,转座发生的频率要低得多。转座子可以在不同 复制子 之间转移,以非正常重组方式从一个位点插入到另外一个位点,对新位点基因的结构 与表达产生多种遗传效应。 采用 TransposonPSI 软件^[14]对转座子进行预测。其通过 PSI-Blast 同源比对来对基因组或者 蛋白序列 进行查找可能的转座子序列。

前噬菌体

整合在宿主基因组上的温和噬菌体的核酸称之为前噬菌体。前噬菌体预测是使用 phiSpy 工具（Nov11_v2.3 ），这是一个预测精度和准确性都很高的工具，支持 GenBank 格式格式文件。

CRISPR

CRISPR (Clustered Regularly Interspaced Short Palindromic Repeat Sequences, 成簇的、规律间隔的短回文重复序列) 是在 40% 已测序的细菌和 90% 已测序的古细菌中都有报道过的、含有一个与噬菌体和质粒同源的短的重复序列, 通过对外来同源的 DNA 作用对噬菌体有抗性, 影响质粒的连接, 是原核生物的免疫系统一部分。采用 CRISPRdigger 工具^[15]对样品基因组进行 CRISPR 预测, CRISPRdigger 准确性高并能预测其中的短回文重复结构。

基因功能分析

基因功能注释

目前提供注释的通用功能数据库主要有 GO^[16](Gene Ontology, <http://geneontology.org/>)、KEGG^[17,18](Kyoto Encyclopedia of Genes and Genomes, <http://www.genome.jp/kegg/>)、COG^[19](Cluster of Orthologous Groups of proteins, <http://www.ncbi.nlm.nih.gov/COG/>)、eggnoG(evolutionary genealogy of genes: Non-supervised Orthologous Groups)、NR^[20](NonRedundant Protein Database)、TCDB^[21](Transporter Classification Database)、SwissProt^[22](<http://www.ebi.ac.uk/uniprot/>)、CAZy^[29](Carbohydrate-Active enZYmes Database) 等。

功能注释基本步骤如下:

- 1) 将预测基因与各功能数据库进行 BLAST 比对 (blastp, $\text{evaluate} \leq 1\text{e-}5$);
- 2) BLAST 结果过滤: 对于每一条序列的 BLAST 结果, 选取 score 最高的比对结果 (默认 $\text{identity} \geq 40\%$, $\text{coverage} \geq 40\%$) 进行注释。

效应子

分泌蛋白预测

分泌蛋白是指在细胞内合成后，在信号肽的引导下穿过细胞膜分泌到细胞外起作用的蛋白质。分泌蛋白中有许多是生命活动所需的重要酶类。分泌蛋白的 N 端是由 15 ~ 30 个氨基酸组成的信号肽，对分泌蛋白的分泌起主导作用。使用信号肽预测工具 SignalP^[23] 进行预测，检测是否含有信号肽及跨膜结果，综合预测蛋白质序列是否是分泌蛋白。

分泌系统蛋白及 T3SS 效应蛋白预测

病原菌通过分泌系统 TNSS^[24] (type N secretion systems, 目前确定的有 7 种, I 型-VII 型) 将该类蛋白分泌至胞外或是宿主细胞中, 通过控制免疫应答反应以及细胞衰亡引起病理反应, 而其中革兰氏阴性菌的 T3SS 通常用来从分子水平研究病原菌, 感染机制, 毒力作用等, 是研究得比较多的分泌系统。

对于 TNSS 系统, 通过蛋白质序列功能数据库注释结果中, 提取分泌系统相关蛋白进行注释。对于革兰氏阴性菌, 另外采用 EffectiveT3 软件预测 T3SS 效应蛋白。

次级代谢基因簇分析

次级代谢产物是微生物在一定的生长时期, 以初级代谢产物为前体合成的对微生物的生命活动无明确功能, 并非生长繁殖所必需的物质。采用 antiSMASH 程序^[25] (version 2.0.2) 对基因组进行预测。

毒力或致病性分析

对于细菌, 目前提供注释的病原细菌致病性和耐药性数据库主要有 PHI^[26] (Pathogen Host Interactions Database)、VFDB^[27] (Virulence Factors of Pathogenic Bacteria)、ARDB^[28] (Antibiotic Resistance Genes Database)、CARD (Comprehensive Antibiotic Research Database)。

参考文献

- [1] Wenger A M, Peluso P, Rowell W J, et al. Accurate circular consensus long-read sequencing improves variant detection and assembly of a human genome[J]. *Nature Biotechnology*, 2019, 37(10): 1155-1162.
- [2] Cheng H, Concepcion GT, Feng X, Zhang H, Li H. Haplotype-resolved de novo assembly using phased assembly graphs with hifiasm[J]. *Nat Methods*. 2021;18(2):170-175.
- [3] Cheng H, Jarvis E D, Fedrigo O, et al. Haplotype-resolved assembly of diploid genomes without parental data[J]. *Nature Biotechnology*, 2022: 1-4.
- [4] Olm, M. R., Brown, C. T., Brooks, B. & Banfield, J. F. dRep: a tool for fast and accurate genomic comparisons that enables improved genome recovery from metagenomes through de-replication. *The ISME Journal* 11, 2864-2868, doi:10.1038/ismej.2017.126 (2017).
- [5] Parks D H, Imelfort M, Skennerton C T, et al. CheckM: assessing the quality of microbial genomes recovered from isolates, single cells, and metagenomes[J]. *Genome research*, 2015, 25(7): 1043-1055.
- [6] Chaumeil P A, Mussig A J, Hugenholtz P, et al. GTDB-Tk: a toolkit to classify genomes with the Genome Taxonomy Database[J]. 2020.
- [7] Parks D H, Chuvochina M, Waite D W, et al. A standardized bacterial taxonomy based on genome phylogeny substantially revises the tree of life[J]. *Nature biotechnology*, 2018, 36(10): 996-1004.
- [8] Besemer J, Lomsadze A, Borodovsky M. GeneMarkS: a self-training method for prediction of gene starts in microbial genomes. Implications for finding sequence motifs in regulatory regions[J]. *Nucleic Acids Research*, 2001, 29(12): 2607-2618.
- [9] Saha S, Bridges S, Magbanua Z V, et al. Empirical comparison of *ab initio* repeat finding programs[J]. *Nucleic acids research*, 2008, 36(7): 2284-2294.
- [10] Benson G. Tandem repeats finder: a program to analyze DNA sequences[J]. *Nucleic acids research*, 1999, 27(2): 573.
- [11] Lowe T M, Eddy S R. tRNAscan-SE: a program for improved detection of transfer RNA genes in genomic sequence[J]. *Nucleic acids research*, 1997, 25(5): 0955-964.
- [12] Gardner P P, Daub J, Tate J G, et al. Rfam: updates to the RNA families database[J]. *Nucleic acids research*, 2009, 37(suppl 1): D136-D140.
- [13] Hsiao W, Wan I, Jones S J, et al. IslandPath: aiding detection of genomic islands in prokaryotes[J]. *Bioinformatics*, 2003, 19(3): 418-420.
- [14] You Z, YJ Liang, Karlene L, et al. "PHAST: A Fast Phage Search Tool" *Nucl. Acids Res*, 2011 doi:10.1093/nar/gkr485.

- [15] Grissa I, Vergnaud G, Pourcel C. CRISPRFinder: a web tool to identify clustered regularly interspaced short palindromic repeats[J]. *Nucleic acids research*, 2007, 35(suppl 2): W52-W57.
- [16] Ashburner M, Ball C A, Blake J A, et al. Gene Ontology: tool for the unification of biology[J]. *Nature genetics*, 2000, 25(1): 25-29.
- [17] Kanehisa M, Goto S, Kawashima S, et al. The KEGG resource for deciphering the genome[J]. *Nucleic acids research*, 2004, 32(suppl 1): D277-D280.
- [18] Kanehisa M, Goto S, Hattori M, et al. From genomics to chemical genomics: new developments in KEGG[J]. *Nucleic acids research*, 2006, 34(suppl 1): D354-D357.
- [19] Galperin MY, Makarova KS, Wolf YI, et al. Expanded microbial genome coverage and improved protein family annotation in the COG database [J]. *Nucleic Acids Research*, 2015, 43(Database issue):261-9.
- [20] Li W, Jaroszewski L, Godzik A. Tolerating some redundancy significantly speeds up clustering of large protein databases[J]. *Bioinformatics*, 2002, 18(1): 77-82.
- [21] Milton SJ, Vamsee SR, Dorjee GT, et al. The Transporter Classification Database. *Nucleic Acids Research*, 2014, doi:10.1093/nar/gkt1097.
- [22] Amos B, Rolf A. The SWISS-PROT protein sequence database and its supplement TrEMBL in 2000. *Nucleic Acids Res.* 2000, 28(1): 45-48.
- [23] Petersen T N, Brunak S, von Heijne G, et al. SignalP 4.0: discriminating signal peptides from transmembrane regions[J]. *Nature methods*. 2011, 8(10): 785-786.
- [24] Eichinger V, Nussbaumer T, Platzer A, et al. Effective DB-updates and novel features for a better annotation of bacterial secreted proteins and Type III, IV, VI secretion systems. 2016, *Nucleic Acids Res.* doi:10.1093/nar/gkv1269.
- [25] Medema M H, Blin K, Cimermancic P, et al. antiSMASH: rapid identification, annotation and analysis of secondary metabolite biosynthesis gene clusters in bacterial and fungal genome sequences[J]. *Nucleic acids research*, 2011, 39(suppl 2): W339-W346.
- [26] Martin U, Rashmi P, Arathi R et al. The Pathogen-Host Interactions database (PHI-base): additions and future developments. *Nucleic Acids Research*. 2015, doi: 10.1093/nar/gku1165.
- [27] Chen L, Xiong Z, Sun L, et al. VFDB 2012 update: toward the genetic diversity and molecular evolution of bacterial virulence factors[J]. *Nucleic acids research*, 2012, 40(D1): D641-D645.
- [28] Liu B, Pop M. ARDB-antibiotic resistance genes database[J]. *Nucleic acids research*, 2009, 37(suppl 1): D443-D447.
- [29] Cantarel B L, Coutinho P M, Rancurel C, et al. The Carbohydrate-Active EnZymes database (CAZy): an expert resource for glycogenomics[J]. *Nucleic acids research*, 2009, 37(suppl 1): D233-D238.