

诺禾致源微生物 Pacbio-HiFi 宏基因组项目售后 FAQ

目录

一、名词解释.....	2
1. Metagenomic (宏基因组)	2
2. Raw Data	2
3. Clean Data	2
4. Contig	3
5. Contig N50	3
二、质控、组装	3
1. 测序数据量 (测序深度) 限制宏基因组组装效果, 那为什么不把所有样本数据合并在一起组装?	3
2. 为什么有污染的情况下组装结果较差	3
三、组分分析和功能注释	3
1. 如果老师关心的基因没有被注释出来, 原因是什么?	4
2. 16S 分析与 Meta 分析的注释结果有差异	4
3. 关于 ncRNA 注释, 为什么注释不到 5S/16S/23S 的序列?	5
4. 为什么在 genebank 找不到基因?	5
5. KEGG 数据库比对时用 EC 号和 KO 区别?	5
6. 在功能注释结果中, Identity、Evalue 和 Score 的区别?	6
7. 将基因组的 KO 号输入 KEGG 网址分析, 为什么有的基因找不到?	6
8. KEGG 数据库的 map 图中框出来的代表什么, 不同颜色表示什么意思?	6
9. KEGG 图中的代码知道酶的名字?	6
10. 次级代谢产物基因簇注释分析中为什么没有 PKS (聚酮合酶) 和 NRPS (非核糖体肽合成酶) 结构?	7
11. 如何打开结果文件	7

一、名词解释

1. Metagenomic (宏基因组)

宏基因组是基因组学一个新兴的科学研究方向。宏基因组学（又称元基因组学，环境基因组学，生态基因组学等），是研究直接从环境样本中提取的基因组遗传物质的学科。

传统的微生物研究依赖于实验室培养，宏基因组的兴起填补了无法在传统实验室中培养的微生物研究的空白。过去几年中，DNA 测序技术的进步以及测序通量和分析方法的改进使得人们得以一窥这一未知的基因组科学领域。

Metagenomics 研究的对象是整个微生物群落。相对于传统单个细菌研究来说，它具有众多优势，其中很重要的两点：

(1) 微生物通常是以群落方式共生于某一小生境中，它们的很多特性是基于整个群落环境及个体间的相互影响的，因此做 Metagenomics 研究比做单个个体的研究更能发现其特性；

(2) Metagenomics 研究无需分离单个细菌，可以研究那些不能被实验室分离培养的微生物。

广义宏基因组是指特定环境下所有生物遗传物质的总和，它决定了生物群体的生命现象。它是以生态环境中全部 DNA 作为研究对象，通过克隆、异源表达来筛选有用基因及其产物，研究其功能和彼此之间的关系和相互作用，并揭示其规律的一门科学。

狭义宏基因组学则以生态环境中全部细菌和真菌基因组 DNA 作为研究对象，它不是采用传统的培养微生物的基因组，包含了可培养和还不能培养的微生物的基因，通过克隆、异源表达来筛选有用基因及其产物，研究其功能和彼此之间的关系和相互作用，并揭示其规律。

2. Raw Data

测序得到的原始数据。

3. Clean Data

对原始数据进行过滤处理，得到用于分析的有效数据。

4. Contig

拼接软件基于 reads 之间的 overlap 区，拼接获得的序列称为 Contig（重叠群）。

5. Contig N50

Reads 拼接后会获得一些不同长度的 Contigs。将所有的 Contig 长度相加，能获得一个 Contig 总长度。然后将所有的 Contigs 按照从长到短进行排序，如获得 Contig 1, Contig 2, Contig 3.....Contig 25。将 Contig 按照这个顺序依次相加，当相加的长度达到 Contig 总长度的一半时，最后一个加上的 Contig 长度即为 Contig N50。举例：Contig 1+Contig 2+ Contig 3+Contig 4=Contig 总长度*1/2 时，Contig 4 的长度即为 Contig N50。Contig N50 可以作为基因组拼接的结果好坏的一个判断标准。

二、质控、组装

1. 测序数据量（测序深度）限制宏基因组组装效果，那为什么不把所有样本数据合并在一起组装？

- 1) 资源限制，所有样本数据合并组装将消耗极大的内存，并且时间相当长；
- 2) 不同样本的高丰度物种差异很大，所有样本都混合在一起进行组装，那么无疑会大大增加数据的复杂度，组装效果可能会更差^[1]；

参考文献：

[1] Qin J, Li R, Raes J, et al. A human gut microbial gene catalogue established by metagenomic sequencing[J]. nature, 2010, 464(7285): 59-65.

2. 为什么有污染的情况下组装结果较差

由于组装软件在组装过程中是将测序数据看作来自同一个基因组的前提下进行的，如果有外源 DNA 混杂，其中不同来源的 DNA 中会有不同程度的相似性序列和非相似性序列，这些复杂的关系会对组装软件产生干扰，而软件为保证组装的准确性，只能将可疑的部分切断成不同的碎片序列，而这也导致最终的组装只能拿到碎片化的序列，而失去了组装本身想要达到的效果。

三、组分分析和功能注释

1. 如果老师关心的基因没有被注释出来，原因是什么？

- 1、这个基因没有被组装出来。
- 2、这个基因在目标基因组上不存在。
- 3、注释的数据库里没有这个基因，所以无法注释出来。
- 4、老师要测的这个菌株，根本就没有这个基因，需要老师确认是否非常肯定，该菌株中含有该基因。

2. 16S 分析与 Meta 分析的注释结果有差异

16S 分析和 meta 分析结果存在差别，主要有两个方面的原因：

1) 分析方法存在较大差异：Shah N 等在 2011 年发表的一篇文献^[1]指出，尽管先前有研究表明 16S 和 Meta 的分析得到相似的物种组成，但是他们的研究结果表明，大多数不同来源的环境样品经过 16S rRNA 与 meta 分析得到的物种注释结果都存在着明显的差别，主要原因是 16S 是经过扩增的，而且不同物种的 DNA 扩增的倍数不一致（biased because of unequal amplification of species 16S rRNA genes ...）；而宏基因组的 DNA 测序深度可能不是十分足够（may not be deep enough to detect...），并且宏基因组分析得到的相对物种丰度因 DNA 的提取方法以及测序方法有很大差异（vary significantly depending on the DNA extraction and...）；

2) 物种注释方法以及数据库存在着一定的差别：16S 采用的是将 16S rRNA 与 Silva 数据库进行比对注释，可注释到细菌、古菌、真菌；meta 是将预测得到的基因与 NR 数据库进行比对从而进行注释，可注释到细菌、古菌、真菌及病毒；

另外，16S 分析和 Meta 分析的注释结果也存在一定的相似点，比如说门水平相对丰度排名靠前的物种的类别是相似的；

综上所述，分析方法本身存在一定差异，是导致 16S 分析和 Meta 分析的注释结果存在一些差别的主要原因，但同时两者也有一定的相似之处。

参考文献：

[1] Shah N, Tang H, Doak TG, Ye Y. Comparing bacterial communities inferred from 16S rRNA gene sequencing and shotgun metagenomics. Pacific Symposium on Biocomputing Pacific Symposium on Biocomputing 2011:165-76.

3. 关于 ncRNA 注释，为什么注释不到 5S/16S/23S 的序列？

上述情况在使用 denovo 方法预测 ncRNA 序列是出现的比较多，由于 denovo 预测 ncRNA，需要完整的 ncRNA 序列，才能确认 ncRNA 的结构，而由于 ncRNA，特别是 16S 和 23S 序列，往往本身就有一定的重复序列成分，在组装过程中很容易组装不完整，特别是框架图组装时，如果整条 rRNA 没有拼接成一条完整序列，是无法预测得到相应的 rRNA 序列的。

如组装较好，该样品对应的物种在数据库注释的少，所以虽然组装 scaffold 少但还是注释不到，不代表没有 rRNA。另外，如果精细图注释到 5S，没有注释到 16S，原因是：5S 较短，序列短比对照的可能性较大。

在一些真核新物种的项目中，会经常出现 18S 等数目为 0 的情况，这个是因为之前这个物种并没有进行过 18S 序列测序，所以数据库以及常用软件中没有收录该物种的 18S 序列，所以没有办法在组装结果中预测出 18s。

4. 为什么在 genbank 找不到基因？

每一个测序菌株都会存在自己特异的基因，一般对于一个细菌来说，保守基因比率在 95%左右。所以有一部分基因在 genbank 数据库检索不到，这个属于正常现象。

其次编码基因在做同源比对的时候，往往选用蛋白与蛋白比对 (blastp) 来进行。因为不同菌株编码基因序列本身就会差异，密码子偏好性不同也会影响比对相似度，差异较多的话就会导致 blastn 比对不到。用基因氨基酸序列进行针对性的同源比对来进行检索。这样可以更准确的检索出相关基因。

5. KEGG 数据库对比时用 EC 号和 KO 区别？

KEGG ORTHOLOGY 是同源基因数据库，表示方式为 K+5 位数字，一个 KO 表示一组同源的基因。如 K01623 (http://www.kegg.jp/dbget-bin/www_bget?ko:K01623)，如果一个 KO 是酶，往往也有对应的酶标号 EC:4.1.2.13；但一个 EC 号可能对应多个 KO 号，如下图。方框表示基因产物，经常为酶，故用 EC 号填充，当该基因产物没有对应的 EC 号时，用一个名称填充。所以以 KO 统计注释到的基因个数更全面。

Orthology	K01622	fructose 1,6-bisphosphate aldolase/phosphatase
	K01623	fructose-bisphosphate aldolase, class I
	K01624	fructose-bisphosphate aldolase, class II
	K11645	fructose-bisphosphate aldolase, class I
	K16305	fructose-bisphosphate aldolase / 6-deoxy-5-ketofructose 1-phosphate synthase
	K16306	fructose-bisphosphate aldolase / 2-amino-3,7-dideoxy-D-threo-hept-6-ulosonate synthase
Entry	K01623	KO
Name	ALDO	
Definition	fructose-bisphosphate aldolase, class I [EC:4.1.2.13]	

6. 在功能注释结果中，Identity、Evalue 和 Score 的区别？

Identity 表示相似性，即序列的一致性。这个值越高，表示同源性越高，序列相似度越高，越有可能是行使相同功能的基因。这个值没有一个固定的范围，不过从经验来看，大于 80%可信度很高，小于 30%就几乎没有参考意义了。

Evalue 值是表示比对结果的可信度，是一个统计学的 P 值，用来进行判断这个比对结果是否可信。一般经验来看当 E 值小于 $1e-5$ 时，认为结果可信。E 值和 identity 没有关系，也不能换算。

比对的 Identity 是体现了比对区域相似性的高低，值越高相似性越高，但 Identity 的高低不能体现整体比对长度的大小，而 Evalue 值是结合序列长度计算出来的，所以在注释结果中，可以先根据 Evalue 的高低判断可靠性，Evalue 值越小可靠性越高。


用来挑选最佳比对结果的时候，往往是选用得分 score，得分 score 最高的那个比对结果是最相似最可信的。

7. 将基因组的 KO 号输入 KEGG 网址分析，为什么有的基因找不到？

KEGG 库中注释到的基因，有一部分是参加代谢网络的或者有代谢通路图，可以在 KEGG 的 pathway 数据库中找到，但是有一部分基因是不参加代谢通路网络的，或者是 KEGG 的 pathway 数据库现有的代谢通路图中没有该基因参与的代谢通路图，这部分基因只能在 KEGG 的 gene 库中找到，不能在 pathway 数据库中找到。

8. KEGG 数据库的 map 图中框出来的代表什么，不同颜色表示什么意思？

有颜色的框表示在该样品中注释到了这个酶，不同颜色表示该样品注释到这个基因的个数，方框内为 EC 号，鼠标停留在框内可显示出对应的相关信息，点击可跳转到 KEGG 网站查看详细信息。也可在~.kegg.catalog.map.gene.xls 文件中对应各 map 编号查看注释到基因，对应 gene_ID 即可在 03.Genome_Component 文件夹的 Gene 中查找相应的序列及信息。相应图例会在结果文件中展示，color_direction.gif 示例如下，详细信息您可以查看 KEGG_KO.readme。框里面数字的颜色表示与疾病相关的基因。



9. KEGG 图中的代码知道酶的名字？

方法一：在 KEGG 主页（<http://www.kegg.jp/>）输入酶标号，如 5.1.1.3，进行搜索。

方法二：我们提供的 map 图的名称与 KEGG 数据库的 map 号是一致的，如 map00010.png。在 KEGG 主页（<http://www.kegg.jp/>）输入“map00010”，可以搜索出这张 map 图，进而可以点击所有的方框查看对应酶的信息。（kegg 流程升级后，在我们提供的图上可以直接点击查看）。

10. 次级代谢产物基因簇注释分析中为什么没有 PKS（聚酮合酶）和 NRPS（非核糖体肽合成酶）结构？

在进行分析时，分两步进行：首先，我们先预测是否存在PKS（聚酮合酶）和NRPS（非核糖体肽合成酶）。其次，根据目前软件训练集中的基因簇的结构进行预测的，如果训练集中的基因簇中有匹配的结构就会预测出来，当然也就有预测不到的情况。也就是说出现没有PKS（聚酮合酶）和NRPS（非核糖体肽合成酶）可能是由于样本本身就没有这两种酶；或者是这两种的酶的结果与训练集中的结果不匹配导致。

11. 如何打开结果文件

我们在对应文件夹内有较为详细的文件说明。结果文件分两类，一类是普通文本文件（或压缩的文本文件），可以用文本编辑器打开（或解压后用文本编辑器打开），推荐文本编辑器 Notepad2，下载网址为：

<http://www.flos-freeware.ch/notepad2.html>；另外一类是图片文件，可以用图片浏览器打开，如 windows 中的图片预览工具，其中一类图片文件是 svg 文件，是用于网络的矢量图格式，可以用 8.0 以上的 IE，或者 firefox，chrome 之类的第三方浏览器打开。更老版本的 IE 需要安装插件才能显示，推荐使用 firefox。

此外超大文件的打开，如 cleandata 的 fastq 文件，这些文件也是纯文本文件，可用文本编辑器打开，不过由于 windows 下读取文本文件的内存机制，会将整个文件读入内存，瞬间将内存占满，因此通常读取会产生障碍。实际上这些文件是测序的原始数据，结果文件中已包括具体的统计结果，建议老师不要在 windows 下尝试打开类似文件。如果老师有需求，我们可以提供截取部分文件内容作为示例。